

第二次实验讲义

从二叉树到决策树

查找路径 分类推理 信息熵与信息增益

主讲	钟志诚
整理	曾有成
单位	中国科学技术大学人工智能与数据科学学院
建议学时	3 学时, $3 \times 45 = 135$ 分钟 (含手算、讨论与代码演示)
学习路线	二叉树结构 $\rightarrow$ 二叉搜索树 $\rightarrow$ 决策树推理 $\rightarrow$ 从数据学习划分
贯穿案例	西瓜书表 4.1: 17 条记录、6 个离散属性、好瓜与坏瓜
配套程序	<code>code/decision_tree.py</code> ; Python 语法带练另附

目录

第一部分 实验目标与预备知识	1
第二部分 二叉树：先认识结构	1
第三部分 二叉搜索树：用有序性缩小查找范围	2
第四部分 决策树：把分支规则用于分类	4
第五部分 训练数据：把一筐瓜写成表	7
第六部分 信息熵：衡量节点还剩多少不确定性	8
第七部分 信息增益：选哪个问题最有帮助	9
第八部分 从公式到算法：递归训练与循环预测	12
第九部分 评估与局限：长出一棵树还不够	14
第十部分 练习与参考解答	15
第十一部分 符号索引与资料	18

第一部分 实验目标与预备知识

1.1 本次课的起点与目标

面对一筐尚未剖开的西瓜，我们希望依据色泽、根蒂等属性判断好坏。若把每条规则写成一串条件判断，程序很快变长；树能够把“当前问什么、接下来走哪里、何时给答案”组织成清晰的结构。

本讲义先借二叉搜索树解释**沿分支逐步排除可能性**，再进入人工智能分类任务：树的结构和规则怎样从样本中学出来？先学会使用一棵已有的树进行推理，再解释训练算法为什么选择这些问题。

学习目标

完成本实验后，应能：说清二叉树与二叉搜索树的区别；手动跟踪一次成功与失败的查找；沿西瓜决策树完成一次预测；用样本计数算出信息熵和信息增益；说明训练与推理的输入为何不同。

1.2 预备知识

本实验需要使用列表、字典、类和函数。不熟悉这些语法时，可先阅读配套的《Python 语法带练》。练习代码位于code/decision_tree.py，按 T1-T7 逐步补全。

第二部分 二叉树：先认识结构

2.1 节点、边、根与叶

树用节点表示对象，用边表示上下层关系。本课使用有根树：一个根节点没有父节点，其余节点各有一个父节点；沿父子关系不会回到原处。两个节点间的连接路径是唯一的。

二叉树中，每个节点至多有两个孩子，分别称为左孩子和右孩子。左右有区别：只有左孩子与只有右孩子是不同的结构。二叉树可以为空，也可以只有一个根节点。




图 1：琥珀色是根，浅青色是叶；箭头从父节点指向孩子。C 只有右孩子。

- **根节点**是入口，此处为 A；**叶节点**没有孩子，此处为 D、E、F。
- 节点 B 与它下面的 D、E 组成以 B 为根的**子树**。子树本身仍是一棵树。
- 从根到一个节点经过的边数叫**深度**。本讲义约定根深度为 0，整棵树**高度**为最大节点深度，此例为 2。

易错提醒

“二叉”只规定孩子数量和左右位置，**不规定节点中的值必须有大小顺序**；也不要求左右两边一样高。不能仅凭一棵树有两个分支，就断言能够像查字典一样快速查找。

思考题 1

图 1 中有几个节点、几条边、几个叶节点？若去掉 E，B 会变成叶节点吗？

第三部分 二叉搜索树：用有序性缩小查找范围

3.1 二叉树加上一条“整个子树有序”的约束

二叉搜索树也称二叉查找树，英文为 BST (Binary Search Tree)。每个节点保存一个用于比较的**键**。本例键为互不相同的整数；对每个节点，左子树所有键都小于当前键，右子树所有键都大于当前键。左右子树也必须满足相同约束。




图 2：二叉搜索树示例；琥珀色边表示查找 10 的路径。

3.2 一次成功查找：目标键 10

目标键记为 q ，当前节点的键记为 k 。比较 q 与 k 后，整个不可能包含目标的子树可以被排除。

步数	当前键	比较与行动	为什么可以排除另一侧
1	8	$10 > 8$ ，走右子树	左子树所有键均小于 8
2	12	$10 < 12$ ，走左子树	右子树所有键均大于 12
3	10	$10 = 10$ ，找到并停止	返回保存该键的节点

3.3 一次失败查找：目标键 11

访问序列为 $8 \rightarrow 12 \rightarrow 10$ 。到 10 时， $11 > 10$ ，还应去右孩子，但右孩子不存在，于是返回“未找到”。到达叶节点不一定成功，必须检查键是否相等。

思考题 2

若把键 9 放在节点 4 的右孩子位置，只检查“ $9 > 4$ ”是否足够？

3.4 从查找路径到可执行循环

以下代码只负责查找。假设每个节点对象已有 `key`、`left`、`right` 三个属性，空孩子为 `None`；它不是配套决策树类的方法。

```
def search(root, target):
    node = root
    while node is not None:
        if target == node.key:
            return node
        if target < node.key:
            node = node.left
        else:
            node = node.right
    return None
```

`root` 是树的入口，`target` 是要找的键，`node` 记录当前访问位置。`return` 立即结束查找；`node = node.left` 只移动当前引用，不删除右子树，也不修改原树。

为什么不会漏掉已存在的键

每次进入循环时，若目标在树中，它一定在当前节点或当前子树里。若目标小于当前键，右子树的所有键都更大，可以整体排除；反之亦然。因此每次移动后，目标若存在，仍在保留下来的子树中。最终找到相等键，或者走到空位置证明不存在。

3.5 查找快不快，取决于树高

设树中有 m 个节点，高度为 h 。每访问一个节点只做常数比较，一条根到叶的路径最多访问 $h + 1$ 个节点。用 $O(\cdot)$ 表示忽略常数后的增长量级：

$$T_{\text{search}} = O(h + 1). \quad (3.5.1)$$

若树保持平衡，高度随节点数按对数增长；若把递增的键依次插入普通二叉搜索树，又不做平衡调整，树可能退化为链：

$$\text{平衡时: } h = O(\log m), \quad T_{\text{search}} = O(\log m); \quad \text{链状时: } h = m - 1, \quad T_{\text{search}} = O(m). \quad (3.5.2)$$



图 3：横向绘制的退化链，画法不改变父子关系。

易错提醒

二叉搜索树的查找时间取决于树高；只有在树保持平衡时，才能保证对数级的查找时间。

第四部分 决策树：把分支规则用于分类

4.1 从“找一个已有键”换成“判断一个新样本”

西瓜分类的输入是一只瓜的属性，输出是类别。我们不要求新瓜与训练记录中的某只瓜完全相同，也不是用西瓜编号找到一个已有标签。需要的是一套能够应用到新属性组合上的判断规则。




图 4：分类推理只读取属性；真实类别在预测完成后才用于核对。

比较项	二叉搜索树	分类决策树
要解决的问题	某个键是否已存在，在哪里	新样本应属于哪个类别
内部节点保存	可比较的键	一个属性测试或划分条件
分支由什么决定	目标键与当前键的大小	样本在测试属性上的取值
成功 / 停止位置	键相等；或走到空位置	到达叶节点；或使用默认回退
结构的来源	数据结构的构造与维护	从训练样本和标签中学习
是否必须二叉	是	不一定；可二叉，也可多叉

4.2 训练与推理是两个不同阶段

训练看到属性和标签，要决定“在哪个节点问哪个问题、何时停止、叶节点输出什么”。**推理**使用固定树，只看到待预测样本的属性，按现有分支走到答案；它不在每一步重新计算信息增益。

核心结论

本课使用**离散属性多叉决策树**：纹理有清晰、稍糊、模糊三种取值，就可以产生三个分支。二叉树是理解树结构的入口，不是对决策树分支数的限制。

4.3 一棵可以执行的西瓜决策树

图 5 由西瓜数据集的 17 条记录训练得到。浅蓝节点表示属性测试，浅青节点表示输出类别；边上的文字是属性取值。琥珀色边标出原编号 15 的推理路径。




图 5：西瓜分类决策树；划分准则与并列处理见第7.2节。

思考题 3

原编号 9 的瓜，纹理为稍糊、触感为硬滑。需要读取色泽吗？

4.4 一次完整推理：先遮住标签，再走路径

从表 4.1 取原编号 15，只向预测函数提供六个属性：

$$\mathbf{x} = (\text{乌黑, 稍蜷, 浊响, 清晰, 稍凹, 软粘})^\top. \tag{4.4.1}$$

这里 $\mathbf{x}$ 是六维属性向量； $\top$ 表示转置，写成列向量便于统一数学记号。代码里仍用长度为 6 的列表表示一个样本，列编号从 0 开始。

步骤	当前节点	读取的属性	进入的节点与输出
1	纹理（列 3）	$\mathbf{x}[3]$ 为清晰	进入根蒂节点
2	根蒂（列 1）	$\mathbf{x}[1]$ 为稍蜷	进入色泽节点
3	色泽（列 0）	$\mathbf{x}[0]$ 为乌黑	进入触感节点
4	触感（列 5）	$\mathbf{x}[5]$ 为软粘	到坏瓜叶节点；输出 0

核心结论

预测类别记为 $\hat{y}$ ，帽号表示模型预测。该样本得到 $\hat{y} = 0$ ，与真实标签 $y = 0$ 相同。这里使用训练记录演示路径，属于训练集回代。

4.5 未出现过的属性值怎么处理

每个节点除属性列和分支字典外，还保存该节点训练样本中的**多数类**。预测时若找不到对应分支，本实验返回**当前节点**的多数类。

例如，沿“清晰 → 稍蜷”到达色泽节点后，若新瓜色泽为该节点没见过的“浅白”，该节点的训练样本为原编号 6、8、15，标签为 1、1、0，因此回退输出 1。回退不等于宣称该新瓜一定是好瓜；它只是数据不足时的默认决策。

易错提醒

当前节点的多数类可能与根节点不同。本例根节点 8 个好瓜、9 个坏瓜，多数类为 0；刚才色泽节点的多数类却为 1。不能把所有未知分支都统一送回根节点的多数类。

一次预测只访问从根出发的一条路径，访问长度决定推理的工作量。

第五部分 训练数据：把一筐瓜写成表

5.1 完整西瓜数据集 2.0

表 1 取自《机器学习》第 4 章表 4.1，17 条记录和 6 个离散属性全部保留；只把“是 / 否”编码为 1 / 0。编号用于追溯教材，不参加划分。

原编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	1
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	1
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	1
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	1
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	1
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	1
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	1
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	1
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0
10	青绿	硬挺	清脆	清晰	平坦	软粘	0
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0

表 1：原编号 1–8 是好瓜，9–17 是坏瓜；代码保留上述行序。

5.2 样本、列和标签的记号

训练集记为 D ，第 n 个样本为 $\mathbf{x}^{(n)}$ ，标签为 $y^{(n)} \in \{0, 1\}$ 。括号上标 (n) 仅表示当前样本编号，不是幂； $x_j^{(n)}$ 表示其第 j 个属性。本讲义的属性列与 Python 一致，从 0 到 5 编号。

特征表 $\mathbf{X}$ 按样本行排列，形状为 $N \times d$ ；这里 $N = 17, d = 6$ 。代码中用二维列表保存 $\mathbf{X}$ ，每项是表示离散属性值的字符串。标签向量 $\mathbf{y}$ 长度为 17。当前数学样本编号从 1 起，Python 行索引从 0 起；抽取子集后，子集当前行号与教材原编号要分开保存。

下文 D 也表示正在处理的节点样本子集，其大小随递归改变。

第六部分 信息熵：衡量节点还剩多少不确定性

6.1 先有类别比例，再有熵

若一个节点里的瓜全是好瓜，已经不需要再问；若好坏各半，单凭这个节点还难以判断。先用当前节点内的经验比例表示类别分布。记 p_k 为类别 k 所占比例， $k = 0, 1$ ； $|D|$ 表示样本数， $\#\{\cdot\}$ 表示满足条件的计数：

$$p_k = \frac{\#\{n : y^{(n)} = k, \mathbf{x}^{(n)} \text{属于当前节点}\}}{|D|}, \quad p_0 + p_1 = 1. \quad (6.1.1)$$

类别概率为 p 的结果，用 $-\log_2 p$ 表示它出现时的信息量：越罕见，信息量越大。 $\log_2$ 是以 2 为底的对数，单位为比特 (bit)。按结果出现的概率求平均，就得到**信息熵**：

$$\text{Ent}(D) = \sum_{k=0}^1 p_k (-\log_2 p_k) = - \sum_{k=0}^1 p_k \log_2 p_k. \quad (6.1.2)$$

Ent 是把标签分布映射为非负数的函数； $\sum$ 表示对两个类别的项求和。约定 $0 \log_2 0 = 0$ ，程序中跳过概率为 0 的项，不计算 $\log_2(0)$ 。

6.2 三组能手算的标签

标签	类别比例	熵与解释
[1, 1, 1, 1]	$p_1 = 1, p_0 = 0$	熵为 0，纯节点
[0, 0, 1, 1]	$p_1 = p_0 = 1/2$	熵为 1，二分类最不确定
[0, 0, 0, 1]	$p_1 = 1/4, p_0 = 3/4$	熵约 0.811278，比均分更纯

对西瓜数据集集中的 17 条训练记录：

$$\text{Ent}(D) = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} \approx 0.997502546. \quad (6.2.1)$$

核心结论

二分类熵介于 0 与 1 之间，越小越纯。熵不是“好瓜概率”：全是坏瓜与全是好瓜的熵都为 0，但输出类别不同。因此节点还需另存类别信息。

思考题 4

把 [0, 0, 1, 1] 的最后一个 1 改成 0，熵变大还是变小？

第七部分 信息增益：选哪个问题最有帮助

7.1 从分支概率推出加权平均

选属性列 j 提问时，令 V_j 表示该属性在当前节点实际出现不同取值集合；例如纹理的集合为 {清晰, 稍糊, 模糊}。令 $D_{j=v}$ 表示属性 j 取值为 v 的样本子集。

从当前节点均匀抽一条记录，它落入分支 v 的比例为 $|D_{j=v}|/|D|$ 。已知分支后的剩余不确定性为 $\text{Ent}(D_{j=v})$ ，因此提问后的平均不确定性是

$$H_{\text{after}}(D, j) = \sum_{v \in V_j} \frac{|D_{j=v}|}{|D|} \text{Ent}(D_{j=v}). \quad (7.1.1)$$

这里 H_{after} 是当前属性划分后的加权熵，输入是当前节点与属性列，输出仍以 bit 为单位。各分支权重之和为 1。**信息增益**就是划分前后不确定性的减少：

$$\text{Gain}(D, j) = \text{Ent}(D) - H_{\text{after}}(D, j) = \text{Ent}(D) - \sum_{v \in V_j} \frac{|D_{j=v}|}{|D|} \text{Ent}(D_{j=v}). \quad (7.1.2)$$

为什么不能把几个分支直接平均

设一个分支只有 1 条样本，另一个有 16 条；它们分别影响原节点的 $1/17$ 与 $16/17$ 。直接取两个熵的算术平均，会把那个只有 1 条样本的分支放大到一半权重。按样本数加权，才对应“随机抽取一个当前样本，问完问题后平均还剩多少不确定性”。

7.2 把数学目标变成一次属性搜索

令 A 为当前路径还没有使用的候选属性列集合， j^* 表示选择结果； $\arg \max$ 返回使增益最大的属性编号，不是增益值：

$$j^* = \arg \max_{j \in A, |V_j| > 1} \text{Gain}(D, j). \quad (7.2.1)$$

只考虑能形成至少两个非空分支的属性；增益并列时按候选列表顺序选先遇到者。程序将相差不超过 10^{-12} 视作并列，减轻浮点计算差异。

这一步是**贪心选择**：只优化当前节点的一步划分，不保证整棵树最浅或测试误差最小。以信息增益选择属性的经典方法称为 ID3 (Iterative Dichotomiser 3)；本实验实现其中的离散属性递归划分主线。

思考题 5

某个属性在当前节点全部相同，它的增益是多少？

7.3 根节点手算：纹理的三条分支

回到完整的 17 条记录。先按纹理分组，再分别计数和计算熵。表中编号均为教材原编号。

纹理	原编号	好瓜	坏瓜	权重	子节点熵
清晰	1、2、3、4、5、6、8、10、15	7	2	9/17	0.764204507
稍糊	7、9、13、14、17	1	4	5/17	0.721928095
模糊	11、12、16	0	3	3/17	0

以清晰分支为例，将 7 个好瓜、2 个坏瓜代入：

$$\text{Ent}(D_{3=\text{清晰}}) = -\frac{7}{9} \log_2 \frac{7}{9} - \frac{2}{9} \log_2 \frac{2}{9} \approx 0.764204507. \quad (7.3.1)$$

其余两支分别得到 $-\frac{1}{5} \log_2 \frac{1}{5} - \frac{4}{5} \log_2 \frac{4}{5} \approx 0.721928095$ 和 0。用分支样本比例加权：

$$\begin{aligned} H_{\text{after}}(D, 3) &\approx \frac{9}{17} \times 0.764204507 + \frac{5}{17} \times 0.721928095 + \frac{3}{17} \times 0 \\ &\approx 0.616910649, \end{aligned} \quad (7.3.2)$$

$$\text{Gain}(D, 3) \approx 0.997502546 - 0.616910649 = 0.380591897.$$

这里 3 是纹理的 Python 列编号。对六个属性做同样的计算：

属性	色泽	根蒂	敲声	纹理	脐部	触感
原始计数计算值	.108125	.142675	.140781	.380592	.289159	.006046
教材列示近似值	.109	.143	.141	.381	.289	.006

核心结论

六个属性中，纹理的信息增益最大，因此选择纹理作为根节点的划分属性。

数值说明：用原始计数计算，色泽增益约为 0.108125；若先将各熵保留三位小数，再计算并舍入，可得教材列示的 0.109。程序按原始计数计算。

7.4 再走一层：必须在子集内重新计算

根节点选纹理后，“模糊”分支全是坏瓜，立即成为叶节点；“清晰”分支还有 9 条记录，包含 7 个好瓜和 2 个坏瓜，仍需划分。记这个子集为 D_{clear} ，可用属性不再包含纹理。

若按根蒂分组，会得到：

根蒂	原编号	标签计数	子节点熵
蜷缩	1、2、3、4、5	好 5、坏 0	0
稍蜷	6、8、15	好 2、坏 1	0.918295834
硬挺	10	好 0、坏 1	0

因此，根蒂在当前子集中的增益为

$$\begin{aligned} \text{Gain}(D_{\text{clear}}, 1) &\approx 0.764204507 - \left(\frac{5}{9} \times 0 + \frac{3}{9} \times 0.918295834 + \frac{1}{9} \times 0 \right) \\ &\approx 0.458105895. \end{aligned} \quad (7.4.1)$$

注意这里权重的分母为 **9**，不是根节点的 17。重新计算剩余属性得到：

属性	色泽	根蒂	敲声	脐部	触感
当前增益	.043068	.458106	.330856	.458106	.458106

根蒂、脐部和触感的增益并列，按候选列顺序选择根蒂。选择其他并列最优属性时，可能得到不同的树形。

7.5 后续节点的划分

沿“清晰 → 稍蜷”剩下原编号 6、8、15，标签为 1、1、0，熵约 0.918296。此时色泽与触感的增益都约为 0.251629，优先选色泽；乌黑分支剩下 8、15，最后由触感区分为好瓜与坏瓜。这样就得到图 5 中原编号 15 走过的那条路径。

思考题 6

能否先在完整数据上把六个属性排好序，然后每一层照这个顺序提问？

第八部分 从公式到算法：递归训练与循环预测

8.1 叶节点为什么使用多数类

某个节点无法继续细分时，必须用一个类别代表其中全部记录。设候选输出为 $c \in \{0, 1\}$ ； $\mathbf{1}[\cdot]$ 是指示函数，条件成立取 1，否则取 0。当前节点的错误数为

$$E_D(c) = \sum_{\mathbf{x}^{(n)} \in D} \mathbf{1}[y^{(n)} \neq c] = |D| - \#\{n : y^{(n)} = c, \mathbf{x}^{(n)} \in D\}. \quad (8.1.1)$$

因此，使错误数最小就等价于使正确类的计数最大：

$$c^* = \arg \min_{c \in \{0, 1\}} E_D(c) = \arg \max_{c \in \{0, 1\}} \#\{n : y^{(n)} = c, \mathbf{x}^{(n)} \in D\}. \quad (8.1.2)$$

$\arg \min$ 表示取到最小值的类别；这就是多数类规则的来由。这里默认两种误判代价相同；平票时本实验固定选 0，便于复现。

8.2 训练：把同一个任务交给更小的子集

1. 创建默认叶节点，记录当前多数类。
2. 若标签已经全相同，直接返回；若候选属性为空，也直接返回。
3. 在当前子集上搜索有至少两种取值的候选属性，选信息增益最大的一个。若没有可划分属性，返回默认叶节点。
4. 将该属性记录为当前节点的问题。对实际出现的每个取值，取出对应特征行与标签。
5. 用新的候选属性列表递归建子树：只去掉已经使用的属性编号，保留特征矩阵所有列；把返回的子树挂到该取值的分支下。

递归是在更小子集上调用同一个建树方法。每条路径至多使用 6 个离散属性，因此会结束；纯节点和无法细分的节点还会提前结束。

易错提醒

不要额外加入“增益为 0 就立即停止”的规则。人工构造的两位异或数据 $(0, 0) \mapsto 0$ 、 $(0, 1) \mapsto 1$ 、 $(1, 0) \mapsto 1$ 、 $(1, 1) \mapsto 0$ ，两个属性在根处的增益都为 0，但先划分一个，再划分另一个就能分开全部类别。

实现约定

本实现只为当前节点实际出现的属性值创建分支，因此递归不接收空子集。预测时遇到未知属性值，按第 4.5 节的规则回退。这一约定用于默认分类，尚未处理训练数据中的缺失值。

8.3 与 Python 类骨架逐一对照

方法	职责	手敲顺序
<code>__init__</code>	初始化根节点，暂不训练	已提供
<code>_entropy(y)</code>	计数、求比例、累加负对数项	T1
<code>_majority_label(y)</code>	返回多数类，平票选 0	T2
<code>_information_gain</code>	分组并计算加权熵减少量	T3
<code>_best_feature</code>	比较当前可用属性的增益	T4
<code>_build_tree</code>	判断终止条件，递归创建子树	T5
<code>fit(X, y)</code>	保存训练得到的根节点	已提供
<code>_predict_one(x)</code>	对一个样本沿分支走到输出	T6
<code>predict(X)</code>	按输入行序重复单样本预测	T7

8.4 单样本预测的实现

在 T6 的 `_predict_one` 中，将图 5 的预测路径写成循环：

- 1. 令当前节点为 `self.root`。
- 2. 若当前节点为叶节点，返回其 `label`。
- 3. 读取当前节点保存的属性列编号，再取出样本 `x` 在该列的值。
- 4. 若该值对应的分支不存在，返回当前节点的 `label`；否则进入对应子节点，继续循环。

输入 `x` 是一个样本的完整特征列表，输出是 0 或 1。调用前必须完成训练；内部节点保存原始属性列编号，叶节点的 `feature` 为 `None`。完成 T6 后，再在 T7 中按输入行序重复调用单样本预测。

思考题 7

这一循环与二叉搜索树的查找循环有什么共同点、什么不同点？

易错提醒：列 0 是合法属性，必须判断 `feature is None`。训练时保留 `X` 的列，避免原始列编号错位。

第九部分 评估与局限：长出一棵树还不够

9.1 回代正确，不等于新样本正确

图 5 可以将当前 17 条训练记录全部分对。用训练时见过的记录再次预测，称为训练集回代；这个结果可用于检查实现，但不能说明模型对未见样本的预测表现。

数据部分	允许的用途	不应承担的用途
训练集	学习属性划分、分支与叶类别	不能用回代成绩替代独立评价
验证集	选择最大深度或剪枝等方案	不能把方案选择后的分数当最终证据
测试集	方案锁定后评价新样本表现	不能反复用于选属性、调参或删除例

本课主线只实现离散树且不剪枝；剪枝是删除收益不足的分支来控制复杂度。将来比较剪枝方案时，应预先留出验证集，不用测试集挑出“最好看”的树。

9.2 准确率与误判代价

对独立评价集 D_{eval} ，样本数为 N_{eval} ，预测类别为 $\hat{y}^{(n)}$ 。准确率对所有样本的预测是否正确求平均：

$$\text{Accuracy} = \frac{1}{N_{\text{eval}}} \sum_{n=1}^{N_{\text{eval}}} \mathbf{1}[\hat{y}^{(n)} = y^{(n)}]. \quad (9.2.1)$$

帽号仍表示预测， $\mathbf{1}$ 仍是指示函数。若卖瓜时“坏瓜判为好瓜”的代价更高，应分别统计两类误判，不能只看一个准确率。多数类叶节点的规则也隐含了等代价假设。

9.3 需要记住的局限

- 信息增益偏好取值多的属性。若把唯一编号作为属性，每个分支只有一条记录，熵会变为 0，却只记住了训练样本。
- 小样本稍有变化，最大增益属性和树结构就可能改变；并列最优时树也不唯一。
- 很深的树容易拟合训练噪声。不断减少训练熵不保证减少测试错误。
- 本实现只处理离散属性。连续特征需要搜索阈值；不能把每个不同小数直接当成一个分支来替代阈值学习。

第十部分 练习与参考解答

10.1 自测题

1. 一棵树每个节点有至多两个孩子，就一定是二叉搜索树吗？请给理由。
2. 预测一条新样本时，程序需要访问整棵决策树吗？需要读取训练集或真实标签吗？
3. 分支大小不同，为什么信息增益公式不能直接平均子节点熵？
4. 某个叶节点的训练标签为 $[1, 1, 0]$ ，按多数类规则输出什么？此时会错分几条训练记录？

10.2 课后练习：从手算到程序

1. 在图 2 中分别查找 6 和 5，写出访问序列与停止原因。若树有 7 个节点，它是否一定只比较 3 次？
2. 教学标签集合为 $[0, 0, 0, 1]$ 。求信息熵；再按某属性划成 $[0, 0]$ 与 $[0, 1]$ ，求加权子熵和信息增益。
3. 不看答案，用表 1 复核纹理的三组计数及信息增益；指出哪条分支立即成为叶节点。
4. 一条样本的纹理为清晰、根蒂为稍蜷、色泽为乌黑，触感为未见过的“粗糙”。沿图 5 写出预测路径，并根据到达节点的训练记录判断输出类别。
5. 完成配套脚本 T1–T3，运行脚本并对照手算结果；说明 $\text{count}/\text{len}(y)$ 、 $\log_2$ 、分支权重各对应哪个数学量。再继续完成 T4–T7。

调试建议

可在信息增益分组处和递归入口设置断点，检查当前标签、样本数和候选列。每完成一个方法，先用小样例确认输出，再运行完整数据。

10.3 课后练习参考解答

练习 1：查找 6 和 5

查找 6：8→4→6，在键相等时成功。查找 5：8→4→6，随后应去 6 的左孩子，该位置为空，所以失败。7 个节点也可能组成高度 6 的链，最坏需访问 7 个节点；不能只凭节点数断言树保持平衡。

练习 2：加权减少量

原标签比例为 3/4 和 1/4，因此

$$\text{Ent}(D) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.811278124. \quad (10.3.1)$$

两个子集各有 2 条样本，熵分别为 0 和 1，所以

$$H_{\text{after}} = \frac{2}{4} \times 0 + \frac{2}{4} \times 1 = 0.5, \quad \text{Gain} \approx 0.811278124 - 0.5 = 0.311278124. \quad (10.3.2)$$

这里只有在两个子集大小相同时，加权平均恰好等于算术平均。

练习 3 与 4：回到真实数据

纹理清晰分支为好 7 坏 2，稍糊为好 1 坏 4，模糊为好 0 坏 3。三条分支的样本数分别为 9、5、3，根处增益约 0.380591897，模糊分支直接成为坏瓜叶节点。

练习 4 的路径为“纹理 = 清晰 → 根蒂 = 稍蜷 → 色泽 = 乌黑”，到达触感节点。该节点对应原编号 8、15，标签分别为 1、0；“粗糙”没有对应分支，两类平票时按约定输出 0。这里使用触感节点的计数，而不是其父节点的多数类 1。

练习 5：公式与语句的映射

`count/len(y)` 得到 p_k ； $-p * \log_2(p)$ 是单类对熵的贡献；`len(child_y)/len(y)` 是当前分支权重。信息增益用父熵减去加权子熵。`y` 必须始终是当前节点的标签，不能在递归中错用全体 17 条标签。

10.4 思考题与自测题参考解答

思考题

1. 6 个节点、5 条边、3 个叶节点；不会，因为 B 仍有左孩子 D。
2. 不够。9 仍处在根 8 的左子树中，却大于 8，违反了整棵子树的约束。
3. 不需要。按“纹理 = 稍糊”进入触感节点，再按“硬滑”到坏瓜叶节点。预测时只访问一条路径。
4. 变小，约为 0.811278；某一类更占优势，剩余不确定性减少。
5. 0。唯一子集就是原集合，划分前后的熵相同，不能缩小问题。
6. 不能。各子集类别比例、分支比例都变了，必须重新计算。原列顺序只用于并列时的确定性选择，不代替信息增益。
7. 都维护当前节点、依据规则移动并在适当位置停止。查找循环比较目标键与节点键；预测循环读取样本属性，根据分支字典移动，返回叶节点类别。

自测题

1. 不一定。二叉搜索树还要求每个节点的左子树所有键都小于当前键，右子树所有键都大于当前键。
2. 只沿一条路径访问节点，直到输出类别；预测只需要已训练的树和新样本属性。
3. 每个分支对原节点的影响取决于它包含的样本比例，因此须用该比例加权。
4. 输出 1，错分 1 条记录。在误判代价相同的前提下，多数类使当前节点的错误数最少。

第十一部分 符号索引与资料

11.1 数据与模型

符号	含义	首次说明
q, k	查找目标键、当前节点的键	3.2
m, h	搜索树节点数、高度；根深度为 0	3.5
$\mathbf{x}, \mathbf{x}^{(n)}$	单个属性向量、第 n 个当前样本	4.4、5.2
$x_j^{(n)}, y^{(n)}, \hat{y}^{(n)}$	第 j 个属性、真实标签、预测标签	5.2、4.4
$\mathbf{X}, \mathbf{y}, N, d$	按行排列的特征、标签、样本数、属性数	5.2
$D, D_{j=v}, V_j, A$	当前样本集、分支子集、取值集合、候选列	5.2、7.1–7.2

11.2 函数、算子与经验比例

符号	含义	首次说明
$ D , \#\{\cdot\}$	集合大小、满足条件的计数	6.1
p_k	当前节点内类别 k 的经验比例	6.1
$\log_2, \sum$	以 2 为底的对数、求和	6.1
$\text{Ent}, H_{\text{after}}$	节点信息熵、划分后的加权熵	6.1、7.1
Gain, j^*	信息增益、选中的属性列	7.1–7.2
$\arg \max, \arg \min$	返回最大 / 最小函数值对应的参数	7.2、8.1
$\mathbf{1}[\cdot], E_D(c), c^*$	指示函数、错误数、所选叶类别	8.1
$\top, \hat{\cdot}, O(\cdot)$	转置、预测帽号、增长量级	4.4、3.5
$D_{\text{eval}}, N_{\text{eval}}$	独立评价集及其样本数	9.2

11.3 参考资料

- 1. 周志华，《机器学习》，第 4 章：决策树。表 4.1 提供本讲义使用的西瓜数据；信息熵与信息增益用于选择划分属性。
- 2. 配套练习：`code/decision_tree.py`。
- 3. 语法复习：《Python 语法带练》及`code/python_syntax/` 中的分章脚本。