

人工智能数学原理与算法 B

第三次实验

逻辑回归与大学排名分类

课程前置讲义

主讲 胡泷

整理 胡泷、曾有成

任课教师 钟志诚

单位 中国科学技术大学
人工智能与数据科学学院

从数据到可解释的分类流程

数据清洗与划分 → 数值表示 → 线性得分与概率 → 交叉熵与正则化 → 梯度更新 → 独立评估。

2026 年秋季 建议 3 学时 (135 分钟)

C0-C7 分阶段完成；日期与提交平台以课程通知为准。

随包数据为 QS (Quacquarelli Symonds) 2026 排名的教学整理版。

目录

1 任务、边界与数据来源	1
2 从原表选择可用字段	2
3 数值填补、标准化与数据划分	3
4 类别编码与增广设计矩阵	4
5 批次、数据集与训练顺序	5
6 线性得分、概率和类别	6
7 从伯努利似然到交叉熵	7
8 从损失到一次参数更新	8
9 正则化与训练循环	9
10 正则化之外: 有边界的特征选择	10
11 评价、泛化与实验解释	11
12 自测、符号索引与资料	12

1 任务、边界与数据来源

1.1 从属性判断走向概率模型

上次实验通过属性问题构造决策树。本次使用一组可训练权重，将混合类型的大学数据转换成概率。逻辑回归（《机器学习》称对数几率回归）虽然含“回归”，这里解决的仍是二分类。

贯穿任务：给定学校的地区、办学性质、规模等信息，以及三个已公布的指标分数，识别它是否位于 **2026 年 QS (Quacquarelli Symonds) 榜单前 500 名**。标签 **top500=1** 表示属于前 500 名，0 表示榜单中其余学校。并列名次按所列名次判断，所以正类有 502 所；不把“第 500 行”作为截断位置。

这是什么任务

这是同年榜单内的分类练习，使用的数值分数也是该年已公布信息。它不是预测未来排名，不是给全球所有大学判定优劣，也不说明模型学到了学校发展的因果规律。

1.2 学习目标与先修知识

完成本讲义的学习后，学生应能够：识别标签泄漏；只用训练集拟合填充值、尺度和类别表；手算独热编码、概率、交叉熵及一次参数更新；实现 PyTorch 逻辑回归模型，并用验证集选择方案。学习本讲义前，应已掌握变量、循环、函数、字典、类、数组切片和矩阵乘法等基础知识。课堂先在 C0 复习张量形状，再学习新的编码步骤。

1.3 课堂版本的规模与来源

原始镜像共 1504 行、30 列，来自公开的 QS 2026 数据整理仓库，本实验保存了原文件及其摘要。课堂数据只选取三个数值字段与五个类别字段；原行号和学校名仅保留用于追溯，不能输入模型。数据保留了真实缺失，既不人为制造缺失，也不进行平衡抽样。

数据以种子 20261008 按标签分层，大致按 60%/20%/20% 划分为训练 902 条（正类 301）、验证 300 条（正类 100）、测试 302 条（正类 101）。学校名在源表中不重复，三份数据中的学校互不重叠。课堂数据目录为 `code/data/classroom/`。

C0: 先说清任务

预测概率为 0.7，标签是否就是 0.7？阈值 0.5 时输出哪一类？若使用 `row_id`，为何也可能泄漏答案？

2 从原表选择可用字段

2.1 字段白名单与数值含义

CSV（Comma-Separated Values，逗号分隔值）文件的每行是一所学校，每列是一个字段。程序只从字段白名单中读取输入，而不是将整张表直接转换为张量。

课堂字段	角色与处理
faculty_student_score	师生比指标 分数 ，不是原始人数比
international_faculty_score	国际教师指标分数，不是百分比
international_student_score	国际学生指标分数，不是百分比
region, status	地区与办学性质，无大小顺序
size	S、M、L、XL，学校规模档位
focus	SP、FO、CO、FC，学科覆盖类型
research	LO、MD、HI、VH，研究活跃程度
row_id, name	原表行号与名称，只用于追溯
top500	0/1 标签，不填补、不标准化

学校规模虽然有序，档位间隔却不等于相同人数；本次五个类别字段统一采用独热编码。字母排序只决定输出列顺序，不代表大小关系。

2.2 筛选不是追求更高的测试分数

当年排名和总分会直接暴露目标；上一年排名虽然可能是合法的历史预测变量，本次也预先排除，以便集中练习混合字段的处理。学校名称不能用作记忆键；原行号来自按排名排列的表，同样必须排除。完整评分向量能近似重构排名规则，本实验只保留三个分数，但它们仍与榜单构造有关。

不能把数值化等同于可用

给学校名编码成 1、2、3，或者把排名填补后当输入，都可能让程序跑通，却不符合任务。原镜像部分名次是区间，不能把区间起点当精确排名；本次阈值 500 不被现有区间跨越。

C1：缺失是什么

数值列中的空白、横线、无法解析文本转为缺失；数值 0 不是缺失。若标签缺失，能否把它填成多数类？给出理由。

3 数值填补、标准化与数据划分

3.1 只从训练集估计统计量

训练集用于学习预处理和权重，验证集用于选择方案，测试集只在冻结后评价。令 N 为训练样本数， $x_j^{(n)}$ 表示第 n 个样本的第 j 个数值特征。括号上标 (n) 是样本编号，不是幂；下标 j 是特征编号。

每个数值字段先对非缺失训练值求均值 μ_j ，用它填补该列。令填补值为 $\bar{x}_j^{(n)}$ ；波浪号保留给后面的增广向量，不在此处混用。填补后计算总体标准差 s_j ，再转换为标准化值 $u_j^{(n)}$ ：

$$s_j = \sqrt{\frac{1}{N} \sum_{n=1}^N (\bar{x}_j^{(n)} - \mu_j)^2}, \quad u_j^{(n)} = \frac{\bar{x}_j^{(n)} - \mu_j}{s_j}. \quad (3.1.1)$$

$\sum$ 表示求和，平方根将尺度还原到原单位。代码用 `std(ddof=0)`，不除以 $N-1$ 。尺度为零时替换为 1；全空训练列均值约定为 0。验证、测试复用训练均值与尺度，不能重新拟合。

C2: 可复核的小例子

训练值为 $[1, 3, \text{缺失}]$ ，均值 2，填补后为 $[1, 3, 2]$ ；总体标准差 $\sqrt{2/3} \approx 0.816497$ ，标准化后约为 $[-1.224745, 1.224745, 0]$ 。验证值 100 转成约 120.025，而不是影响训练均值；验证缺失转成 0。

3.2 真实缺失与适用边界

训练表的办学性质缺失 31 条、国际教师分数缺失 49 条、国际学生分数缺失 18 条。数值缺失用训练均值处理；类别缺失在下一节编码为 Unknown。缺失机制未被确认，不能声称它完全随机，也不能把缺失分数解释为该校真实得分为零。

C2: 检查是否泄漏

把验证集某个数值改成一百万，训练均值与训练张量应不应该改变？若先在全数据上填补再划分，会出现什么问题？

4 类别编码与增广设计矩阵

4.1 独热编码由训练类别表确定

独热编码 (one-hot encoding) 用一列指示一个类别。对地区字段, 若训练表观察到 Asia、Europe, 则固定列序为 Asia、Europe、Unknown; Unknown 接收缺失和验证/测试中训练未见的类别。

原始取值	Asia	Europe	Unknown
Asia	1	0	0
Europe	0	1	0
缺失	0	0	1
训练未见类别	0	0	1

类别表只从训练集拟合; 验证与测试必须使用相同列顺序, 不能各自生成自己的编码列。Unknown 即使未在训练中出现也预留一列, 其权重可能始终为零; 这不意味着模型学会了未知类别的特殊规律。

本次保留完整独热列, 方便直观看到每个类别; 独热列保持 0/1, **不再标准化**。完整独热列与截距存在冗余, 未正则化参数不一定可唯一解释, 但仍可计算预测。删去每组一个参考列是另一种约定, 本次不混用。

4.2 拼接并在首列增加常数

先放三个标准化数值, 再按 region、status、size、focus、research 顺序放独热列。每个字段内取训练类别的字母排序, 再加 Unknown。当前共 $d = 28$ 个特征: 3 个数值与 25 个独热列。

令 $\mathbf{x}^{(n)} \in \mathbb{R}^d$ 为处理后的样本列向量, 粗体表示向量; 转置 $\top$ 将列变成行。波浪号表示增加常数项, 以统一处理截距:

$$\tilde{\mathbf{x}}^{(n)} = (1, (\mathbf{x}^{(n)})^\top)^\top, \quad \mathbf{X} = \begin{bmatrix} (\tilde{\mathbf{x}}^{(1)})^\top \\ \vdots \\ (\tilde{\mathbf{x}}^{(N)})^\top \end{bmatrix} \in \mathbb{R}^{N \times (d+1)}. \quad (4.2.1)$$

标签列为 $\mathbf{y} \in \mathbb{R}^{N \times 1}$, 元素取 0 或 1。训练张量形状为 (902, 29), 标签为 (902, 1); 验证为 (300, 29) 与 (300, 1)。只标准化数值列, 不标准化标签或新增常数列。

C2: 编码自查

为何不能把 Asia、Europe、Americas 编为 1、2、3 后直接输入? 为何测试集中首次出现的类别不能添加新列?

5 批次、数据集与训练顺序

5.1 Dataset 与 DataLoader 各做什么

Dataset 保存特征与标签, `__getitem__` 按同一索引取一对样本。DataLoader 负责组成批次, 并且只在训练时打乱。标签与特征不能分别打乱。

```
dataset = student.UniversityDataset(X, y)
loader = student.make_loader(dataset, 64, True)
for X_batch, y_batch in loader:
    print(X_batch.shape, y_batch.shape)
```

一轮 (epoch) 遍历训练数据一次。训练集有 902 条, 批量大小 64, 因此有 14 个满批和最后 6 条, 共 15 个批次。一个批次大小记为 B , 输入形状 $(B, 29)$, 标签形状 $(B, 1)$ 。不足批量的最后一批不丢弃。

5.2 从一个小例子进入补全

先用 5 条样本、批量大小 2、顺序取样, 观察批量大小为 2, 2, 1; 再开启训练打乱, 核对特征标签始终配对。参考实现优先使用显式循环和普通 `import`, 不需要理解复杂配置系统。

代码阅读节奏

C0 观察张量形状; C1 清洗数值与标签; C2 数值处理和独热编码; C3 成对取批; C4 输出线性得分; C5 构造目标; C6 自动求导与更新; C7 解释验证和测试结果。每一步先预测小例子的输出, 再补函数、运行和解释。

C3: 为什么保留末批

如果丢弃最后 6 条, 是否每轮都训练了所有学校? 批次大小变化时, 为什么平均损失仍应除以本批实际样本数?

6 线性得分、概率和类别

6.1 三个不同的输出

参数 $\theta = (\theta_0, \dots, \theta_d)^\top \in \mathbb{R}^{d+1}$, 其中 θ_0 是截距; 代码保存为 **(d+1, 1)**。线性得分 $z^{(n)}$ 可以取任意实数。sigmoid 函数 $\sigma: \mathbb{R} \rightarrow (0, 1)$ 将得分变成概率:

$$z^{(n)} = (\tilde{\mathbf{x}}^{(n)})^\top \theta, \quad p^{(n)} = P(y^{(n)} = 1 \mid \mathbf{x}^{(n)}; \theta) = \sigma(z^{(n)}) = \frac{1}{1 + e^{-z^{(n)}}}. \quad (6.1.1)$$

P 表示概率, 条件竖线 “|” 表示给定特征; 分号后的参数确定当前模型。 e 是自然指数的底。 $p^{(n)}$ 是模型概率, 不是已观察到的标签。

$$\hat{y}^{(n)} = \mathbf{1}[p^{(n)} \geq \tau], \quad \tau \in (0, 1). \quad (6.1.2)$$

帽号在这里表示**预测类别**。 τ 是决策阈值; 指示函数 $\mathbf{1}[\cdot]$ 在括号内条件成立时为 1, 否则为 0。本课预先固定主实验阈值为 0.5, 恰好等于阈值也判为前 500 名。

6.2 为什么叫对数几率回归

几率是属于与不属于前 500 名的概率之比 $p/(1-p)$; 对数几率函数 $\text{logit}: (0, 1) \rightarrow \mathbb{R}$ 是 sigmoid 的反函数:

$$\text{logit}(p) = \log \frac{p}{1-p} = z. \quad (6.2.1)$$

$\log$ 表示自然对数。本模型假设**对数几率是处理后特征的线性函数**。sigmoid 和 logit 不能互称。阈值为 0.5 时, 边界为 $z = 0$; 提高阈值时, 边界得分变为 $\log(\tau/(1-\tau))$ 。

得分 z	-2	0	2
概率 p	0.119203	0.5	0.880797
类别 ($\tau = 0.5$)	0	1	1

检查点 C4: 模型接口

若参数是 $(1, 2, -1)^\top$, 增广输入是 $(1, 3, 2)^\top$, **forward** 应返回什么? **sigmoid(forward(X))** 又是什么?

7 从伯努利似然到交叉熵

7.1 为什么采用这个损失

给定特征，一个二分类标签服从伯努利模型：只可能取 0 或 1，取 1 的概率为 $p^{(n)}$ 。单条观测标签的概率质量为

$$P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}) = (p^{(n)})^{y^{(n)}} (1 - p^{(n)})^{1-y^{(n)}}. \quad (7.1.1)$$

若 $y^{(n)} = 1$ ，式子只留下 $p^{(n)}$ ；若标签为 0，只留下 $1 - p^{(n)}$ 。假定样本在给定参数后条件独立，整批数据的似然 Λ 是这些概率的连乘； $\prod$ 表示逐项相乘：

$$\Lambda(\boldsymbol{\theta}) = \prod_{n=1}^N P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}). \quad (7.1.2)$$

最大似然选择让已观察数据更可能出现的参数。取对数将连乘变成求和；加负号将最大化改成最小化；除以 N 得到与样本规模无关的平均损失。

$$\begin{aligned} \mathcal{L}^{(n)} &= -y^{(n)} \log p^{(n)} - (1 - y^{(n)}) \log(1 - p^{(n)}), \\ R(\boldsymbol{\theta}) &= \frac{1}{N} \sum_{n=1}^N \mathcal{L}^{(n)} = -\frac{1}{N} \log \Lambda(\boldsymbol{\theta}). \end{aligned} \quad (7.1.3)$$

$\mathcal{L}^{(n)}$ 是单样本损失， R 是经验风险（样本平均）。该损失称二元交叉熵，简称 BCE (Binary Cross-Entropy)。当真实标签为 1 时，预测 0.9 的损失约为 0.10536，预测 0.1 的损失约为 2.30259，错误且自信会受到更大惩罚。

7.2 让计算接口与公式一致

实际训练用 `BCEWithLogitsLoss`：它接收原始得分并在内部稳定计算 sigmoid 与交叉熵的组合。单样本等价式为

$$\mathcal{L}(z, y) = \max(z, 0) - yz + \log(1 + e^{-|z|}). \quad (7.2.1)$$

$\max(z, 0)$ 取较大值， $|z|$ 是绝对值；此式避免直接计算过大的指数。`BCELoss` 接收概率，`BCEWithLogitsLoss` 接收得分，不能把两种接口混用。

检查点 C5

所有得分为 0 时，平均数据损失是多少？为什么不能先 sigmoid 再传给 `BCEWithLogitsLoss`？

8 从损失到一次参数更新

8.1 梯度给出每个参数的变化方向

梯度 $\nabla_{\theta} R$ 是 R 对每个参数的偏导数组成的列向量；在当前位置，小幅沿负梯度移动会使损失一阶近似下降。先对单样本逐步求导：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial p} &= -\frac{y}{p} + \frac{1-y}{1-p}, & \frac{\partial p}{\partial z} &= p(1-p), \\ \frac{\partial \mathcal{L}}{\partial z} &= \frac{\partial \mathcal{L}}{\partial p} \frac{\partial p}{\partial z} = p - y.\end{aligned}\quad (8.1.1)$$

∂ 表示把其他变量暂时固定的偏导；链式法则把前两项相乘，约去分母，得到 $p - y$ 。又因 $z = \mathbf{\tilde{x}}^T \boldsymbol{\theta}$ ，有

$$\nabla_{\theta} R = \frac{1}{N} \mathbf{X}^T (\mathbf{p} - \mathbf{y}), \quad \boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \eta \nabla_{\theta} R. \quad (8.1.2)$$

$\mathbf{p}, \mathbf{y} \in \mathbb{R}^{N \times 1}$ ； $\mathbf{X}^T \in \mathbb{R}^{(d+1) \times N}$ ，梯度形状为 $(d+1) \times 1$ 。 $\eta > 0$ 是学习率；方括号上标 $[t]$ 表示迭代次数，与样本编号 (n) 区分。

8.2 贯穿手算：两所假设学校的更新

为便于手算，仅保留“标准化师生比分数、标准化国际学生分数”两个坐标。下表**专为课堂构造**，不是教材记录，也不是随包数据的抽样；标准化坐标 0 表示处于训练均值。

当前样本 n	师生比分数坐标	国际学生分数坐标	标签 $y^{(n)}$
1	1	0	1
2	0	1	0

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}, \quad \boldsymbol{\theta}^{[0]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{p} = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix}, \quad \nabla R = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -0.5 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0 \\ -0.25 \\ 0.25 \end{bmatrix}. \quad (8.2.1)$$

取 $\eta = 0.4$ ，更新后参数为 $(0, 0.1, -0.1)^T$ ，两条概率分别为 0.524979 和 0.475021。平均损失从 0.693147 降至 0.644397。

检查点 C6: 核对方向

第一个分数权重变大、第二个分数权重变小，为何能让这两条已知标签更可能？请用代码输出 `theta.grad` 与更新后的 `theta` 核对，不能只看损失是否下降。

9 正则化与训练循环

9.1 区分拟合损失和训练总目标

训练集拟合得好不保证新样本表现好。参数过大可能把样本噪声也拟合进去。用 Ω 表示权重惩罚, $\lambda \geq 0$ 控制其强度, 训练总目标 J 为

$$J(\theta) = R(\theta) + \lambda \Omega(\theta),$$

$$\Omega_{L1}(\theta) = \sum_{j=1}^d |\theta_j|, \quad \Omega_{L2}(\theta) = \frac{1}{2} \sum_{j=1}^d \theta_j^2. \quad (9.1.1)$$

L1 (L1 Norm, 一范数) 是绝对值之和; 本实验的 L2 (L2 Norm, 二范数) 惩罚采用二范数平方的一半, 并非二范数本身。这里不惩罚截距 θ_0 。若参数为 $(10, 3, -4)^\top$, 两种惩罚分别为 7 和 12.5。

L2 惩罚的梯度是 $(0, \theta_1, \dots, \theta_d)^\top$ 。L1 在非零坐标用符号函数求导, 零点不唯一; PyTorch 在该处取 0。普通梯度更新下不保证权重恰好为零, 不能把 L1 等同于本程序一定自动删除特征。

9.2 一批数据如何执行更新

本实验用小批量随机梯度下降 SGD (Stochastic Gradient Descent) 更新参数。对当前批次, 把上一节梯度式中的 N 换成当前批次大小 B 。`torch.optim.SGD` 已提供参数更新规则, 学生连接五个步骤:

```
optimizer.zero_grad()
logits = model(X_batch)
loss = data_loss(logits, y_batch)
objective = loss + strength * model.penalty(kind)
objective.backward()
optimizer.step()
```

`backward()` 用自动微分得到每个参数的梯度; `step()` 更新参数。梯度默认会累加, 所以每批先清零。损失在反向传播前不能用 `item()` 转成普通数, 也不能 `detach()` 切断计算图。实验中的 `train_epoch` 还需在 `step()` 之后累计各批的数据损失, 用于返回本轮平均损失, 完整代码见实验手册 C6。

曲线必须比较同一种量

不同 λ 的训练总目标不能直接拿来选模型。本实验每轮结束, 用当前同一组参数分别计算全训练集与验证集的**无正则数据损失**, 画出两条曲线; 模型选择也看验证数据损失。

检查点 C5/C6

把 `zero_grad()` 删除, 第二次更新仍与手算一致吗? 若 λ 极大, 可能发生什么?

10 正则化之外：有边界的特征选择

10.1 必要排除与验证选择不是一回事

建模前删除排名、总分、名称和行号，是按照任务排除泄漏和标识字段。特征选择则是在**允许使用的字段**中比较完整与精简表示；这里称特征选择，避免与决策树剪枝混淆。

主实验完整组为三个数值字段与五个类别字段。选做精简组删除 focus 与 research，保留三个数值与 region、status、size；编码后由 28 维变为 18 维。提前规定对照，固定同一划分、学习率、训练种子、最大轮数和 L2 系数 0.01，只改变字段组。

对照必须回答的问题

删除两个字段后，验证损失、召回率和特征维数怎样变化？若精简组更差，说明这些字段在当前划分中提供了信息；不应继续查看测试集并逐列试删直到得到高分。

10.2 正则化不等于保证提高分数

L2 通常缩小权重，L1 鼓励稀疏，但本程序用普通小批量梯度下降，L1 不保证权重精确为零。一个独热类别权重很小，也不等于整个原始字段无用；相关字段还可能分摊作用。不能用任意权重阈值直接宣布完成“自动剪枝”。

主实验的三种正则化方案只比较验证**数据损失**，不比较包含不同惩罚项的总目标；无正则也可能最好。所有方案在第 60 轮表现最好，也不证明已经达到全局数值最优，可能需要更多训练；本次不据测试结果延长训练。

10.3 选做与主实验如何衔接

命令 `python run_lab.py --feature-study` 只读取训练和验证表，不覆盖主实验冻结模型。报告中将它单独列为拓展分析，不对两个特征组分别反复测试。若另行设计将特征组也纳入选模，必须在查看测试结果前规定联合选择规则。

C7 选做

精简组维数更少但验证损失更大，可以为了“更简单”选它吗？可以讨论性能与复杂度的取舍，但必须如实报告损失，不应声称它在所有方面更好。

11 评价、泛化与实验解释

11.1 从四种计数到评价指标

以前 500 名为正类。TP (True Positive, 真正例) 是真实正类且预测正类; FP (False Positive, 假正例) 是误报; FN (False Negative, 假负例) 是漏判; TN (True Negative, 真负例) 是真实负类且预测负类。

$$\text{Accuracy} = \frac{TP + TN}{N}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (11.1.1)$$

准确率衡量整体正确比例, 精确率回答预测前 500 中有多少正确, 召回率回答实际前 500 找到多少。F1 分数 (F1 Score) 是精确率和召回率的调和平均:

$$F1 = \frac{2 \text{Precision Recall}}{\text{Precision} + \text{Recall}}. \quad (11.1.2)$$

代码约定分母为零时返回 0。主实验阈值预先固定为 0.5; 降低阈值一般增加召回, 也可能增加误报。在学校信息筛查中, 漏掉目标学校与把非目标纳入待核查名单的代价不同, 本实验不虚构实际业务代价。验证表比较 0.3、0.5、0.7, 只用于解释权衡。

11.2 不要只看单一准确率

约三分之二样本为负类, 全部预测负类就有约 66.6% 的测试准确率, 因此同时报告多数类基线、混淆矩阵、精确率、召回率与 F1。验证损失选择参数及轮次, 冻结后测试一次; 不反复换种子、字段或阈值挑高分。

11.3 当前模型在完整 workflow 中的位置

任务与可用时点 → 来源核对 → 划分 → 训练拟合预处理 → 概率模型与目标 → 优化 → 验证选择 → 冻结测试 → 后续监测。若未来改成跨年预测, 要用早期信息预测后续标签, 并按时间评估; 不能把同一学校多年的记录随机混入三份数据, 便声称能泛化到新学校。

当前只覆盖榜单中学校, 排名规则及缺失模式会变化; 原数据来自第三方公开镜像, 保留出处与原文件, 但未逐校核验。输出是模型概率, 并不自动保证校准。特征权重表示条件关联, 不证明地区或办学性质导致排名变化。

12 自测、符号索引与资料

12.1 课堂追问的预期答案

1. C0: 0.7 是概率; 阈值 0.5 时预测 1, 阈值 0.8 时预测 0。原行号与排序相关, 不能输入。
2. C1: 不填补标签。数值 0 保留, 横线或无效文本转为缺失。
3. C2: 训练均值 2、标准差约 0.816497; 验证不能改变它们。未知类别归 Unknown, 列数不变。
4. C3: 902 条、每批 64, 得到 15 批, 最后 6 条; 5 条、每批 2, 得到 2, 2, 1。
5. C4: 输入 (1, 3, 2)、参数 (1, 2, -1), 得分 5, 概率约 0.993307。
6. C5: 零得分的平均交叉熵为 $\log 2 \approx 0.693147$; 不要重复 sigmoid。
7. C6: 首次更新为 $(0, 0.1, -0.1)^\top$; 删除清梯度会让第二次更新偏离手算。
8. C7: 小例子四种计数各 1, 准确率、精确率、召回率和 F1 均为 0.5; 阈值降为 0.3 后召回率为 1, 但仍有一个误报。

退出卡: 写出“类别表为什么只能在训练上拟合”与“为什么不能只按准确率选模型”的各一句解释。下次实验可继续研究优化算法、学习率与收敛。

12.2 按角色索引记号

类别	符号及含义	首次解释
数据	$N, x_j^{(n)}$: 样本数与第 n 个样本的第 j 个数值	3.1
预处理	$\mu_j, s_j, \bar{x}_j^{(n)}, u_j^{(n)}$: 均值、尺度、填补值、标准化值	3.1
表示	$\mathbf{x}^{(n)}, \tilde{\mathbf{x}}^{(n)}, \mathbf{X}, \mathbf{y}, d, \top$: 向量、增广、矩阵、标签、维数、转置	4.2
模型	$\theta, z, p, \sigma, \tau, \hat{y}, \mathbf{1}$: 参数、得分、概率、函数、阈值、预测、指示	6.1
概率	$P, , \text{logit}, \log, \Lambda, \prod$: 概率、条件、对数几率、对数、似然、连乘	6–7
目标与优化	$\mathcal{L}, R, J, \Omega, \lambda, \nabla, \partial, \eta, [t], B$: 损失、风险、目标、惩罚、系数、梯度、偏导、步长、迭代、批量	5、7–9

12.3 实际使用资料与改编边界

- 项目上级目录《人工智能数学原理与算法：实验指导书（最终）.pdf》第 1 章，书内第 1–13 页：沿用数据准备、PyTorch 逻辑回归、正则化与评价主线；本实验采用大学排名数据，并增加独热编码和特征选择对照。
- 仓库 `source/slides/` 下的《2.5 逻辑回归 _v2.pdf》：沿用得分、概率、最大似然与梯度顺序；本实验统一采用 0/1 标签与增广截距。
- 仓库教案目录中的《人工智能数学原理与算法 _12 次课程与助教分工 _ 最终版.xlsx》：第三次实验衔接；本材料建议 135 分钟，不替代课程具体日期安排。
- 同级实验 01 的实验手册与报告模板：提交方式；实验 02 的代码：分阶段补全与小例子风格。
- 本次原表 `code/data/qs2026_raw.csv` 与 `code/data/classroom/split_manifest.json`：固定来源、原行号、划分与真实缺失。镜像地址见数据说明。
- [QS 官方学校分类说明](#)：规模、学科覆盖及研究活跃程度；[QS 排名方法说明](#)：指标与排名构造。核对日期为 2026-10-08。

第三方镜像中的某些低排名段以区间起点表示，不能用于精确排名回归。本实验只使用能确定的前 500 标签，课堂文件没有跨越 500 的模糊标签。参考运行只说明这份划分上的表现，不能挪用教材或其他数据集的准确率。