

人工智能数学原理与算法 B

## 第三次实验

### 逻辑回归与大学排名分类

课程前置讲义

主讲 胡泷

整理 胡泷、曾有成

任课教师 钟志诚

单位 中国科学技术大学  
人工智能与数据科学学院

#### 从数据到可解释的分类流程

数据清洗与划分 → 数值表示 → 线性得分与概率 → 交叉熵与正则化 → 梯度更新 → 独立评估。

2026 年秋季 建议 3 学时 (135 分钟)

C0-C7 分阶段完成；日期与提交平台以课程通知为准。

随包数据为 QS (Quacquarelli Symonds) 2026 排名的教学整理版。

## 目录

|                   |    |
|-------------------|----|
| 1 任务、边界与数据来源      | 1  |
| 2 从原表选择可用字段       | 2  |
| 3 数值填补、标准化与数据划分   | 3  |
| 4 类别编码与增广设计矩阵     | 4  |
| 5 批次、数据集与训练顺序     | 5  |
| 6 线性得分、概率和类别      | 6  |
| 7 从伯努利似然到交叉熵      | 7  |
| 8 从损失到一次参数更新      | 8  |
| 9 正则化与训练循环        | 9  |
| 10 正则化之外：有边界的特征选择 | 10 |
| 11 评价、泛化与实验解释     | 11 |
| 12 自测、符号索引与资料     | 12 |

# 1 任务、边界与数据来源

## 1.1 从属性判断走向概率模型

上次实验通过属性问题构造决策树。本次使用一组可训练权重，将混合类型的大学数据转换成概率。逻辑回归（《机器学习》称对数几率回归）虽然含“回归”，这里解决的仍是二分类。

贯穿任务：给定学校的地区、办学性质、规模等信息，以及三个已公布的指标分数，识别它是否位于 **2026 年 QS (Quacquarelli Symonds) 榜单前 500 名**。标签 **top500=1** 表示属于前 500 名，0 表示榜单中其余学校。并列名次按所列名次判断，所以正类有 502 所；不把“第 500 行”作为截断位置。

### 这是什么任务

这是同年榜单内的分类练习，使用的数值分数也是该年已公布信息。它不是预测未来排名，不是给全球所有大学判定优劣，也不说明模型学到了学校发展的因果规律。

## 1.2 学习目标与先修知识

能识别标签泄漏；能只用训练集拟合填充值、尺度和类别表；能手算独热编码、概率、交叉熵及一次更新；能实现 PyTorch 模型并用验证集选择方案。已具备变量、循环、函数、字典、类、数组切片和矩阵乘法基础。先以 C0 复习形状，再学习新的编码步骤。

## 1.3 课堂版本的规模与来源

原镜像为 1504 行、30 列，来自公开的 QS 2026 数据整理仓库，保存原文件和摘要。只选三个数值字段与五个类别字段；保留原行号和学校名用于追溯，二者不能输入模型。保留真实缺失，不人为制造缺失，不平衡抽样。

种子 20261008，按标签分层约 60%/20%/20%：训练 902 条（正类 301）、验证 300 条（正类 100）、测试 302 条（正类 101）。学校名在源表中不重复，三份学校互斥。课堂目录为 **code/data/classroom/**。原教材贷款案例及其 65.5% 准确率示例不适用于本次数据。

### C0：先说清任务

预测概率为 0.7，标签是否就是 0.7？阈值 0.5 时输出哪一类？若使用 **row\_id**，为何也可能泄漏答案？

## 2 从原表选择可用字段

### 2.1 字段白名单与数值含义

CSV（Comma-Separated Values，逗号分隔值）文件每行是一所学校，每列是一个字段。程序只从白名单取输入，不对整张表直接转换成张量。

| 课堂字段                        | 角色与处理              |
|-----------------------------|--------------------|
| faculty_student_score       | 师生比指标分数，不是原始人数比    |
| international_faculty_score | 国际教师指标分数，不是百分比     |
| international_student_score | 国际学生指标分数，不是百分比     |
| region, status              | 地区与办学性质，无大小顺序      |
| size                        | S、M、L、XL，学校规模档位    |
| focus                       | SP、FO、CO、FC，学科覆盖类型 |
| research                    | LO、MD、HI、VH，研究活跃程度 |
| row_id, name                | 原表行号与名称，只用于追溯      |
| top500                      | 0/1 标签，不填补、不标准化    |

学校规模虽然有序，档位间隔却不等于相同人数；本次五个类别字段统一采用独热编码。字母排序只决定输出列顺序，不代表大小关系。

### 2.2 筛选不是追求更高的测试分数

当年排名和总分直接暴露目标；上一年排名虽可能是合法的历史预测变量，本次也预先排除，以集中练习混合字段。学校名称不作记忆键；原行号来自按排名排列的表，也必须排除。完整评分向量能近似重构排名规则，本实验只保留三个分数，但它们仍与榜单构造有关。

不能把数值化等同于可用

给学校名编码成 1、2、3，或者把排名填补后当输入，都可能让程序跑通，却不符合任务。原镜像部分名次是区间，不能把区间起点当精确排名；本次阈值 500 不被现有区间跨越。

C1：缺失是什么

数值列中的空白、横线、无法解析文本转为缺失；数值 0 不是缺失。若标签缺失，能否把它填成多数类？给出理由。

### 3 数值填补、标准化与数据划分

#### 3.1 只从训练集估计统计量

训练集用于学习预处理和权重, 验证集用于选择方案, 测试集只在冻结后评价。令  $N$  为训练样本数,  $x_j^{(n)}$  表示第  $n$  个样本的第  $j$  个数值特征。括号上标  $(n)$  是样本编号, 不是幂; 下标  $j$  是特征编号。

每个数值字段先对非缺失训练值求均值  $\mu_j$ , 用它填补该列。令填补值为  $\bar{x}_j^{(n)}$ ; 波浪号保留给后面的增广向量, 不在此处混用。填补后计算总体标准差  $s_j$ , 再转换为标准化值  $u_j^{(n)}$ :

$$s_j = \sqrt{\frac{1}{N} \sum_{n=1}^N (\bar{x}_j^{(n)} - \mu_j)^2}, \quad u_j^{(n)} = \frac{\bar{x}_j^{(n)} - \mu_j}{s_j}. \quad (3.1.1)$$

$\sum$  表示求和, 平方根将尺度还原到原单位。代码用 `std(ddof=0)`, 不除以  $N-1$ 。尺度为零时替换为 1; 全空训练列均值约定为 0。验证、测试复用训练均值与尺度, 不能重新拟合。

#### C2: 可复核的小例子

训练值为  $[1, 3, \text{缺失}]$ , 均值 2, 填补后为  $[1, 3, 2]$ ; 总体标准差  $\sqrt{2/3} \approx 0.816497$ , 标准化后约为  $[-1.224745, 1.224745, 0]$ 。验证值 100 转成约 120.025, 而不是影响训练均值; 验证缺失转成 0。

#### 3.2 真实缺失与适用边界

训练表的办学性质缺失 31 条、国际教师分数缺失 49 条、国际学生分数缺失 18 条。数值缺失用训练均值处理; 类别缺失在下一节编码为 Unknown。缺失机制未被确认, 不能声称它完全随机, 也不能把缺失分数解释为该校真实得分为零。

#### C2: 检查是否泄漏

把验证集某个数值改成一百万, 训练均值与训练张量应不应该改变? 若先在全数据上填补再划分, 会出现什么问题?

## 4 类别编码与增广设计矩阵

### 4.1 独热编码由训练类别表确定

独热编码 (one-hot encoding) 用一列指示一个类别。对地区字段, 若训练表观察到 Asia、Europe, 则固定列序为 Asia、Europe、Unknown; Unknown 接收缺失和验证/测试中训练未见的类别。

| 原始取值   | Asia | Europe | Unknown |
|--------|------|--------|---------|
| Asia   | 1    | 0      | 0       |
| Europe | 0    | 1      | 0       |
| 缺失     | 0    | 0      | 1       |
| 训练未见类别 | 0    | 0      | 1       |

类别表只从训练集拟合; 验证与测试必须使用相同列顺序, 不能各自生成自己的编码列。Unknown 即使未在训练中出现也预留一列, 其权重可能始终为零; 这不意味着模型学会了未知类别的特殊规律。

本次保留完整独热列, 方便直观看到每个类别; 独热列保持 0/1, **不再标准化**。完整独热列与截距存在冗余, 未正则化参数不一定可唯一解释, 但仍可计算预测。删去每组一个参考列是另一种约定, 本次不混用。

### 4.2 拼接并在首列增加常数

先放三个标准化数值, 再按 region、status、size、focus、research 顺序放独热列。每个字段内取训练类别的字母排序, 再加 Unknown。当前共  $d = 28$  个特征: 3 个数值与 25 个独热列。

令  $\mathbf{x}^{(n)} \in \mathbb{R}^d$  为处理后的样本列向量, 粗体表示向量; 转置  $\top$  将列变成行。波浪号表示增加常数项, 以统一处理截距:

$$\tilde{\mathbf{x}}^{(n)} = (1, (\mathbf{x}^{(n)})^\top)^\top, \quad \mathbf{X} = \begin{bmatrix} (\tilde{\mathbf{x}}^{(1)})^\top \\ \vdots \\ (\tilde{\mathbf{x}}^{(N)})^\top \end{bmatrix} \in \mathbb{R}^{N \times (d+1)}. \quad (4.2.1)$$

标签列为  $\mathbf{y} \in \mathbb{R}^{N \times 1}$ , 元素取 0 或 1。训练张量形状为 (902, 29), 标签为 (902, 1); 验证为 (300, 29) 与 (300, 1)。只标准化数值列, 不标准化标签或新增常数列。

#### C2: 编码自查

为何不能把 Asia、Europe、Americas 编为 1、2、3 后直接输入? 为何测试集中首次出现的类别不能添加新列?

## 5 批次、数据集与训练顺序

### 5.1 Dataset 与 DataLoader 各做什么

Dataset 保存特征与标签, `__getitem__` 按同一索引取一对样本。DataLoader 负责组成批次, 并且只在训练时打乱。标签与特征不能分别打乱。

```
dataset = student.UniversityDataset(X, y)
loader = student.make_loader(dataset, 64, True)
for X_batch, y_batch in loader:
    print(X_batch.shape, y_batch.shape)
```

一轮 (epoch) 遍历训练数据一次。训练集有 902 条, 批量大小 64, 因此有 14 个满批和最后 6 条, 共 15 个批次。一个批次大小记为  $B$ , 输入形状  $(B, 29)$ , 标签形状  $(B, 1)$ 。不足批量的最后一批不丢弃。

### 5.2 从一个小例子进入补全

先用 5 条样本、批量大小 2、顺序取样, 观察批量大小为 2, 2, 1; 再开启训练打乱, 核对特征标签始终配对。参考实现优先使用显式循环和普通 `import`, 不需要理解复杂配置系统。

#### 代码阅读节奏

C0 观察张量形状; C1 清洗数值与标签; C2 数值处理和独热编码; C3 成对取批; C4 输出线性得分; C5 构造目标; C6 自动求导与更新; C7 解释验证和测试结果。每一步先预测小例子的输出, 再补函数、运行和解释。

#### C3: 为什么保留末批

如果丢弃最后 6 条, 是否每轮都训练了所有学校? 批次大小变化时, 为什么平均损失仍应除以本批实际样本数?

## 6 线性得分、概率和类别

### 6.1 三个不同的输出

参数  $\theta = (\theta_0, \dots, \theta_d)^\top \in \mathbb{R}^{d+1}$ , 其中  $\theta_0$  是截距; 代码保存为 **(d+1, 1)**。线性得分  $z^{(n)}$  可以取任意实数。sigmoid 函数  $\sigma: \mathbb{R} \rightarrow (0, 1)$  将得分变成概率:

$$z^{(n)} = (\tilde{\mathbf{x}}^{(n)})^\top \theta, \quad p^{(n)} = P(y^{(n)} = 1 \mid \mathbf{x}^{(n)}; \theta) = \sigma(z^{(n)}) = \frac{1}{1 + e^{-z^{(n)}}}. \quad (6.1.1)$$

$P$  表示概率, 条件竖线 “|” 表示给定特征; 分号后的参数确定当前模型。 $e$  是自然指数的底。 $p^{(n)}$  是模型概率, 不是已观察到的标签。

$$\hat{y}^{(n)} = \mathbf{1}[p^{(n)} \geq \tau], \quad \tau \in (0, 1). \quad (6.1.2)$$

帽号在这里表示**预测类别**。 $\tau$  是决策阈值; 指示函数  $\mathbf{1}[\cdot]$  在括号内条件成立时为 1, 否则为 0。本课预先固定主实验阈值为 0.5, 恰好等于阈值也判为前 500 名。

### 6.2 为什么叫对数几率回归

几率是属于与不属于前 500 名的概率之比  $p/(1-p)$ ; 对数几率函数  $\text{logit}: (0, 1) \rightarrow \mathbb{R}$  是 sigmoid 的反函数:

$$\text{logit}(p) = \log \frac{p}{1-p} = z. \quad (6.2.1)$$

$\log$  表示自然对数。本模型假设**对数几率是处理后特征的线性函数**。sigmoid 和 logit 不能互称。阈值为 0.5 时, 边界为  $z = 0$ ; 提高阈值时, 边界得分变为  $\log(\tau/(1-\tau))$ 。

|                     |          |     |          |
|---------------------|----------|-----|----------|
| 得分 $z$              | -2       | 0   | 2        |
| 概率 $p$              | 0.119203 | 0.5 | 0.880797 |
| 类别 ( $\tau = 0.5$ ) | 0        | 1   | 1        |

#### 检查点 C4: 模型接口

若参数是  $(1, 2, -1)^\top$ , 增广输入是  $(1, 3, 2)^\top$ , **forward** 应返回什么? **sigmoid(forward(X))** 又是什么?

## 7 从伯努利似然到交叉熵

### 7.1 为什么采用这个损失

给定特征，一个二分类标签服从伯努利模型：只可能取 0 或 1，取 1 的概率为  $p^{(n)}$ 。单条观测标签的概率质量为

$$P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}) = (p^{(n)})^{y^{(n)}} (1 - p^{(n)})^{1-y^{(n)}}. \quad (7.1.1)$$

若  $y^{(n)} = 1$ ，式子只留下  $p^{(n)}$ ；若标签为 0，只留下  $1 - p^{(n)}$ 。假定样本在给定参数后条件独立，整批数据的似然  $\Lambda$  是这些概率的连乘； $\prod$  表示逐项相乘：

$$\Lambda(\boldsymbol{\theta}) = \prod_{n=1}^N P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}). \quad (7.1.2)$$

最大似然选择让已观察数据更可能出现的参数。取对数将连乘变成求和；加负号将最大化改成最小化；除以  $N$  得到与样本规模无关的平均损失。

$$\begin{aligned} \mathcal{L}^{(n)} &= -y^{(n)} \log p^{(n)} - (1 - y^{(n)}) \log(1 - p^{(n)}), \\ R(\boldsymbol{\theta}) &= \frac{1}{N} \sum_{n=1}^N \mathcal{L}^{(n)} = -\frac{1}{N} \log \Lambda(\boldsymbol{\theta}). \end{aligned} \quad (7.1.3)$$

$\mathcal{L}^{(n)}$  是单样本损失， $R$  是经验风险（样本平均）。该损失称二元交叉熵，简称 BCE (Binary Cross-Entropy)。当真实标签为 1 时，预测 0.9 的损失约为 0.10536，预测 0.1 的损失约为 2.30259，错误且自信会受到更大惩罚。

### 7.2 让计算接口与公式一致

实际训练用 `BCEWithLogitsLoss`：它接收原始得分并在内部稳定计算 sigmoid 与交叉熵的组合。单样本等价式为

$$\mathcal{L}(z, y) = \max(z, 0) - yz + \log(1 + e^{-|z|}). \quad (7.2.1)$$

$\max(z, 0)$  取较大值， $|z|$  是绝对值；此式避免直接计算过大的指数。`BCELoss` 接收概率，`BCEWithLogitsLoss` 接收得分，不能把两种接口混用。

#### 检查点 C5

所有得分为 0 时，平均数据损失是多少？为什么不能先 sigmoid 再传给 `BCEWithLogitsLoss`？

## 8 从损失到一次参数更新

### 8.1 梯度给出每个参数的变化方向

梯度  $\nabla_{\theta} R$  是  $R$  对每个参数的偏导数组成的列向量；在当前位置，小幅沿负梯度移动会使损失一阶近似下降。先对单样本逐步求导：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial p} &= -\frac{y}{p} + \frac{1-y}{1-p}, & \frac{\partial p}{\partial z} &= p(1-p), \\ \frac{\partial \mathcal{L}}{\partial z} &= \frac{\partial \mathcal{L}}{\partial p} \frac{\partial p}{\partial z} = p - y.\end{aligned}\quad (8.1.1)$$

$\partial$  表示把其他变量暂时固定的偏导；链式法则把前两项相乘，约去分母，得到  $p - y$ 。又因  $z = \tilde{\mathbf{x}}^{\top} \boldsymbol{\theta}$ ，有

$$\nabla_{\theta} R = \frac{1}{N} \mathbf{X}^{\top} (\mathbf{p} - \mathbf{y}), \quad \boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \eta \nabla_{\theta} R. \quad (8.1.2)$$

$\mathbf{p}, \mathbf{y} \in \mathbb{R}^{N \times 1}$ ； $\mathbf{X}^{\top} \in \mathbb{R}^{(d+1) \times N}$ ，梯度形状为  $(d+1) \times 1$ 。 $\eta > 0$  是学习率；方括号上标  $[t]$  表示迭代次数，与样本编号  $(n)$  区分。

### 8.2 贯穿手算：两所假设学校的更新

为便于手算，仅保留“标准化师生比分数、标准化国际学生分数”两个坐标。下表**专为课堂构造**，不是教材记录，也不是随包数据的抽样；标准化坐标 0 表示处于训练均值。

| 当前样本 $n$ | 师生比分数坐标 | 国际学生分数坐标 | 标签 $y^{(n)}$ |
|----------|---------|----------|--------------|
| 1        | 1       | 0        | 1            |
| 2        | 0       | 1        | 0            |

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}, \quad \boldsymbol{\theta}^{[0]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{p} = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix}, \quad \nabla R = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -0.5 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0 \\ -0.25 \\ 0.25 \end{bmatrix}. \quad (8.2.1)$$

取  $\eta = 0.4$ ，更新后参数为  $(0, 0.1, -0.1)^{\top}$ ，两条概率分别为 0.524979 和 0.475021。平均损失从 0.693147 降至 0.644397。

#### 检查点 C6: 核对方向

第一个分数权重变大、第二个分数权重变小，为何能让这两条已知标签更可能？请用代码输出 `theta.grad` 与更新后的 `theta` 核对，不能只看损失是否下降。

## 9 正则化与训练循环

### 9.1 区分拟合损失和训练总目标

训练集拟合得好不保证新样本表现好。参数过大可能把样本噪声也拟合进去。用  $\Omega$  表示权重惩罚,  $\lambda \geq 0$  控制其强度, 训练总目标  $J$  为

$$J(\theta) = R(\theta) + \lambda \Omega(\theta),$$

$$\Omega_{L1}(\theta) = \sum_{j=1}^d |\theta_j|, \quad \Omega_{L2}(\theta) = \frac{1}{2} \sum_{j=1}^d \theta_j^2. \quad (9.1.1)$$

L1 (L1 Norm, 一范数) 是绝对值之和; 本实验的 L2 (L2 Norm, 二范数) 惩罚采用二范数平方的一半, 并非二范数本身。这里不惩罚截距  $\theta_0$ 。若参数为  $(10, 3, -4)^\top$ , 两种惩罚分别为 7 和 12.5。

L2 惩罚的梯度是  $(0, \theta_1, \dots, \theta_d)^\top$ 。L1 在非零坐标用符号函数求导, 零点不唯一; PyTorch 在该处取 0。普通梯度更新下不保证权重恰好为零, 不能把 L1 等同于本程序一定自动删除特征。

### 9.2 一批数据如何执行更新

本实验用小批量随机梯度下降 SGD (Stochastic Gradient Descent) 更新参数。对当前批次, 把上一节梯度式中的  $N$  换成当前批次大小  $B$ 。torch.optim.SGD 已提供参数更新规则, 学生连接五个步骤:

```
optimizer.zero_grad()
logits = model(X_batch)
loss = data_loss(logits, y_batch)
objective = loss + strength * model.penalty(kind)
objective.backward()
optimizer.step()
```

backward() 用自动微分得到每个参数的梯度; step() 更新参数。梯度默认会累加, 所以每批先清零。损失在反向传播前不能用 item() 转成普通数, 也不能 detach() 切断计算图。

#### 曲线必须比较同一种量

不同  $\lambda$  的训练总目标不能直接拿来选模型。本实验每轮结束, 用当前同一组参数分别计算全训练集与验证集的**无正则数据损失**, 画出两条曲线; 模型选择也看验证数据损失。

#### 检查点 C5/C6

把 zero\_grad() 删除, 第二次更新仍与手算一致吗? 若  $\lambda$  极大, 可能发生什么?

## 10 正则化之外：有边界的特征选择

### 10.1 必要排除与验证选择不是一回事

建模前删除排名、总分、名称和行号，是按照任务排除泄漏和标识字段。特征选择则是在**允许使用的字段**中比较完整与精简表示；这里称特征选择，避免与决策树剪枝混淆。

主实验完整组为三个数值字段与五个类别字段。选做精简组删除 focus 与 research，保留三个数值与 region、status、size；编码后由 28 维变为 18 维。提前规定对照，固定同一划分、学习率、训练种子、最大轮数和 L2 系数 0.01，只改变字段组。

#### 对照必须回答的问题

删除两个字段后，验证损失、召回率和特征维数怎样变化？若精简组更差，说明这些字段在当前划分中提供了信息；不应继续查看测试集并逐列试删直到得到高分。

### 10.2 正则化不等于保证提高分数

L2 通常缩小权重，L1 鼓励稀疏，但本程序用普通小批量梯度下降，L1 不保证权重精确为零。一个独热类别权重很小，也不等于整个原始字段无用；相关字段还可能分摊作用。不能用任意权重阈值直接宣布完成“自动剪枝”。

主实验的三种正则化方案只比较验证**数据损失**，不比较包含不同惩罚项的总目标；无正则也可能最好。所有方案在第 60 轮表现最好，也不证明已经达到全局数值最优，可能需要更多训练；本次不据测试结果延长训练。

### 10.3 选做与主实验如何衔接

命令 `python run_lab.py --feature-study` 只读取训练和验证表，不覆盖主实验冻结模型。报告中将它单独列为拓展分析，不对两个特征组分别反复测试。若另行设计将特征组也纳入选模，必须在查看测试结果前规定联合选择规则。

#### C7 选做

精简组维数更少但验证损失更大，可以为了“更简单”选它吗？可以讨论性能与复杂度的取舍，但必须如实报告损失，不应声称它在所有方面更好。

## 11 评价、泛化与实验解释

### 11.1 从四种计数到评价指标

以前 500 名为正类。TP (True Positive, 真正例) 是真实正类且预测正类; FP (False Positive, 假正例) 是误报; FN (False Negative, 假负例) 是漏判; TN (True Negative, 真负例) 是真实负类且预测负类。

$$\text{Accuracy} = \frac{TP + TN}{N}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (11.1.1)$$

准确率衡量整体正确比例, 精确率回答预测前 500 中有多少正确, 召回率回答实际前 500 找到多少。F1 分数 (F1 Score) 是精确率和召回率的调和平均:

$$F1 = \frac{2 \text{Precision Recall}}{\text{Precision} + \text{Recall}}. \quad (11.1.2)$$

代码约定分母为零时返回 0。主实验阈值预先固定为 0.5; 降低阈值一般增加召回, 也可能增加误报。在学校信息筛查中, 漏掉目标学校与把非目标纳入待核查名单的代价不同, 本实验不虚构实际业务代价。验证表比较 0.3、0.5、0.7, 只用于解释权衡。

### 11.2 不要只看单一准确率

约三分之二样本为负类, 全部预测负类就有约 66.6% 的测试准确率, 因此同时报告多数类基线、混淆矩阵、精确率、召回率与 F1。验证损失选择参数及轮次, 冻结后测试一次; 不反复换种子、字段或阈值挑高分。

### 11.3 当前模型在完整 workflow 中的位置

任务与可用时点 → 来源核对 → 划分 → 训练拟合预处理 → 概率模型与目标 → 优化 → 验证选择 → 冻结测试 → 后续监测。若未来改成跨年预测, 要用早期信息预测后续标签, 并按时间评估; 不能把同一学校多年的记录随机混入三份数据, 便声称能泛化到新学校。

当前只覆盖榜单中学校, 排名规则及缺失模式会变化; 原数据来自第三方公开镜像, 保留出处与原文件, 但未逐校核验。输出是模型概率, 并不自动保证校准。特征权重表示条件关联, 不证明地区或办学性质导致排名变化。

## 12 自测、符号索引与资料

### 12.1 课堂追问的预期答案

1. C0: 0.7 是概率; 阈值 0.5 时预测 1, 阈值 0.8 时预测 0。原行号与排序相关, 不能输入。
2. C1: 不填补标签。数值 0 保留, 横线或无效文本转为缺失。
3. C2: 训练均值 2、标准差约 0.816497; 验证不能改变它们。未知类别归 Unknown, 列数不变。
4. C3: 902 条、每批 64, 得到 15 批, 最后 6 条; 5 条、每批 2, 得到 2, 2, 1。
5. C4: 输入 (1, 3, 2)、参数 (1, 2, -1), 得分 5, 概率约 0.993307。
6. C5: 零得分的平均交叉熵为  $\log 2 \approx 0.693147$ ; 不要重复 sigmoid。
7. C6: 首次更新为  $(0, 0.1, -0.1)^\top$ ; 删除清梯度会让第二次更新偏离手算。
8. C7: 小例子四种计数各 1, 准确率、精确率、召回率和 F1 均为 0.5; 阈值降为 0.3 后召回率为 1, 但仍有一个误报。

退出卡: 写出“类别表为什么只能在训练上拟合”与“为什么不能只按准确率选模型”的各一句解释。下次实验可继续研究优化算法、学习率与收敛。

### 12.2 按角色索引记号

| 类别    | 符号及含义                                                                                                | 首次解释  |
|-------|------------------------------------------------------------------------------------------------------|-------|
| 数据    | $N, x_j^{(n)}$ : 样本数与第 $n$ 个样本的第 $j$ 个数值                                                             | 3.1   |
| 预处理   | $\mu_j, s_j, \bar{x}_j^{(n)}, u_j^{(n)}$ : 均值、尺度、填补值、标准化值                                            | 3.1   |
| 表示    | $\mathbf{x}^{(n)}, \tilde{\mathbf{x}}^{(n)}, \mathbf{X}, \mathbf{y}, d, \top$ : 向量、增广、矩阵、标签、维数、转置    | 4.2   |
| 模型    | $\theta, z, p, \sigma, \tau, \hat{y}, \mathbf{1}$ : 参数、得分、概率、函数、阈值、预测、指示                             | 6.1   |
| 概率    | $P,  , \text{logit}, \log, \Lambda, \prod$ : 概率、条件、对数几率、对数、似然、连乘                                     | 6–7   |
| 目标与优化 | $\mathcal{L}, R, J, \Omega, \lambda, \nabla, \partial, \eta, [t], B$ : 损失、风险、目标、惩罚、系数、梯度、偏导、步长、迭代、批量 | 5、7–9 |

### 12.3 实际使用资料与改编边界

- 项目上级目录《人工智能数学原理与算法：实验指导书（最终）.pdf》第 1 章，书内第 1–13 页：保留数据准备、PyTorch 逻辑回归、正则化与评价主线；贷款案例改为大学排名，增加独热编码和特征选择对照。
- 仓库 `source/slides/` 下的《2.5 逻辑回归 \_v2.pdf》：沿用得分、概率、最大似然与梯度顺序；本实验统一采用 0/1 标签与增广截距。
- 仓库教案目录中的《人工智能数学原理与算法 \_12 次课程与助教分工 \_ 最终版.xlsx》：第三次实验衔接；本材料建议 135 分钟，不替代课程具体日期安排。
- 同级实验 01 的实验手册与报告模板：提交方式；实验 02 的代码：分阶段补全与小例子风格。
- 本次原表 `code/data/qs2026_raw.csv` 与 `code/data/classroom/split_manifest.json`：固定来源、原行号、划分与真实缺失。镜像地址见数据说明。
- [QS 官方学校分类说明](#)：规模、学科覆盖及研究活跃程度；[QS 排名方法说明](#)：指标与排名构造。核对日期为 2026-10-08。

第三方镜像中的某些低排名段以区间起点表示，不能用于精确排名回归。本实验只使用能确定的前 500 标签，课堂文件没有跨越 500 的模糊标签。参考运行只说明这份划分上的表现，不能挪用教材、旧贷款实验或其他数据集的准确率。