

人工智能数学原理与算法 B

第三次实验

逻辑回归与贷款违约预测

课程前置讲义

主讲 钟志诚

整理 曾有成

单位 中国科学技术大学

人工智能与数据科学学院

从数据到可解释的分类流程

数据清洗与划分 → 数值表示 → 线性得分与概率 → 交叉熵与正则化 → 梯度更新 → 独立评估。

2026 年秋季 建议 3 学时 (135 分钟)

C0-C7 分阶段完成；日期与提交平台以课程通知为准。

随包数据为天池真实贷款记录的固定课堂子集。

目录

1 本次实验要解决什么问题	1
2 先把表格变成可靠的输入	2
3 标准化、增广特征与张量	3
4 从一条样本到一批样本	4
5 线性得分、概率和类别	5
6 从伯努利似然到交叉熵	6
7 从损失到一次参数更新	7
8 正则化与训练循环	8
9 评价与真实 workflow	9
10 自测答案、符号索引与资料	10

1 本次实验要解决什么问题

1.1 从决策树走向概率模型

上次实验用一串属性问题构造决策树。本次仍做二分类，但改用一组可训练的权重：给定贷款申请时已知的信息，估计这笔贷款违约的概率。逻辑回归（《机器学习》称对数几率回归）虽然名字含“回归”，本次输出的任务标签仍是离散类别。

训练数据中的标签 `isDefault` 取 1 表示违约，取 0 表示未违约。高概率表示模型认为违约更可能；是否采取某种业务行动还取决于误判代价。本实验只学习分类流程，不构造实际授信决策系统。

学习目标

能把混合类型表格转换为不泄漏信息的模型输入；能解释得分、概率、类别的区别；能从伯努利似然得到二元交叉熵；能手算一次更新并补全 PyTorch 模型；能用验证集选方案，用测试集报告最终结果。

1.2 先修知识与本次边界

已会变量、列表、循环、函数、类、`import` 和数组切片。数学上用到矩阵乘法、指数、自然对数和简单求导。前两次实验入口保持不变，本次先用 C0 复习张量形状，再逐步增加新概念。

本次依据指定实验指导书第 1 章第 1-13 页，保留 `pandas`、`Dataset`、`DataLoader`、逻辑回归和正则化；补充一次梯度更新以解释训练循环。下一实验可深入比较优化算法，这里不扩展到动量等方法。

1.3 教材数据与随包数据必须区分

教材描述 10000 条记录、8000/1000/1000 的划分及 50% 训练正类比例。本次从用户下载的天池 80 万条带标签训练数据中，按标签分层重新抽取 8000/1000/1000 条；这不是教材原有抽样。源表 47 列含编号与标签，不等于 47 个模型输入，本实验只选八个字段。

原划分种子为 20261008，训练平衡种子为 20261009；按指导书令训练正负各 4000 条，验证与测试保持原样，各含 200 条正类。三份均无缺失标签，输入仍有缺失值。默认读 `code/data/classroom/`。竞赛 `testA.csv` 无标签，`sample_submit.csv` 中的 0.5 只是提交示例，均不能用于本地评分。教材示例准确率不作为验收标准。

检查点 C0：先说清输出

模型输出 0.7，是否意味着“标签是 0.7”？阈值设为 0.5 时输出哪一类？若改为 0.8 呢？先口答，再做第 10 节的自测。

2 先把表格变成可靠的输入

2.1 字段、标签与可用时刻

CSV（Comma-Separated Values，逗号分隔值）文件的每行是一条样本，每列是一种属性。本实验固定使用下表顺序；编号和标签不作为输入。金额与收入保留原数值，未核实币种，不称人民币元。利率用百分数值；债务收入比 **dti** 保留原尺度，不假设位于 0 到 1 之间。

字段	处理方式及含义
loanAmnt、annualIncome	贷款金额、年收入，保留为数值
interestRate、dti	利率、债务收入比，保留源数值
grade	A 至 G 编码为 1 至 7；引入有序等距假设
employmentLength	按教材映射为等级编码，不等于真实年数
issueDate	距训练集最早发放日期的天数
earliesCreditLine	距训练集最早信用月份的月数；沿用原拼写
id、subGrade	不作为特征；细分等级在本教学版本中省略
isDefault	标签，单独保存，绝不填充或标准化

2.2 先划分，再估计预处理规则

训练集用来估计填充值、尺度、日期原点和模型权重；验证集用来选择正则化方案、轮数等设置；测试集只在方案冻结后用于最终评价。已经划分好的三个文件不合并重切。

先删除标签缺失的行，再从**训练特征**计算统计量。验证集和测试集缺失标签的行同样只能排除出有监督评价，并报告样本数；不能猜测标签。

看似无监督的统计量也可能泄漏

把三份表合起来算均值会让预处理知道测试分布。对三份表各算日期原点，则会让同一日历日期对应不同数字。这里保存训练原点、均值和标准差，随后一律复用。

检查点 C1：编码不是测量值

< 1 year、1 year、3 years、10+ years 应得到 1、2、4、12。为什么不能把最后的 12 解释为真实工作 12 年？

3 标准化、增广特征与张量

3.1 为什么先调整尺度

金额可能是数万, 等级编码只有 1 至 7。不同尺度使同一个学习率很难同时适合每个坐标, 也使正则化对权重的比较失去统一尺度。用训练列均值填补缺失值, 再对数值列标准化。

令 $r_j^{(n)}$ 为编码后的原始数值, 第 j 个特征的训练非缺失均值为 μ_j ; $\bar{r}_j^{(n)}$ 表示用 μ_j 填补后的值。训练集大小为 N , 尺度 s_j 为填补后按总体定义计算的标准差:

$$s_j = \sqrt{\frac{1}{N} \sum_{n=1}^N (\bar{r}_j^{(n)} - \mu_j)^2}, \quad x_j^{(n)} = \frac{\bar{r}_j^{(n)} - \mu_j}{s_j}. \quad (3.1.1)$$

求和号 $\sum$ 表示把各样本的项相加; 平方根把平方单位还原。全空训练列均值约定为 0, 零标准差约定改为 1, 均写入保存的预处理规则。代码用 `std(ddof=0)`; `ddof` 指分母的自由度修正值, 本处为 0。

用三个数检查 C2

训练某列是 [1, 3, 缺失], 均值为 2; 填充后是 [1, 3, 2], 标准差是 $\sqrt{2/3} \approx 0.816497$ 。验证值 100 应转换为 $98/\sqrt{2/3} \approx 120.025$, 验证缺失值变为 0。验证值不一定落在 $[-1, 1]$ 。

3.2 把截距放进矩阵

令 $\mathbf{x}^{(n)} \in \mathbb{R}^d$ 为标准化后的第 n 个样本; 括号上标是样本编号, 下标 j 是特征坐标, $\mathbb{R}^d$ 表示由 d 个实数组成的向量。本实验 $d = 8$ 。波浪号表示增加了常数特征, 转置 $\top$ 把列改为行:

$$\tilde{\mathbf{x}}^{(n)} = (1, (\mathbf{x}^{(n)})^\top)^\top, \quad \mathbf{X} = \begin{bmatrix} (\tilde{\mathbf{x}}^{(1)})^\top \\ \vdots \\ (\tilde{\mathbf{x}}^{(N)})^\top \end{bmatrix} \in \mathbb{R}^{N \times (d+1)}. \quad (3.2.1)$$

标签张量 $\mathbf{y} \in \mathbb{R}^{N \times 1}$ 。在代码中, `X.shape` 为 `(N, 9)`, `y.shape` 为 `(N, 1)`, 均使用 32 位浮点数 `float32`。先标准化八列, 再加常数 1, 不能把常数列标准化成 0。

检查点 C2

若预测张量是 `(64, 1)`, 标签是 `(64, )`, 两者相减会发生什么? 为什么必须先检查形状?

4 从一条样本到一批样本

4.1 Dataset 和 DataLoader 各做什么

Dataset 负责“总共有几条、给定索引返回哪一条”；**DataLoader** 负责“按什么顺序、每批拿几条”。它们不自动替我们清洗、划分或防止标签泄漏。

```
class LoanDataset(Dataset):
    def __init__(self, X, y):
        self.X = X
        self.y = y

    def __len__(self):
        return len(self.X)

    def __getitem__(self, index):
        return self.X[index], self.y[index]
```

`class LoanDataset(Dataset)` 表示在 PyTorch 提供的数据集类上实现自己的取样规则；`self` 是当前对象。`len(dataset)` 调用 `__len__`，`dataset[2]` 调用 `__getitem__(2)`。这与上次决策树中把相关数据和方法放入同一个对象的思路相同。

4.2 一轮与一次更新

一轮 (epoch) 遍历训练集一次；一次更新只使用当前批次。批量大小为 B ，本实验设为 64。训练集有 8000 条，一轮恰好有 125 批，每批 64 条。若使用其他样本数，仍保留不足 64 条的末批；C3 用五条样本检查这一情况。

```
loader = DataLoader(dataset, batch_size=64,
                    shuffle=True, drop_last=False)
for X_batch, y_batch in loader:
    print(X_batch.shape, y_batch.shape)
```

`shuffle=True` 只用于训练。验证和测试保持固定顺序；`drop_last=False` 不丢弃最后不足一批的样本。打乱的是成对记录，不能独立打乱特征和标签。

检查点 C3：先用五条数据

五条数据、批量大小为 2，会得到几批？每批标签数是多少？如果最后一批被丢弃，评价指标代表的还是原来的五条样本吗？

课堂提示

学生先观察一条样本的形状，再观察一批样本的形状。不要让“二维张量”和“二维特征空间”混为一谈：二维张量指两个轴，本实验可包含八个特征。

5 线性得分、概率和类别

5.1 三个不同的输出

参数 $\theta = (\theta_0, \dots, \theta_d)^\top \in \mathbb{R}^{d+1}$, 其中 θ_0 是截距; 代码保存为 **(d+1, 1)**。线性得分 $z^{(n)}$ 可以取任意实数。sigmoid 函数 $\sigma: \mathbb{R} \rightarrow (0, 1)$ 将得分变成概率:

$$z^{(n)} = (\tilde{\mathbf{x}}^{(n)})^\top \theta, \quad p^{(n)} = P(y^{(n)} = 1 \mid \mathbf{x}^{(n)}; \theta) = \sigma(z^{(n)}) = \frac{1}{1 + e^{-z^{(n)}}}. \quad (5.1.1)$$

P 表示概率, 条件竖线 “|” 表示给定特征; 分号后的参数确定当前模型。 e 是自然指数的底。 $p^{(n)}$ 是模型概率, 不是已观察到的标签。

$$\hat{y}^{(n)} = \mathbf{1}[p^{(n)} \geq \tau], \quad \tau \in (0, 1). \quad (5.1.2)$$

帽号在这里表示**预测类别**。 τ 是决策阈值; 指示函数 $\mathbf{1}[\cdot]$ 在括号内条件成立时为 1, 否则为 0。本课预先固定主实验阈值为 0.5, 恰好等于阈值也判为违约。

5.2 为什么叫对数几率回归

几率是违约与不违约概率之比 $p/(1-p)$; 对数几率函数 $\text{logit}: (0, 1) \rightarrow \mathbb{R}$ 是 sigmoid 的反函数:

$$\text{logit}(p) = \log \frac{p}{1-p} = z. \quad (5.2.1)$$

$\log$ 表示自然对数。本模型假设**对数几率是处理后特征的线性函数**。sigmoid 和 logit 不能互称。阈值为 0.5 时, 边界为 $z = 0$; 提高阈值时, 边界得分变为 $\log(\tau/(1-\tau))$ 。

得分 z	-2	0	2
概率 p	0.119203	0.5	0.880797
类别 ($\tau = 0.5$)	0	1	1

检查点 C4: 模型接口

若参数是 $(1, 2, -1)^\top$, 增广输入是 $(1, 3, 2)^\top$, **forward** 应返回什么? **sigmoid(forward(X))** 又是什么?

6 从伯努利似然到交叉熵

6.1 为什么采用这个损失

给定特征，一个二分类标签服从伯努利模型：只可能取 0 或 1，取 1 的概率为 $p^{(n)}$ 。单条观测标签的概率质量为

$$P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}) = (p^{(n)})^{y^{(n)}} (1 - p^{(n)})^{1-y^{(n)}}. \quad (6.1.1)$$

若 $y^{(n)} = 1$ ，式子只留下 $p^{(n)}$ ；若标签为 0，只留下 $1 - p^{(n)}$ 。假定样本在给定参数后条件独立，整批数据的似然 Λ 是这些概率的连乘； $\prod$ 表示逐项相乘：

$$\Lambda(\boldsymbol{\theta}) = \prod_{n=1}^N P(y^{(n)} | \mathbf{x}^{(n)}; \boldsymbol{\theta}). \quad (6.1.2)$$

最大似然选择让已观察数据更可能出现的参数。取对数将连乘变成求和；加负号将最大化改成最小化；除以 N 得到与样本规模无关的平均损失。

$$\begin{aligned} \mathcal{L}^{(n)} &= -y^{(n)} \log p^{(n)} - (1 - y^{(n)}) \log(1 - p^{(n)}), \\ R(\boldsymbol{\theta}) &= \frac{1}{N} \sum_{n=1}^N \mathcal{L}^{(n)} = -\frac{1}{N} \log \Lambda(\boldsymbol{\theta}). \end{aligned} \quad (6.1.3)$$

$\mathcal{L}^{(n)}$ 是单样本损失， R 是经验风险（样本平均）。该损失称二元交叉熵，简称 BCE (Binary Cross-Entropy)。当真实标签为 1 时，预测 0.9 的损失约为 0.10536，预测 0.1 的损失约为 2.30259，错误且自信会受到更大惩罚。

6.2 让计算接口与公式一致

实际训练用 `BCEWithLogitsLoss`：它接收原始得分并在内部稳定计算 sigmoid 与交叉熵的组合。单样本等价式为

$$\mathcal{L}(z, y) = \max(z, 0) - yz + \log(1 + e^{-|z|}). \quad (6.2.1)$$

$\max(z, 0)$ 取较大值， $|z|$ 是绝对值；此式避免直接计算过大的指数。`BCELoss` 接收概率，`BCEWithLogitsLoss` 接收得分，不能把两种接口混用。

检查点 C5

所有得分为 0 时，平均数据损失是多少？为什么不能先 sigmoid 再传给 `BCEWithLogitsLoss`？

7 从损失到一次参数更新

7.1 梯度给出每个参数的变化方向

梯度 $\nabla_{\theta} R$ 是 R 对每个参数的偏导数组成的列向量；在当前位置，小幅沿负梯度移动会使损失一阶近似下降。先对单样本逐步求导：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial p} &= -\frac{y}{p} + \frac{1-y}{1-p}, & \frac{\partial p}{\partial z} &= p(1-p), \\ \frac{\partial \mathcal{L}}{\partial z} &= \frac{\partial \mathcal{L}}{\partial p} \frac{\partial p}{\partial z} = p - y.\end{aligned}\quad (7.1.1)$$

∂ 表示把其他变量暂时固定的偏导；链式法则把前两项相乘，约去分母，得到 $p - y$ 。又因 $z = \tilde{\mathbf{x}}^{\top} \boldsymbol{\theta}$ ，有

$$\nabla_{\theta} R = \frac{1}{N} \mathbf{X}^{\top} (\mathbf{p} - \mathbf{y}), \quad \boldsymbol{\theta}^{[t+1]} = \boldsymbol{\theta}^{[t]} - \eta \nabla_{\theta} R. \quad (7.1.2)$$

$\mathbf{p}, \mathbf{y} \in \mathbb{R}^{N \times 1}$; $\mathbf{X}^{\top} \in \mathbb{R}^{(d+1) \times N}$ ，梯度形状为 $(d+1) \times 1$ 。 $\eta > 0$ 是学习率；方括号上标 $[t]$ 表示迭代次数，与样本编号 (n) 区分。

7.2 贯穿手算：两条模拟贷款的更新

为便于手算，仅保留“标准化贷款金额、标准化收入”两个坐标。下表**专为课堂构造**，不是教材记录，也不是随包数据的抽样；标准化坐标 0 表示处于训练均值。

当前样本 n	贷款坐标	收入坐标	标签 $y^{(n)}$
1	1	0	1
2	0	1	0

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}, \quad \boldsymbol{\theta}^{[0]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{p} = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix}, \quad \nabla R = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -0.5 \\ 0.5 \end{bmatrix} = \begin{bmatrix} 0 \\ -0.25 \\ 0.25 \end{bmatrix}. \quad (7.2.1)$$

取 $\eta = 0.4$ ，更新后参数为 $(0, 0.1, -0.1)^{\top}$ ，两条概率分别为 0.524979 和 0.475021。平均损失从 0.693147 降至 0.644397。

检查点 C6: 核对方向

贷款权重变大、收入权重变小，为何能让这两条已知标签更可能？请用代码输出 `theta.grad` 与更新后的 `theta` 核对，不能只看损失是否下降。

8 正则化与训练循环

8.1 区分拟合损失和训练总目标

训练集拟合得好不保证新样本表现好。参数过大可能把样本噪声也拟合进去。用 Ω 表示权重惩罚, $\lambda \geq 0$ 控制其强度, 训练总目标 J 为

$$J(\theta) = R(\theta) + \lambda \Omega(\theta),$$

$$\Omega_{L1}(\theta) = \sum_{j=1}^d |\theta_j|, \quad \Omega_{L2}(\theta) = \frac{1}{2} \sum_{j=1}^d \theta_j^2. \quad (8.1.1)$$

L1 (L1 Norm, 一范数) 是绝对值之和; 本实验的 L2 (L2 Norm, 二范数) 惩罚采用二范数平方的一半, 并非二范数本身。这里不惩罚截距 θ_0 。若参数为 $(10, 3, -4)^\top$, 两种惩罚分别为 7 和 12.5。

L2 惩罚的梯度是 $(0, \theta_1, \dots, \theta_d)^\top$ 。L1 在非零坐标用符号函数求导, 零点不唯一; PyTorch 在该处取 0。普通梯度更新下不保证权重恰好为零, 不能把 L1 等同于本程序一定自动删除特征。

8.2 一批数据如何执行更新

本实验用小批量随机梯度下降 SGD (Stochastic Gradient Descent) 更新参数。对当前批次, 把上一节梯度式中的 N 换成当前批次大小 B 。torch.optim.SGD 已提供参数更新规则, 学生连接五个步骤:

```
optimizer.zero_grad()
logits = model(X_batch)
loss = data_loss(logits, y_batch)
objective = loss + strength * model.penalty(kind)
objective.backward()
optimizer.step()
```

backward() 用自动微分得到每个参数的梯度; step() 更新参数。梯度默认会累加, 所以每批先清零。损失在反向传播前不能用 item() 转成普通数, 也不能 detach() 切断计算图。

曲线必须比较同一种量

不同 λ 的训练总目标不能直接拿来选模型。本实验每轮结束, 用当前同一组参数分别计算全训练集与验证集的**无正则数据损失**, 画出两条曲线; 模型选择也看验证数据损失。

检查点 C5/C6

把 zero_grad() 删除, 第二次更新仍与手算一致吗? 若 λ 极大, 可能发生什么?

9 评价与真实 workflow

9.1 先数清四种结果

在固定阈值下，TP (True Positive, 真正例) 表示真实违约且预测违约；FP (False Positive, 假正例) 表示真实未违约却预测违约；FN (False Negative, 假负例) 表示真实违约却预测未违约；TN (True Negative, 真负例) 表示两者都为未违约。

$$\text{Accuracy} = \frac{TP + TN}{N}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}. \quad (9.1.1)$$

准确率统计整体正确比例；精确率回答“预测违约中有多少真违约”；召回率回答“真实违约中找到了多少”。F1 分数 (F1 Score) 是精确率与召回率的调和平均：

$$F1 = \frac{2 \text{Precision Recall}}{\text{Precision} + \text{Recall}}. \quad (9.1.2)$$

本代码约定分母为 0 的比率返回 0。训练两类相同时，常数基线预先约定总预测未违约；在当前测试集上准确率为 80%。同时报告混淆矩阵与召回率，不能只看准确率。

9.2 阈值连接误判代价

在教学假设下，漏判一次的代价为 2、误报一次为 1，则总代价为 $2FN + FP$ 。它只是课堂设定，不能当作实际贷款损失。比较验证集上阈值 0.3、0.5、0.7 的结果；降低阈值通常增加召回率，也可能增加误报。

本实验主结果**预先固定阈值为 0.5**，按验证数据损失选择正则化方案和轮数。测试集只在冻结后读取一次；报告测试结果后不得据此回调参数。若要扩展阈值选择，也必须在测试前用验证集确定规则。

检查点 C7

真实标签为 [1, 0, 1, 0]，概率为 [0.9, 0.8, 0.4, 0.1]。在阈值 0.5 下手算四种计数，再把阈值改为 0.3；哪类错误减少了？

9.3 本算法在项目中的位置与局限

先明确任务与误判代价，再收集预测时可获得的数据，划分训练/验证/测试，拟合表示规则，选择概率模型和目标，优化权重，用验证集做选择，最后测试与上线监测。数据是否覆盖新时期、概率是否校准、不同群体误差是否不同，都需要额外证据。

训练集有 50% 违约样本，验证与测试为 20%；平衡抽样后，输出不能直接视为自然人群中已校准的违约概率。两组类别比例不同，损失曲线的高低差不单由过拟合决定。原始字段含极端值，随机划分不能代表未来时期。有序编码引入等距假设；线性对数几率不能自动表达复杂交互。实际贷款等级、利率是否可在预测时取得，也要按业务时点核对。单次小测试集的结果有随机波动，不能证明泛化能力。

10 自测答案、符号索引与资料

10.1 课前自测与退出卡

1. C0: 0.7 是概率; 阈值 0.5 判 1, 阈值 0.8 判 0。
2. C1: 12 是为最高就业年限档指定的编码, 原始信息只有“10 年以上”。
3. C2: $(64, 1) - (64,)$ 可能广播成 $(64, 64)$; 损失函数也可能直接拒绝不匹配形状, 必须保持标签为 $(64, 1)$ 。
4. C3: 共三批, 大小为 2、2、1; 丢弃末批会改变评价样本集合。
5. C4: 得分 $1 + 2 \times 3 - 2 = 5$, 概率约为 0.993307。
6. C5: 数据损失为 $\log 2 \approx 0.693147$; 提前 sigmoid 会把概率当得分再次转换, 改变模型和梯度。
7. C6: 误差向量为 $(-0.5, 0.5)^\top$, 更新后概率向各自标签移动。漏清梯度会累加前一批的梯度; 过大正则化可能欠拟合。
8. C7: 阈值 0.5 时四种计数均为 1, 各比率为 0.5; 阈值 0.3 时真正例 2、假正例 1、假负例 0、真负例 1, 召回率为 1。

退出卡: 用一句话说出得分、概率、类别的区别; 写出一次梯度更新; 解释为什么训练集和验证集必须使用同一组预处理统计量。后续优化实验将沿用损失、梯度和学习率记号, 比较不同更新规则。

10.2 符号索引

类别	记号与含义	首次解释
数据与模型	$r_j^{(n)}, \mu_j, s_j$: 编码值、训练均值、尺度	3.1
数据与模型	$\mathbf{x}^{(n)}, \tilde{\mathbf{x}}^{(n)}, \mathbf{X}, \mathbf{y}$: 样本、增广样本、设计矩阵、标签	3.2
数据与模型	$\theta, z, p, \hat{y}, \tau$: 参数、得分、概率、类别、阈值	5.1
函数与算子	$\sigma, \text{logit}, \log, \mathbf{1}[\cdot]$: 概率映射、反函数、对数、指示函数	5.1–5.2
函数与算子	$\nabla, \partial, \eta, [t]$: 梯度、偏导、学习率、迭代	7.1
概率与估计	$P, \Lambda, \mathcal{L}, R, J, \Omega, \lambda$: 概率、似然、单样本损失、风险、目标、惩罚及强度	5–8 节

10.3 实际使用资料与改编说明

- 项目上级目录的《人工智能数学原理与算法: 实验指导书 (最终) .pdf》第 1 章, 第 1–13 页 (文件第 15–27 页): 任务、数据清洗、PyTorch 接口、正则化及评分结构。
- 仓库 `source/slides/2.5 逻辑回归 _v2.pdf`: 贷款任务、得分与概率、最大似然与梯度的叙述顺序。原课件的正负一标签在本文统一为 0/1。
- 仓库 `source/experiment/Logic.ipynb` 与 `source/experiment/utils.py`: 原实验入口和字段编码。本文明确修订 `sigmoid/logit` 名称、训练统计量复用和损失接口。
- 仓库 `教案/人工智能数学原理与算法 _12 次课程与助教分工 _最终版.xlsx`: “课程执行总表” 第 3 次及实验安排说明; 理论课为 3 学时, 实验具体日期未固定, 本文建议 135 分钟。
- 天池下载的 `code/data/train.csv` 与随包 `code/data/classroom/`: 真实贷款源表与固定抽样; 来源、字段、摘要及重建方法见 `code/data/README.md`。
- 同级实验 01 的 `assets/experiment-style.tex` 与实验 02 的 `README.md`、`code/decision_tree.py`: 版式、渐进任务和代码提示风格。