实验 05

# 宠物主体分割

## 卷积编码器、解码器与小型 U-Net



PyTorch 实验讲解

主讲：钟志诚　整理：曾有成
中国科学技术大学
人工智能与数据科学学院

# 每个像素都要回答：是不是宠物



整张图的类别 → 猫 / 狗 / 品种

图像分类

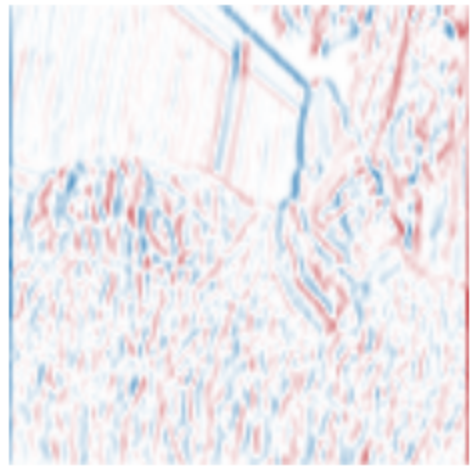
像素位置 (u, v) → 宠物 1 / 背景 0

主体分割：保留空间位置

本实验的输出是一张 128 × 128 的二值掩码

# 卷积神经网络的基本组成

CNN（Convolutional Neural Network，卷积神经网络）

| 局部像素 | 卷积响应 | 激活后响应 | 池化后响应 |
| --- | --- | --- | --- |
|  |  |  |  |
| 转为灰度后计算<br>黄框：一个局部窗口 | 同一组核权重<br>提取局部变化 | 负值变为 0<br>引入非线性 | 局部取最大值<br>高、宽各减半 |

固定核教学演示，非训练结果。红：负响应；白：0；蓝：正响应。

# 卷积核在局部窗口里计算

输入：3 × 3

| | | |
|---|---|---|
| 1 | 2 | 3 |
| 4 | 5 | 6 |
| 7 | 8 | 9 |

卷积核：2 × 2

| | |
|---|---|
| 1 | 0 |
| 0 | -1 |

输出：2 × 2

| | |
|---|---|
| -4 | -4 |
| -4 | -4 |

$$1 \times 1 + 2 \times 0 + 4 \times 0 + 5 \times (-1) = -4$$

逐元素相乘，再求和。同一个核滑到下一个位置，重复计算。

# 激活改变数值，池化改变尺寸

## ReLU（Rectified Linear Unit）

修正线性单元：负值变为 0

| 输入 | -2 | 0 | 3 |
|---|---|---|---|
| 输出 | 0 | 0 | 3 |

$$g(z) = \max(0, z)$$

z：激活前数值；输出尺寸不变

## 2 × 2 最大池化，步长 2

| | | | |
|---|---|---|---|
| 1 | 3 | 2 | 0 |
| 4 | 2 | 1 | 5 |
| 0 | 6 | 3 | 1 |
| 2 | 1 | 4 | 2 |

→

| | |
|---|---|
| 4 | 5 |
| 6 | 4 |

4 × 4 → 2 × 2

池化保留局部最大响应，也会丢失部分精确位置信息。

# 层与层连接时，先核对维度

## PyTorch 图像张量：[B, C, H, W]

B：批量图片数；C：通道数；H、W：高、宽

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + 2p - k}{s} \right\rfloor + 1$$

H 的下标 in / out 表示输入 / 输出，$\lfloor \cdot \rfloor$ 表示向下取整。
k：核大小；p：每侧填充；s：步长。这里膨胀率为 1，宽度同理。

| 操作 | 输入 | 输出 |
| --- | --- | --- |
| 3 × 3 卷积，填充 1，步长 1 | [B, 3, 128, 128] | [B, 16, 128, 128] |
| 2 × 2 池化，步长 2 | [B, 16, 128, 128] | [B, 16, 64, 64] |

# Oxford-IIIT Pet：真实宠物照片

37 个猫狗品种，7,349 张图片。本实验统一学习“宠物前景”。



Bengal



Persian



Siamese



samoyed



english cocker spaniel

观察难点：毛发边界、姿态变化、相似背景和遮挡

# 三值标注与本实验的二值目标

原图

三值标注

训练目标

Abyssinian_10



Trimap: pet / background / unknown



Target: white=pet, gray=ignored



beagle_10



Trimap: pet / background / unknown



Target: white=pet, gray=ignored



1 宠物前景
目标为 1

2 背景
目标为 0

3 未确定区域
损失与指标忽略

# 固定划分与同步预处理

| 集合 | 图片数 | 用途 |
| --- | --- | --- |
| 训练集 | 2,941 | 更新网络参数 |
| 验证集 | 739 | 选择网络、超参数与最佳轮次 |
| 测试集 | 3,669 | 选定模型后做最终评估 |

## 统一缩放到 128 × 128

图片：双线性插值
标注：最近邻插值

## 图片与掩码一起翻转

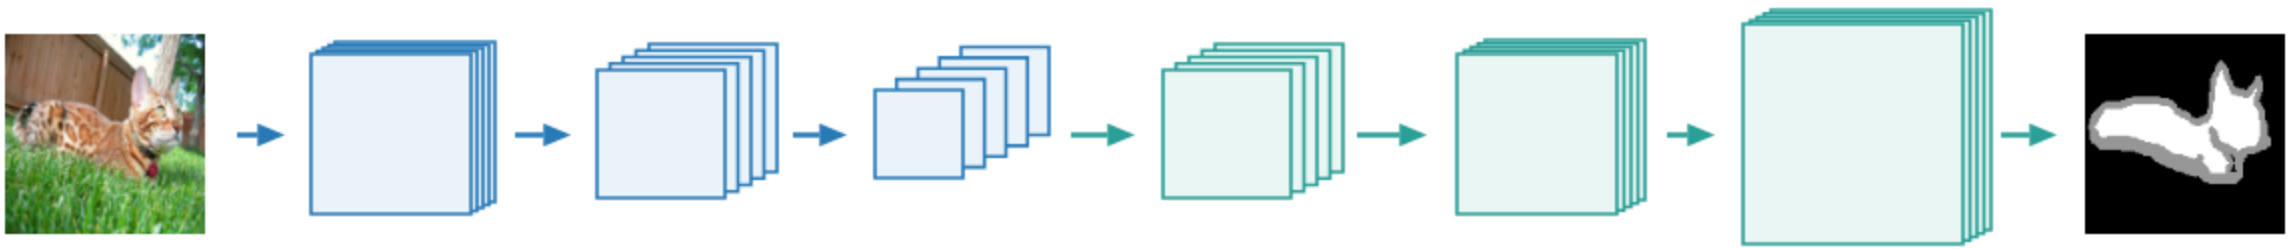
随机增强仅用于训练集
三份名单互不相交

# 基础模型：编码器与解码器

学生搭建编码器（Encoder / Backbone）与解码器（Decoder）

空间变小 · 通道增多

空间变大 · 通道整体减少



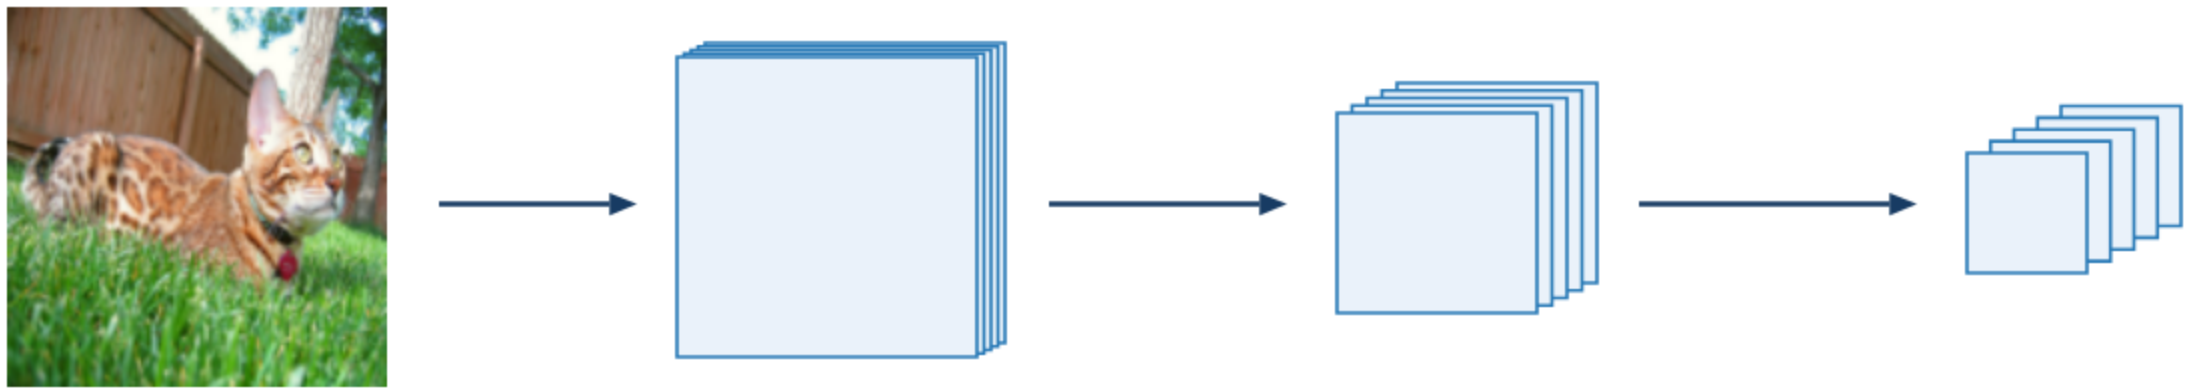

1 × 1 卷积
生成单通道得分

正面大小：空间分辨率；叠层厚度：通道数（示意）。

右侧展示目标标注；实际输出经概率变换与阈值判断后得到预测掩码。

# 编码器：空间更小，特征通道更多

每个阶段：3 × 3 卷积 → ReLU → 2 × 2 池化



输入图片
RGB 三通道

阶段 1：e1
较高分辨率

阶段 2：e2
中间尺度

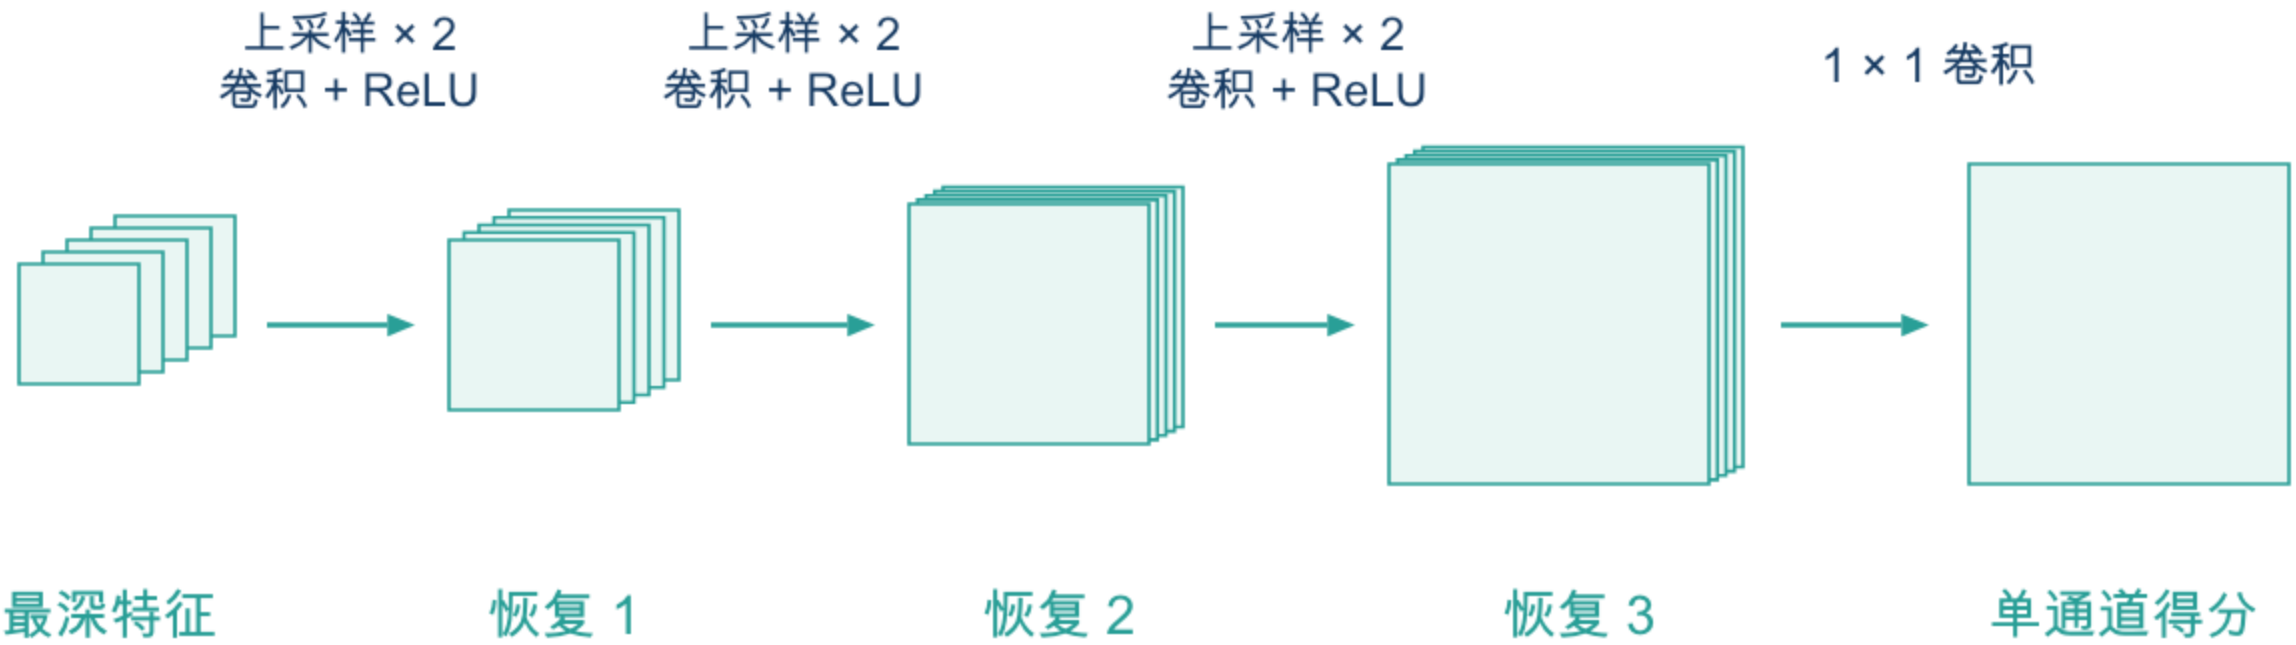
阶段 3：z
最深特征

RGB（Red, Green, Blue）：红、绿、蓝。图中每一叠表示一组特征图。

卷积学习不同的响应；池化减少空间位置。e1、e2、z 都要保留。

# 解码器：逐步恢复逐像素输出

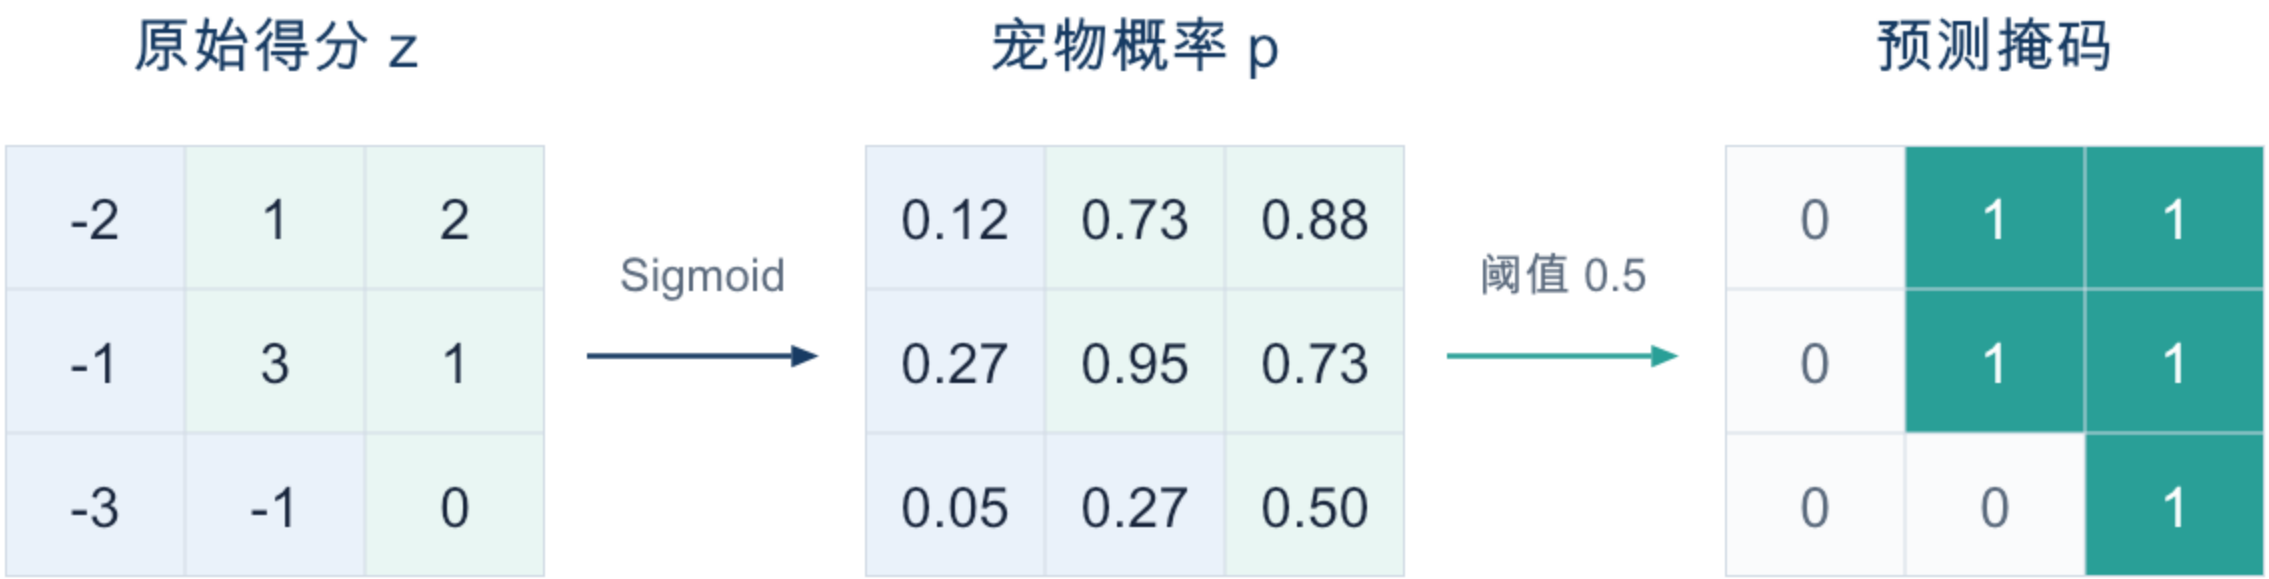
每次先上采样扩大特征图，再用卷积学习组合




通道整体减少，部分阶段保持不变；输出头把多通道变为单通道。

插值能恢复尺寸，却无法凭空找回池化时丢失的细节。

# 单通道得分、概率与预测掩码




$$p = \sigma(z) = \frac{1}{1 + \exp(-z)}$$

$$\hat{y} = \mathbf{1}[p \geq 0.5] = \mathbf{1}[z \geq 0]$$

σ 是 Sigmoid 函数；ŷ 是预测标签；1[条件] 在条件成立时取 1，否则取 0。

训练交给损失函数的是原始得分。上述数字仅作教学演示。

# 训练目标：只在有效像素上计算损失

## 二元交叉熵衡量概率与标签的差异

$$\mathcal{L}_{\text{pix}} = -y \log p - (1 - y) \log(1 - p)$$

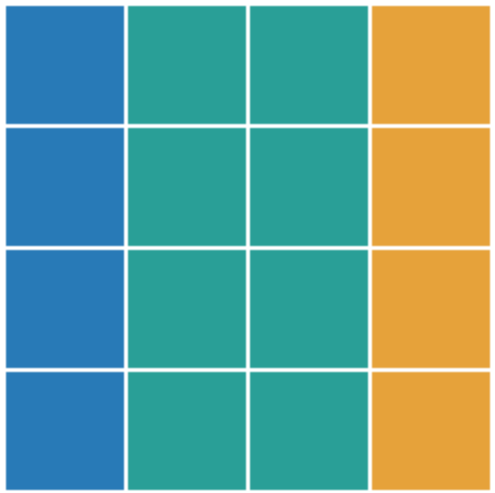
y 是 0 或 1 的标签，p 是宠物概率，log 表示自然对数。

| 区域 | 是否计入训练损失 | 是否计入评估 |
| --- | --- | --- |
| 宠物 / 背景 | 计入 | 计入 |
| 原始标注值 3 | 忽略，梯度为 0 | 忽略 |

先对每张图片的有效像素取平均，再对批量图片取平均。

# IoU 与 Dice：预测区域重合了多少

## IoU（Intersection over Union，交并比）



P：预测前景，共 12 格
G：真实前景，共 12 格

$$\mathrm{IoU} = \frac{|P \cap G|}{|P \cup G|} \qquad \mathrm{IoU} = \frac{8}{16} = 0.5$$

**重合部分，占两者覆盖范围的比例**

并集包含误检、漏检和正确重合，共 16 格。

$$\mathrm{Dice} = \frac{2|P \cap G|}{|P| + |G|} \qquad \mathrm{Dice} = \frac{2 \times 8}{12 + 12} = \frac{2}{3} \approx 0.667$$

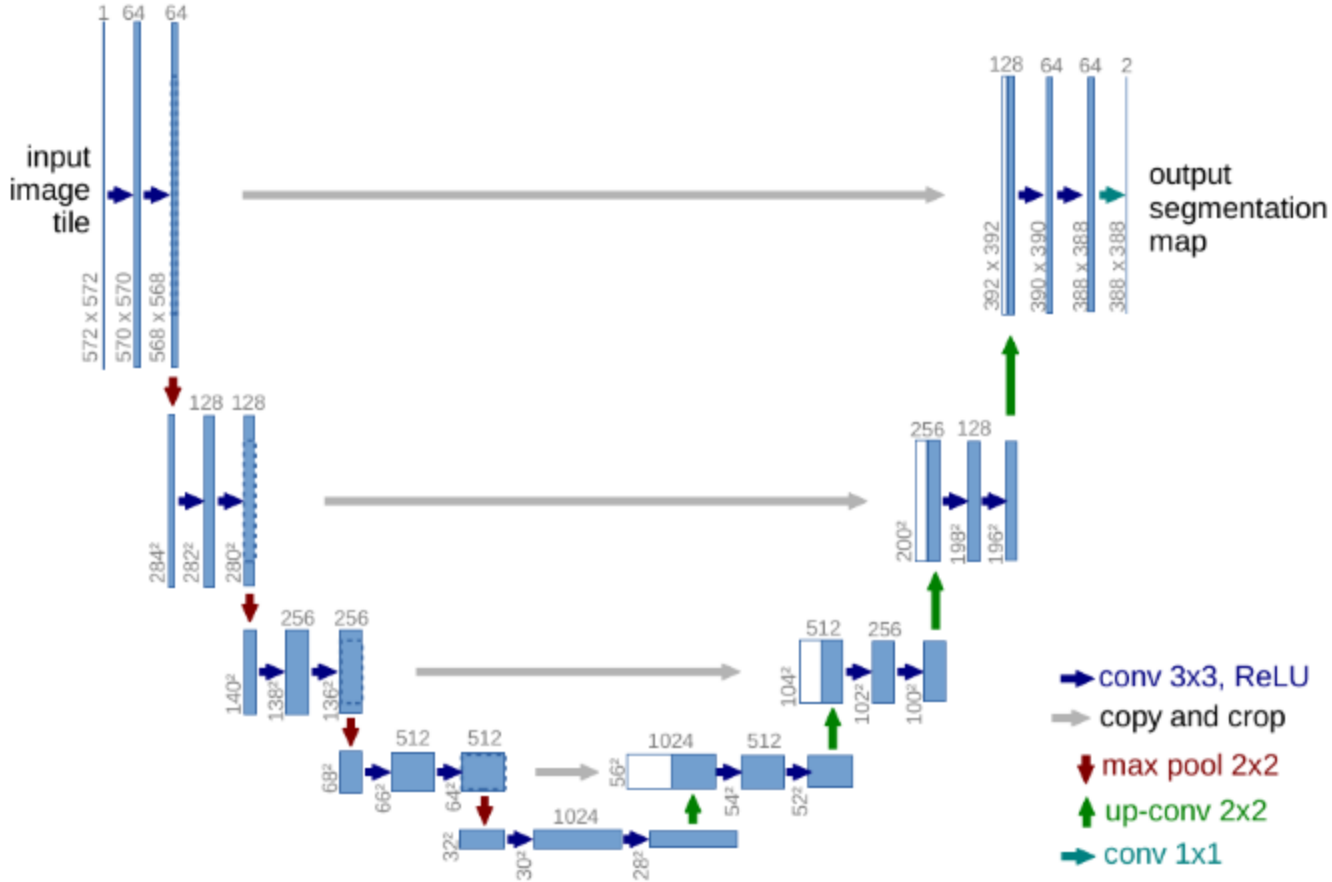
**重合部分，相对于两份前景的总量**

两份前景合计 24 格，重合在分子中也计两次。

仅 P：4　　重合：8　　仅 G：4

|·| 表示像素数；∩ 为交集，∪ 为并集。只看有效像素，最后逐图取平均。

# U-Net：让解码器接收浅层特征




左侧：降低分辨率
学习更大范围的表示

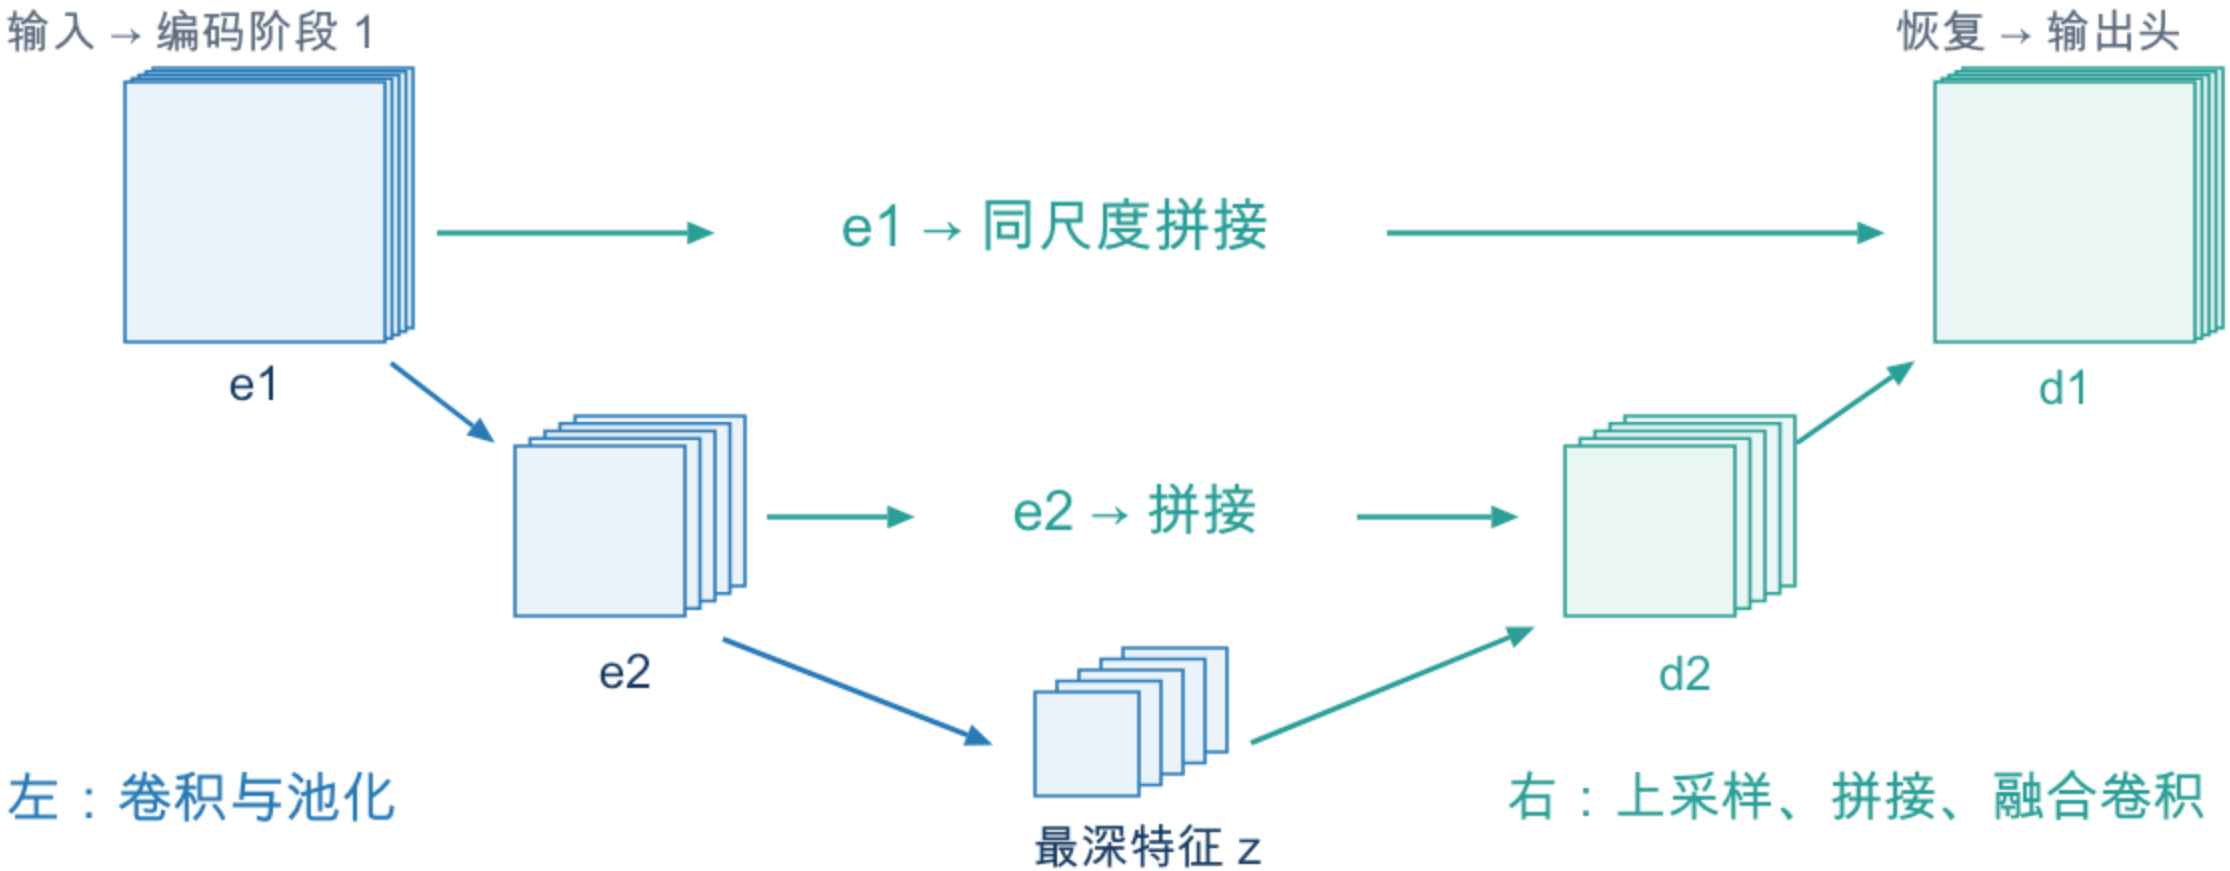
右侧：提高分辨率
恢复逐像素输出

横向：传递浅层特征
补充定位细节

原论文结构示意。下一页使用本实验的简化配置。

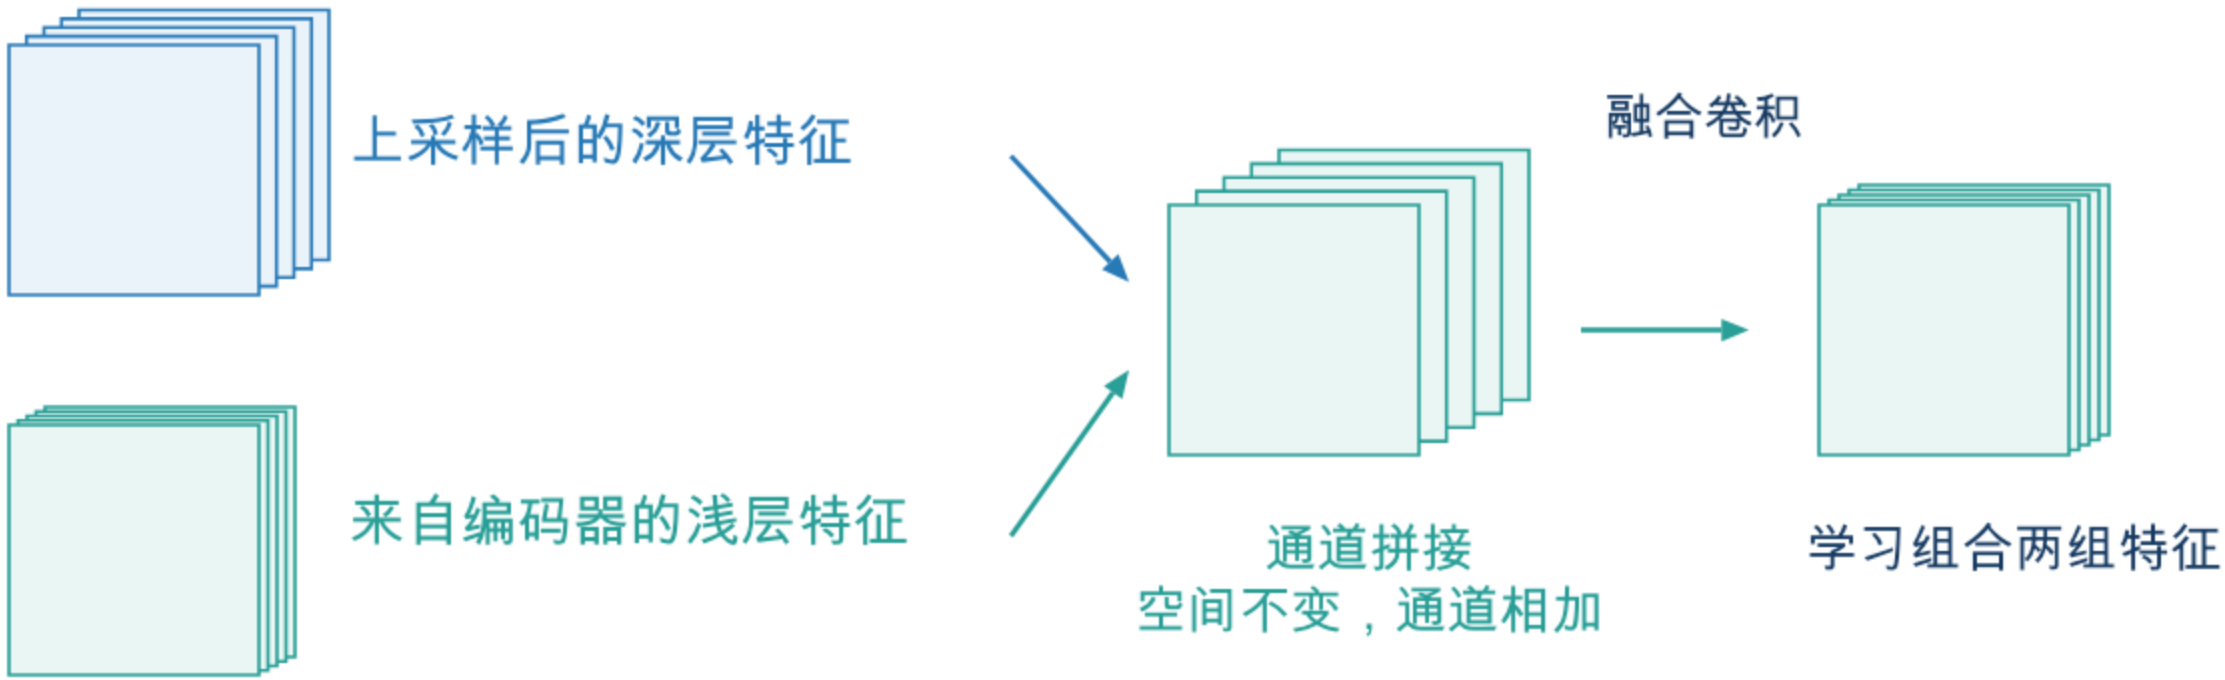
# 进阶选做：小型 U-Net

跳跃连接把较高分辨率的特征，送到同尺度的解码阶段



# 跳跃连接：对齐、拼接、融合

先把深层特征上采样，使它与跳跃特征的高、宽一致




示例：64 通道与 32 通道拼接成 96 通道，再由卷积映射到 32 通道。

# U-Net 拼接与 ResNet 相加

ResNet（Residual Network，残差网络）

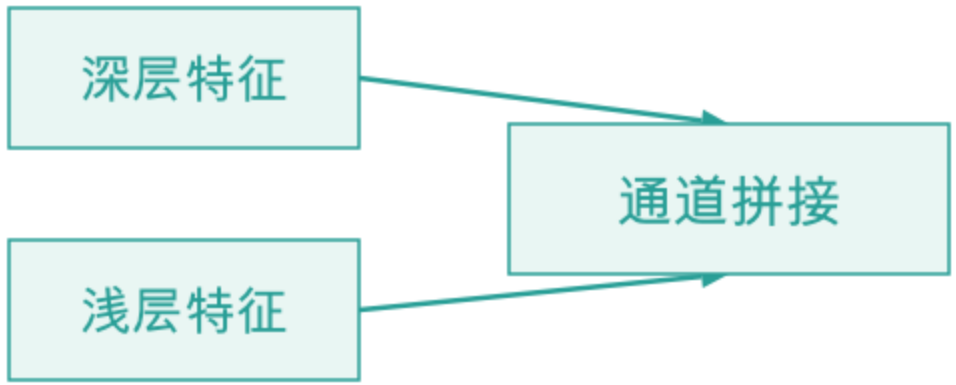
残差相加：学习对输入的修正




$$\mathbf{Y} = F(\mathbf{X}) + \mathbf{X}$$

对应元素相加，形状需匹配
通道数不变，传递恒等路径

U-Net 拼接：融合不同层的特征




高、宽对齐，沿通道保留两组特征
再由卷积学习融合，补充定位细节

# BN 与 LN：稳定特征尺度，帮助训练

BN（Batch Normalization）

批量归一化

同一通道，跨样本与空间位置统计

作用：控制特征尺度，改善优化
批量统计的噪声可能带来正则化效果

注意：小批量统计可能不稳定
训练、评估使用统计量的方式不同

LN（Layer Normalization）

层归一化

同一样本，在指定特征维度统计

作用：稳定每个样本的特征尺度
不依赖同批次的其他样本

注意：先明确归一化哪些维度
不能把 LN 当成 BN 的直接替换

归一化后仍有可学习的缩放与平移；是否提升泛化，要用验证集对照。

# 学生需要补全的三份代码

| 文件 | 学生完成 | 检查命令 |
| --- | --- | --- |
| operator_exercises.py | 卷积、激活、池化 | python checks.py operators |
| student_encoder.py | 三阶段编码器<br>及一个改进版本 | python checks.py encoder |
| student_decoder.py | 上采样、卷积与输出头 | python checks.py decoder |

已提供：数据处理、网络连接、训练循环、损失与评估。

完整网络：分别运行 python checks.py basic 和 python checks.py improved

进阶选做：自行实现小型 U-Net。解码器形状与 Hint 见讲义第6节。

# 本地与107平台两条运行路径

## 本地有NVIDIA显卡：本地入口（讲义8.1）

```
python run_local.py basic
python run_local.py improved
```

## 本地没有NVIDIA显卡：107平台Slurm（讲义8.2）

```
bash scripts/submit.sh basic
bash scripts/submit.sh improved
```

两条路径共用代码与评分标准。选定模型后，按对应入口评估并提交日志。

# 至少完成一组受控对比

| 实验 | 变化 | 保持一致 |
| --- | --- | --- |
| 基础模型 | 三阶段编码器 | 划分、分辨率、训练预算 |
| 改进模型 | 例如只加入 BN | 同一解码器与评估口径 |
| 进阶 U-Net | 加入跳跃连接与融合 | 相同数据与训练设置 |

## 报告记录

验证 IoU、损失曲线、参数量与训练耗时。
至少分析 3 个相对成功案例和 3 个失败案例。

# 评分与提交内容

| 评分项 | 分值 |
| --- | --- |
| 基础运算与尺寸解释 | 20 |
| 编解码器实现与连接 | 30 |
| 训练与复现 | 20 |
| 对比与错误分析 | 20 |
| 最终分割效果 | 10 |

效果分（10 分）
测试集平均前景 IoU 乘以 10

进阶最多加 20 分
总分封顶 100 分

连接与维度 8 · 有效对照 8
与残差思想的理论比较 4

提交代码、报告、最佳权重
训练记录、代码快照
测试指标与运行日志

完整数据集、环境与缓存不打包。

# 开始实验前的四个检查问题

01 卷积怎样改变通道数？池化会改变通道数吗？

02 上采样回到原图大小，是否意味着细节全部恢复？

03 64 通道与 32 通道拼接后，融合卷积接收多少通道？

04 为什么分割效果主要看前景 IoU，而不是像素准确率？

# 参考资料与图片来源

| | |
|---|---|
| 课程理论 | 邱锡鹏《神经网络与深度学习》第5章<br>实验05讲义与配套 PyTorch 代码 |
| 宠物照片与标注 | Parkhi 等，Oxford-IIIT Pet / Cats and Dogs (2012)<br>robots.ox.ac.uk/~vgg/data/pets/ |
| 网络结构 | Ronneberger 等，U-Net (2015)，原论文 Figure 1<br>He 等，Deep Residual Learning (2015) |
| 接口说明 | PyTorch：Conv2d、BatchNorm2d、LayerNorm<br>图片出处与课堂提问见各页讲者备注 |

# 基础实现有局限，任务本身有提升空间

同一测试集：3,669 张图片；按每张图片的前景指标取平均

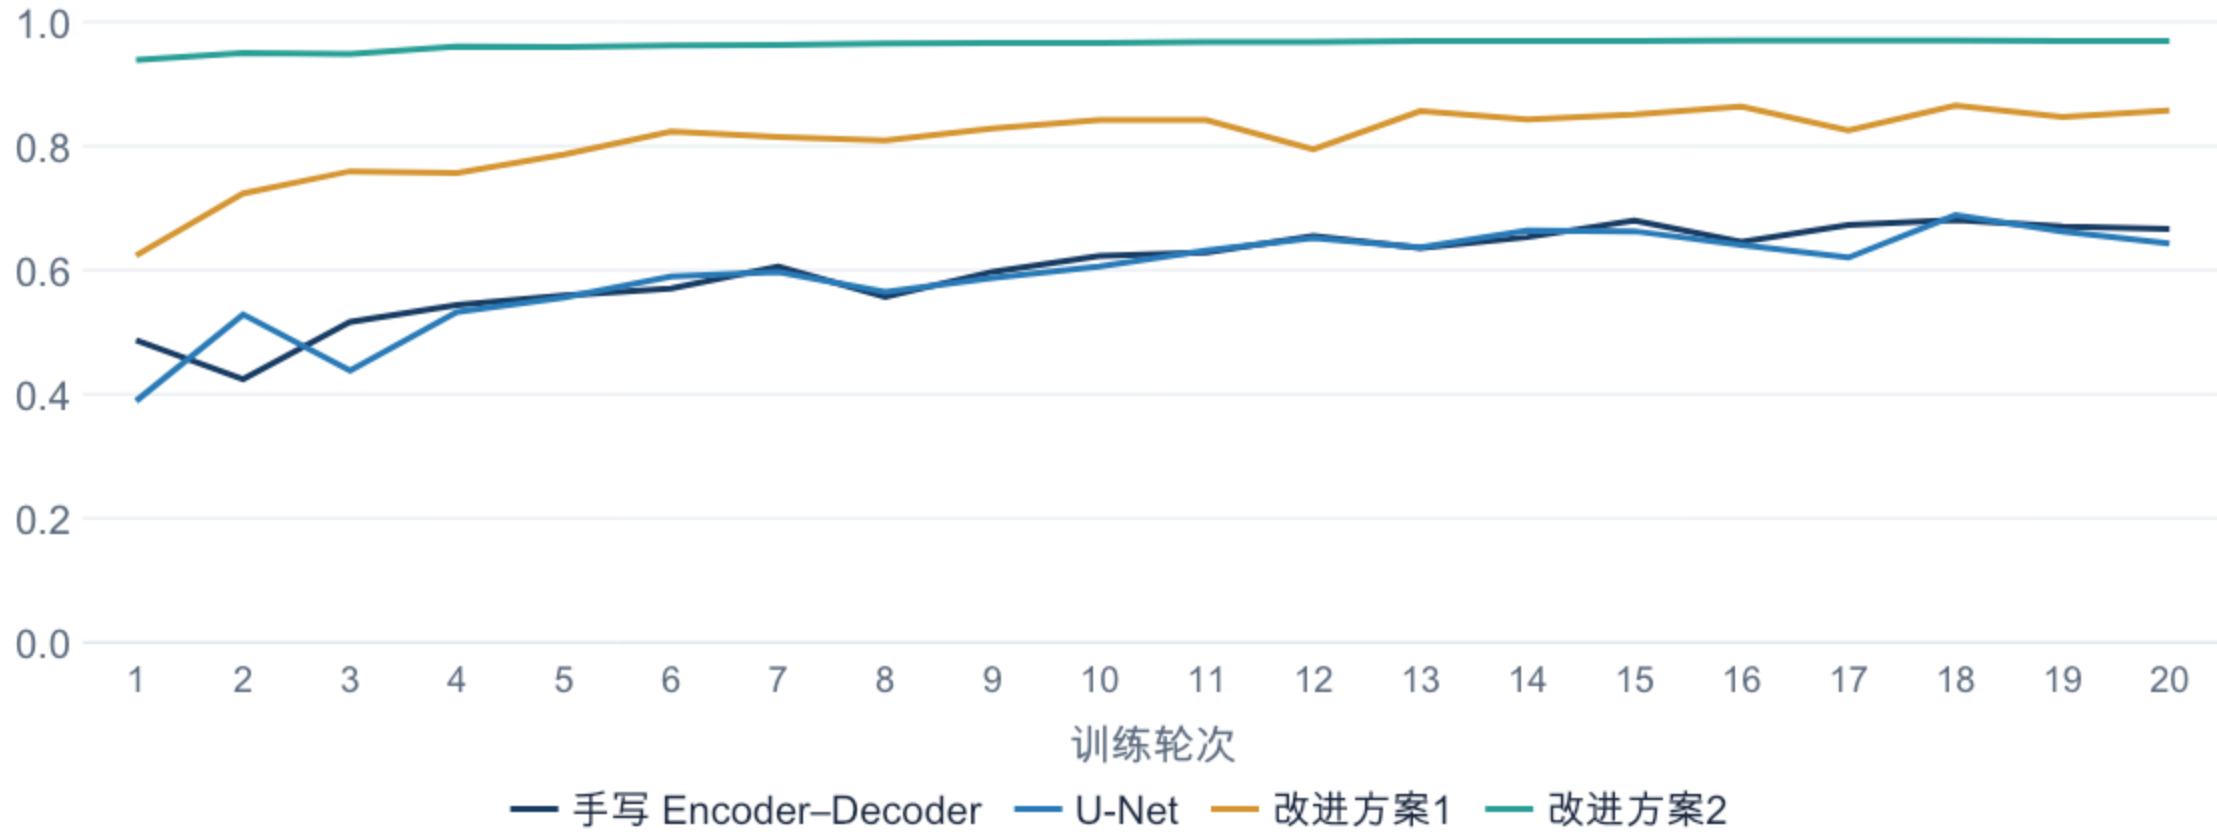
| 实验 | 测试 IoU ↑ | 测试 Dice ↑ |
| --- | --- | --- |
| 手写 Encoder–Decoder | 0.702 | 0.806 |
| U-Net | 0.707 | 0.811 |
| 改进方案1 | 0.867 | 0.917 |
| 改进方案2 | 0.969 | 0.981 |

## 从约 0.70 到约 0.97：分割质量还有很大提升空间

统一 128 × 128 评估网格，阈值 0.5，忽略不确定边界；训练配置不同。

# 训练曲线：观察分割效果如何变化

每轮训练结束后，在同一验证集上计算前景 IoU（越高越好）

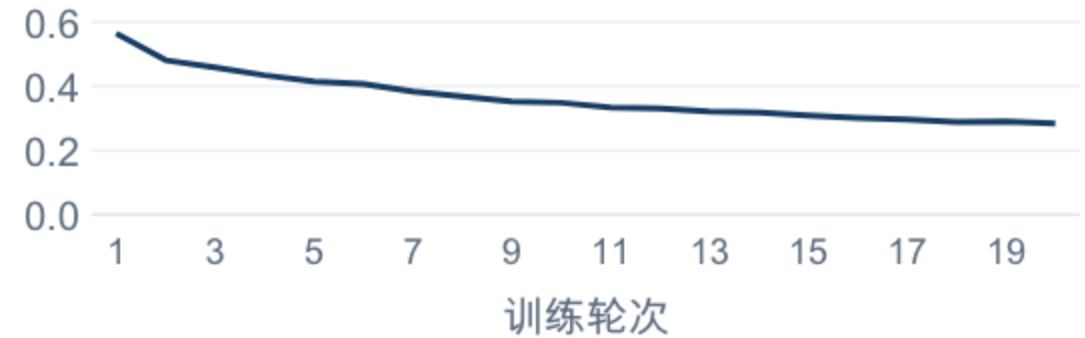



曲线保留真实波动；最终模型由验证集选择，再做一次完整测试。

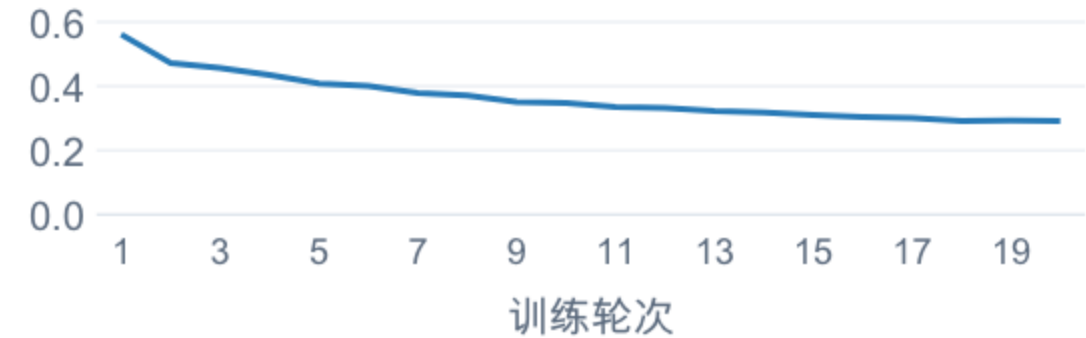
# 训练损失下降，并不等于分割已经足够好

同时看训练损失、验证指标和预测图片，才能判断模型学到了什么

手写 Encoder–Decoder



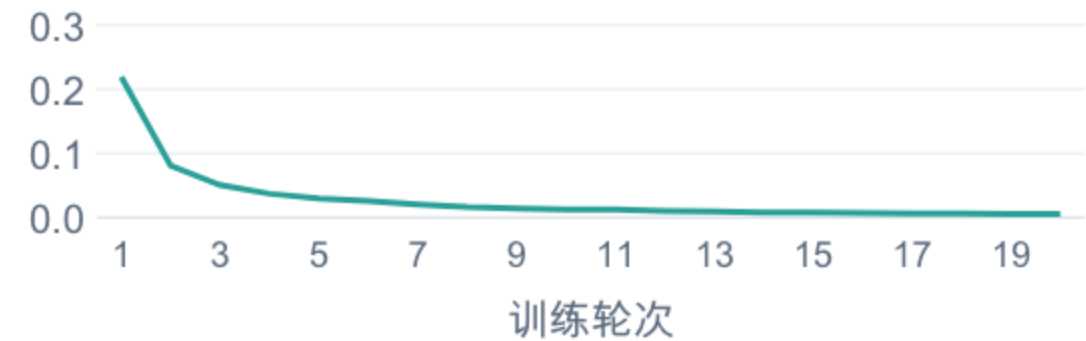

U-Net




改进方案1




改进方案2




各子图纵轴独立；损失定义可能不同，数值不作横向排名。

# 同一张图片，分割结果可以差多少（1/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

| 输入图片 | 真实掩码 | 手写 Encoder–Decoder | U-Net | 改进方案1 | 改进方案2 |
|---|---|---|---|---|---|
|  |  |  |  |  |  |
| Birman_5 | | IoU 0.638 | IoU 0.696 | IoU 0.564 | IoU 0.969 |
|  |  |  |  |  |  |
| Maine_Coon_69 | | IoU 0.242 | IoU 0.444 | IoU 0.344 | IoU 0.995 |

白：宠物；黑：背景；灰：标注中的忽略区域。

# 同一张图片，分割结果可以差多少（2/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

| 输入图片 | 真实掩码 | 手写 Encoder–Decoder | U-Net | 改进方案1 | 改进方案2 |
|---|---|---|---|---|---|
|  |  |  |  |  |  |
| Siamese_47 | | IoU 0.882 | IoU 0.846 | IoU 0.787 | IoU 0.872 |
|  |  |  |  |  |  |
| scottish_terrier_99 | | IoU 0.518 | IoU 0.627 | IoU 0.466 | IoU 0.992 |

白：宠物；黑：背景；灰：标注中的忽略区域。

# 同一张图片，分割结果可以差多少（3/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

| 输入图片 | 真实掩码 | 手写 Encoder–Decoder | U-Net | 改进方案1 | 改进方案2 |
|---|---|---|---|---|---|
|  |  |  |  |  |  |
| boxer_27 | | IoU 0.957 | IoU 0.906 | IoU 0.820 | IoU 1.000 |
|  |  |  |  |  |  |
| great_pyrenees_22 | | IoU 0.834 | IoU 0.862 | IoU 0.994 | IoU 0.998 |

白：宠物；黑：背景；灰：标注中的忽略区域。

# 手写网络是起点，分割质量可以继续提高

## 0.70 → 0.97

同一测试集上的平均前景 IoU

先完成：把原理变成能训练、能评估的网络

再探索：让每一次修改，都有曲线与预测结果作证

**基础模型的效果有限，不意味着这个任务只能做到这样。**

在本实验评价口径下，可以做得很好；高平均分也仍有失败样例。