实验 05

宠物主体分割

卷积编码器、解码器与小型 U-Net



PyTorch 实验讲解

主讲：钟志诚　整理：曾有成
中国科学技术大学
人工智能与数据科学学院

每个像素都要回答：是不是宠物



整张图的类别 → 猫 / 狗 / 品种

图像分类

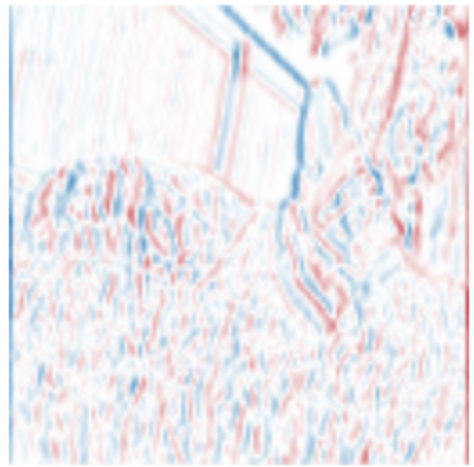
像素位置 (u, v) → 宠物 1 / 背景 0

主体分割：保留空间位置

本实验的输出是一张 128 × 128 的二值掩码

卷积神经网络的基本组成

CNN（Convolutional Neural Network，卷积神经网络）

局部像素	卷积响应	激活后响应	池化后响应
			
转为灰度后计算 黄框：一个局部窗口	同一组核权重 提取局部变化	负值变为 0 引入非线性	局部取最大值 高、宽各减半

固定核教学演示，非训练结果。红：负响应；白：0；蓝：正响应。

卷积核在局部窗口里计算

输入：3 × 3

1	2	3
4	5	6
7	8	9

卷积核：2 × 2

1	0
0	-1

输出：2 × 2

-4	-4
-4	-4

$$1 \times 1 + 2 \times 0 + 4 \times 0 + 5 \times (-1) = -4$$

逐元素相乘，再求和。同一个核滑到下一个位置，重复计算。

激活改变数值，池化改变尺寸

ReLU（Rectified Linear Unit）

修正线性单元：负值变为 0

输入	-2	0	3
输出	0	0	3

$$g(z) = \max(0, z)$$

z：激活前数值；输出尺寸不变

2 × 2 最大池化，步长 2

1	3	2	0
4	2	1	5
0	6	3	1
2	1	4	2

→

4	5
6	4

4 × 4 → 2 × 2

池化保留局部最大响应，也会丢失部分精确位置信息。

层与层连接时，先核对维度

PyTorch 图像张量：[B, C, H, W]

B：批量图片数；C：通道数；H、W：高、宽

$$H_{\text{out}} = \left\lfloor \frac{H_{\text{in}} + 2p - k}{s} \right\rfloor + 1$$

H 的下标 in / out 表示输入 / 输出，$\lfloor \cdot \rfloor$ 表示向下取整。
k：核大小；p：每侧填充；s：步长。这里膨胀率为 1，宽度同理。

操作	输入	输出
3 × 3 卷积，填充 1，步长 1	[B, 3, 128, 128]	[B, 16, 128, 128]
2 × 2 池化，步长 2	[B, 16, 128, 128]	[B, 16, 64, 64]

Oxford-IIIT Pet：真实宠物照片

37 个猫狗品种，7,349 张图片。本实验统一学习“宠物前景”。



Bengal



Persian



Siamese



samoyed



english cocker spaniel

观察难点：毛发边界、姿态变化、相似背景和遮挡

三值标注与本实验的二值目标

原图

三值标注

训练目标

Abyssinian_10



Trimap: pet / background / unknown



Target: white=pet, gray=ignored



beagle_10



Trimap: pet / background / unknown



Target: white=pet, gray=ignored



1 宠物前景
目标为 1

2 背景
目标为 0

3 未确定区域
损失与指标忽略

固定划分与同步预处理

集合	图片数	用途
训练集	2,941	更新网络参数
验证集	739	选择网络、超参数与最佳轮次
测试集	3,669	选定模型后做最终评估

统一缩放到 128 × 128

图片：双线性插值
标注：最近邻插值

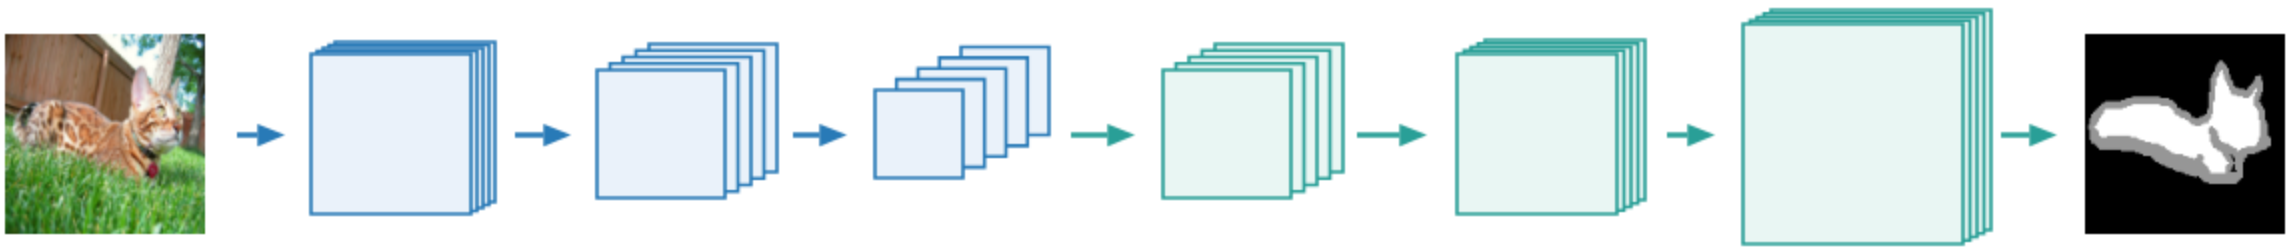
图片与掩码一起翻转

随机增强仅用于训练集
三份名单互不相交

基础模型：编码器与解码器

学生搭建编码器（Encoder / Backbone），课程提供解码器（Decoder）

空间变小 · 通道增多　　空间变大 · 通道整体减少



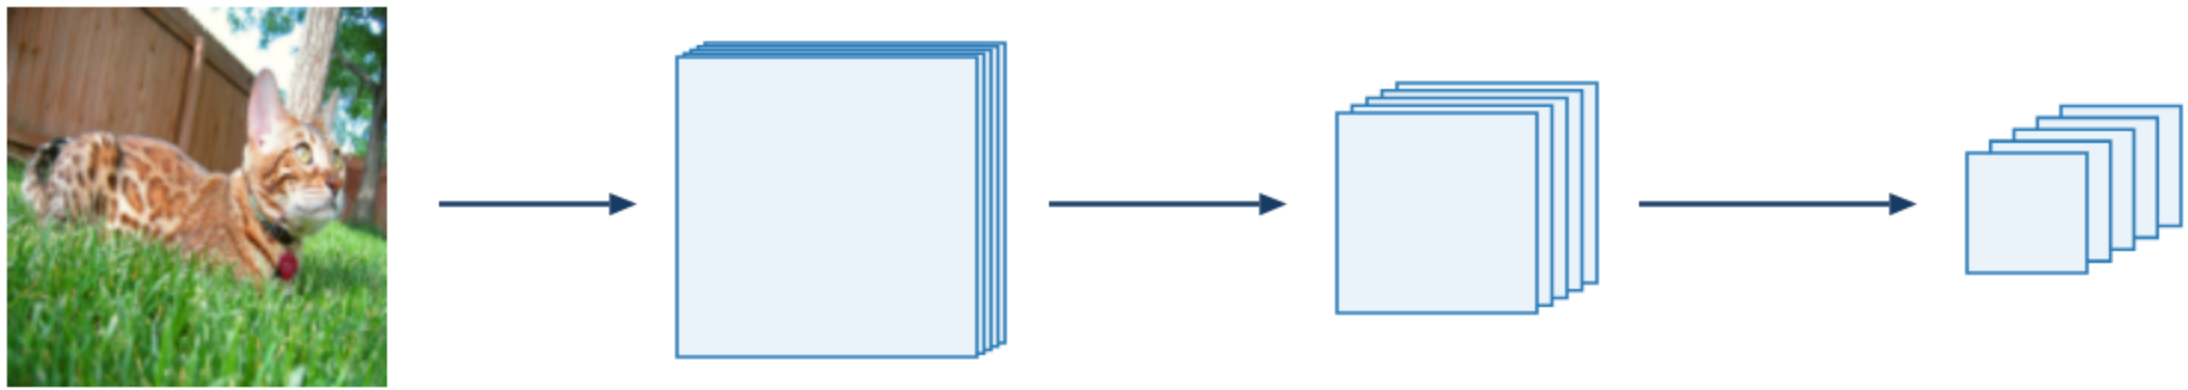
1 × 1 卷积
生成单通道得分

正面大小：空间分辨率；叠层厚度：通道数（示意）。

右侧展示目标标注；实际输出经概率变换与阈值判断后得到预测掩码。

编码器：空间更小，特征通道更多

每个阶段：3 × 3 卷积 → ReLU → 2 × 2 池化



输入图片
RGB 三通道

阶段 1：e1
较高分辨率

阶段 2：e2
中间尺度

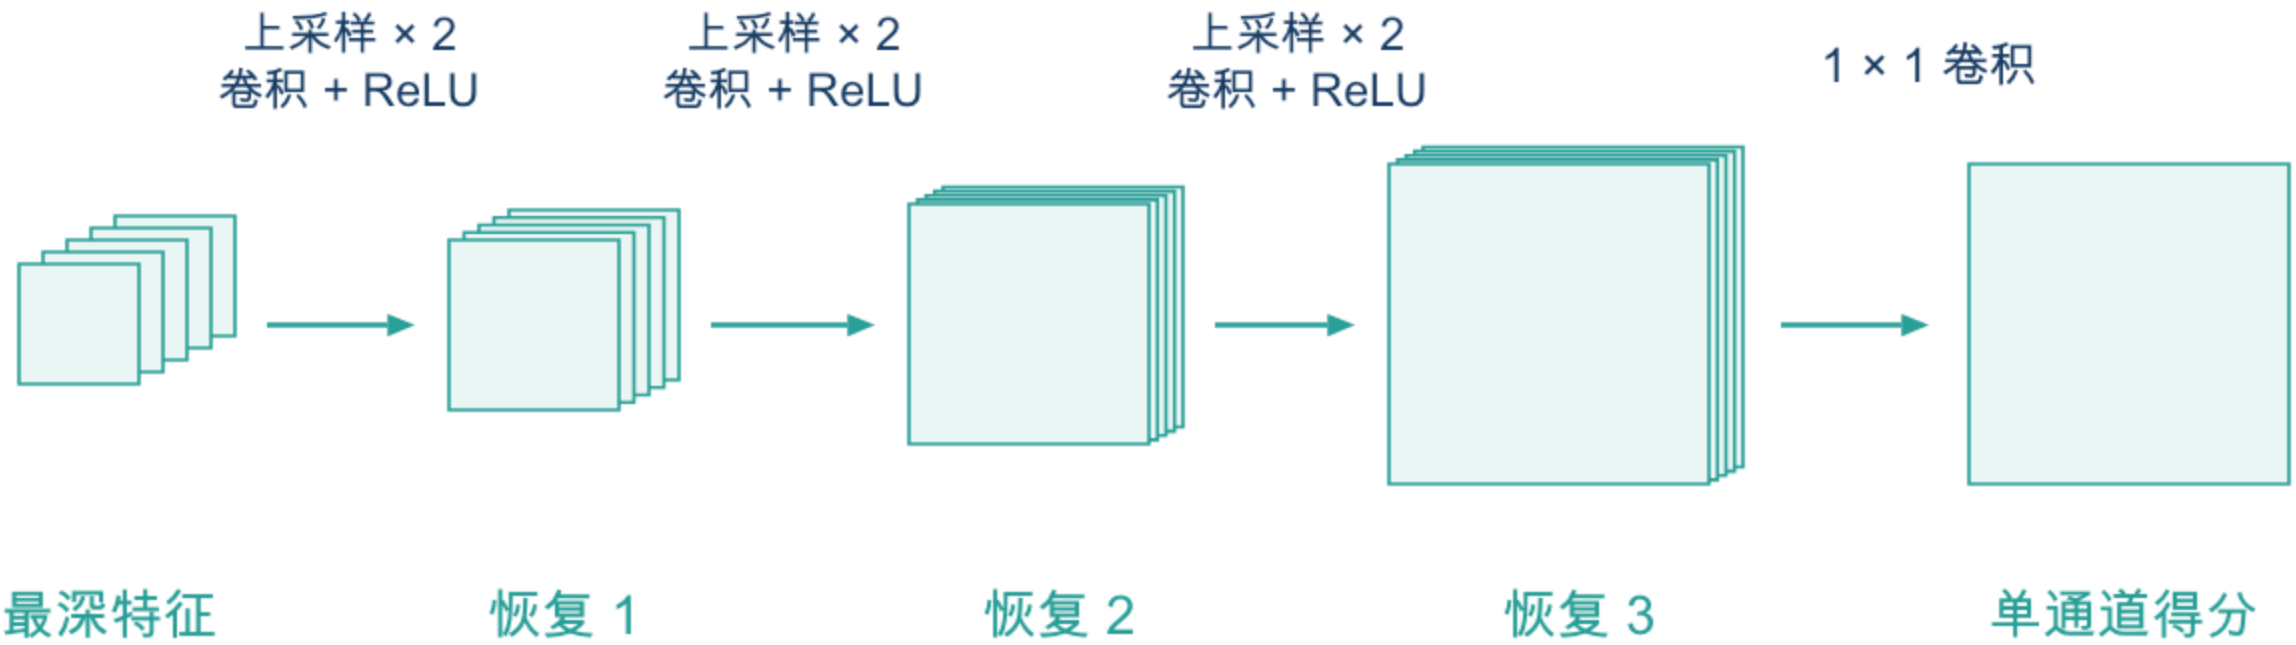
阶段 3：z
最深特征

RGB（Red, Green, Blue）：红、绿、蓝。图中每一叠表示一组特征图。

卷积学习不同的响应；池化减少空间位置。e1、e2、z 都要保留。

解码器：逐步恢复逐像素输出

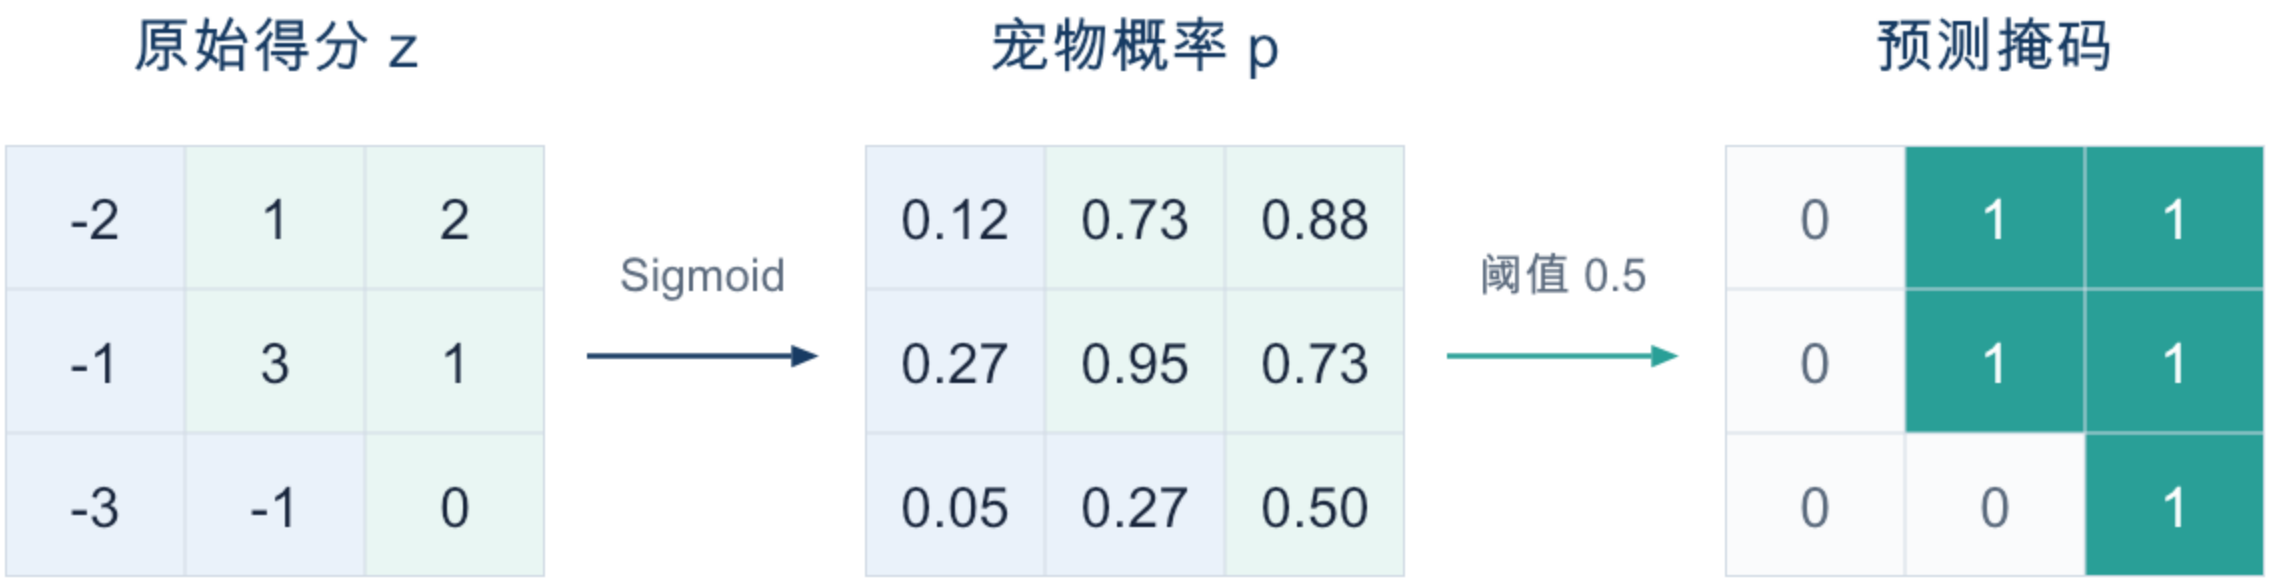
每次先上采样扩大特征图，再用卷积学习组合



通道整体减少，部分阶段保持不变；输出头把多通道变为单通道。

插值能恢复尺寸，却无法凭空找回池化时丢失的细节。

单通道得分、概率与预测掩码



$$p = \sigma(z) = \frac{1}{1 + \exp(-z)}$$

$$\hat{y} = \mathbf{1}[p \geq 0.5] = \mathbf{1}[z \geq 0]$$

σ 是 Sigmoid 函数；ŷ 是预测标签；1[条件] 在条件成立时取 1，否则取 0。

训练交给损失函数的是原始得分。上述数字仅作教学演示。

训练目标：只在有效像素上计算损失

二元交叉熵衡量概率与标签的差异

$$\mathcal{L}_{\text{pix}} = -y \log p - (1 - y) \log(1 - p)$$

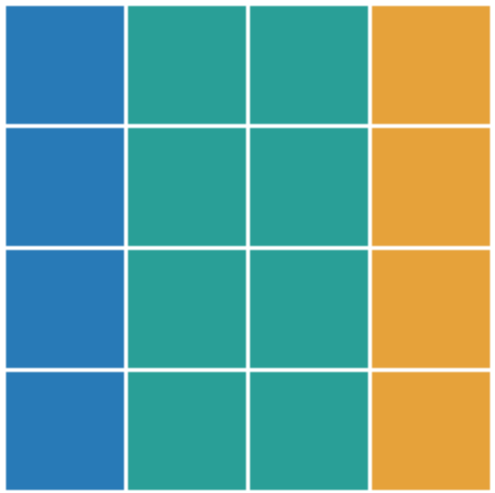
y 是 0 或 1 的标签，p 是宠物概率，log 表示自然对数。

区域	是否计入训练损失	是否计入评估
宠物 / 背景	计入	计入
原始标注值 3	忽略，梯度为 0	忽略

先对每张图片的有效像素取平均，再对批量图片取平均。

IoU 与 Dice：预测区域重合了多少

IoU（Intersection over Union，交并比）



P：预测前景，共 12 格
G：真实前景，共 12 格

$$\mathrm{IoU} = \frac{|P \cap G|}{|P \cup G|} \qquad \mathrm{IoU} = \frac{8}{16} = 0.5$$

重合部分，占两者覆盖范围的比例

并集包含误检、漏检和正确重合，共 16 格。

$$\mathrm{Dice} = \frac{2|P \cap G|}{|P| + |G|} \qquad \mathrm{Dice} = \frac{2 \times 8}{12 + 12} = \frac{2}{3} \approx 0.667$$

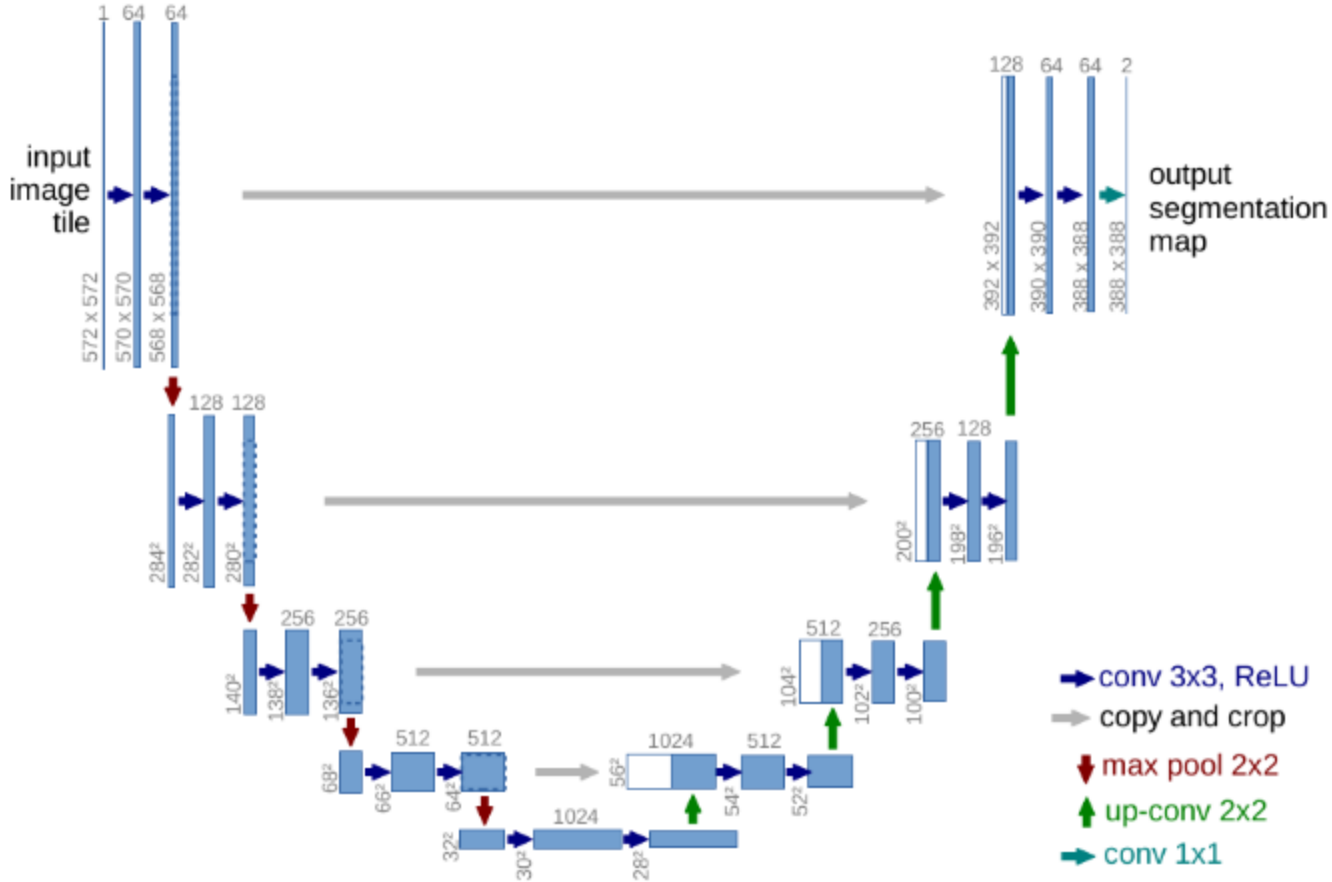
重合部分，相对于两份前景的总量

两份前景合计 24 格，重合在分子中也计两次。

仅 P：4　　重合：8　　仅 G：4

|·| 表示像素数；∩ 为交集，∪ 为并集。只看有效像素，最后逐图取平均。

U-Net：让解码器接收浅层特征



左侧：降低分辨率
学习更大范围的表示

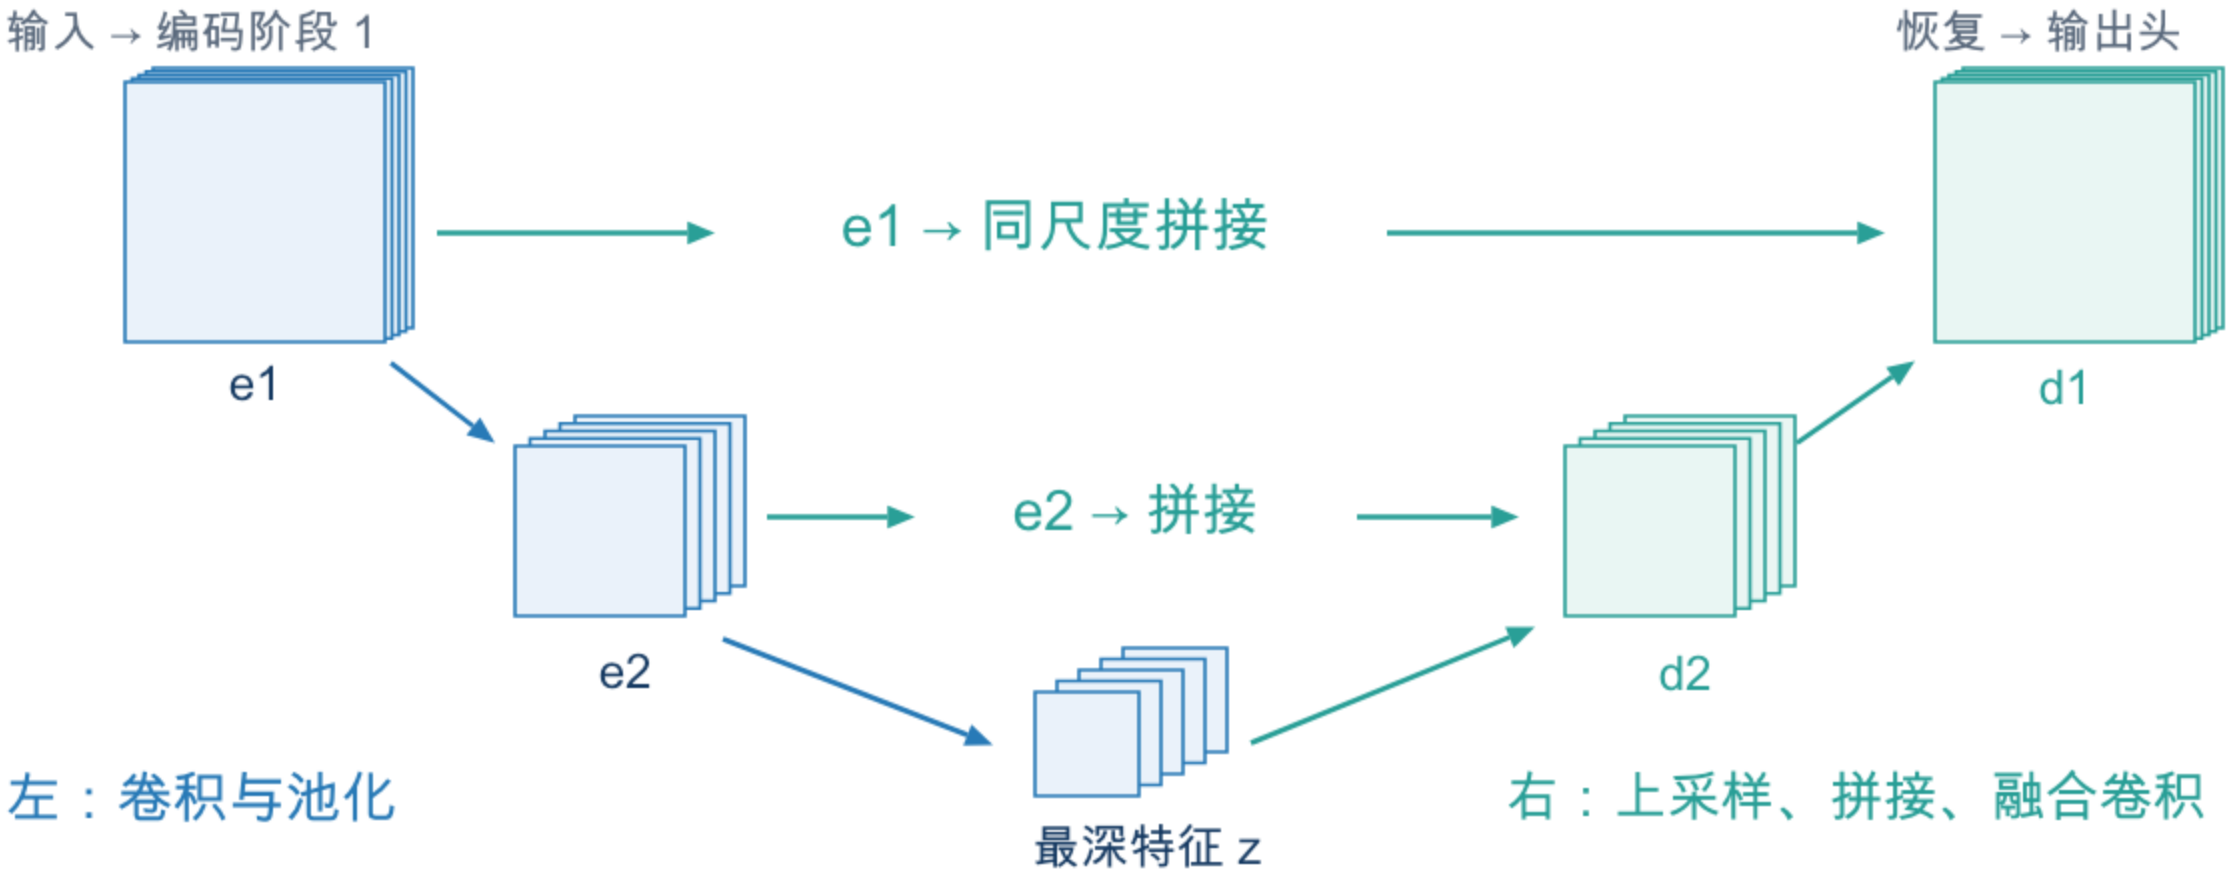
右侧：提高分辨率
恢复逐像素输出

横向：传递浅层特征
补充定位细节

原论文结构示意。下一页使用本实验的简化配置。

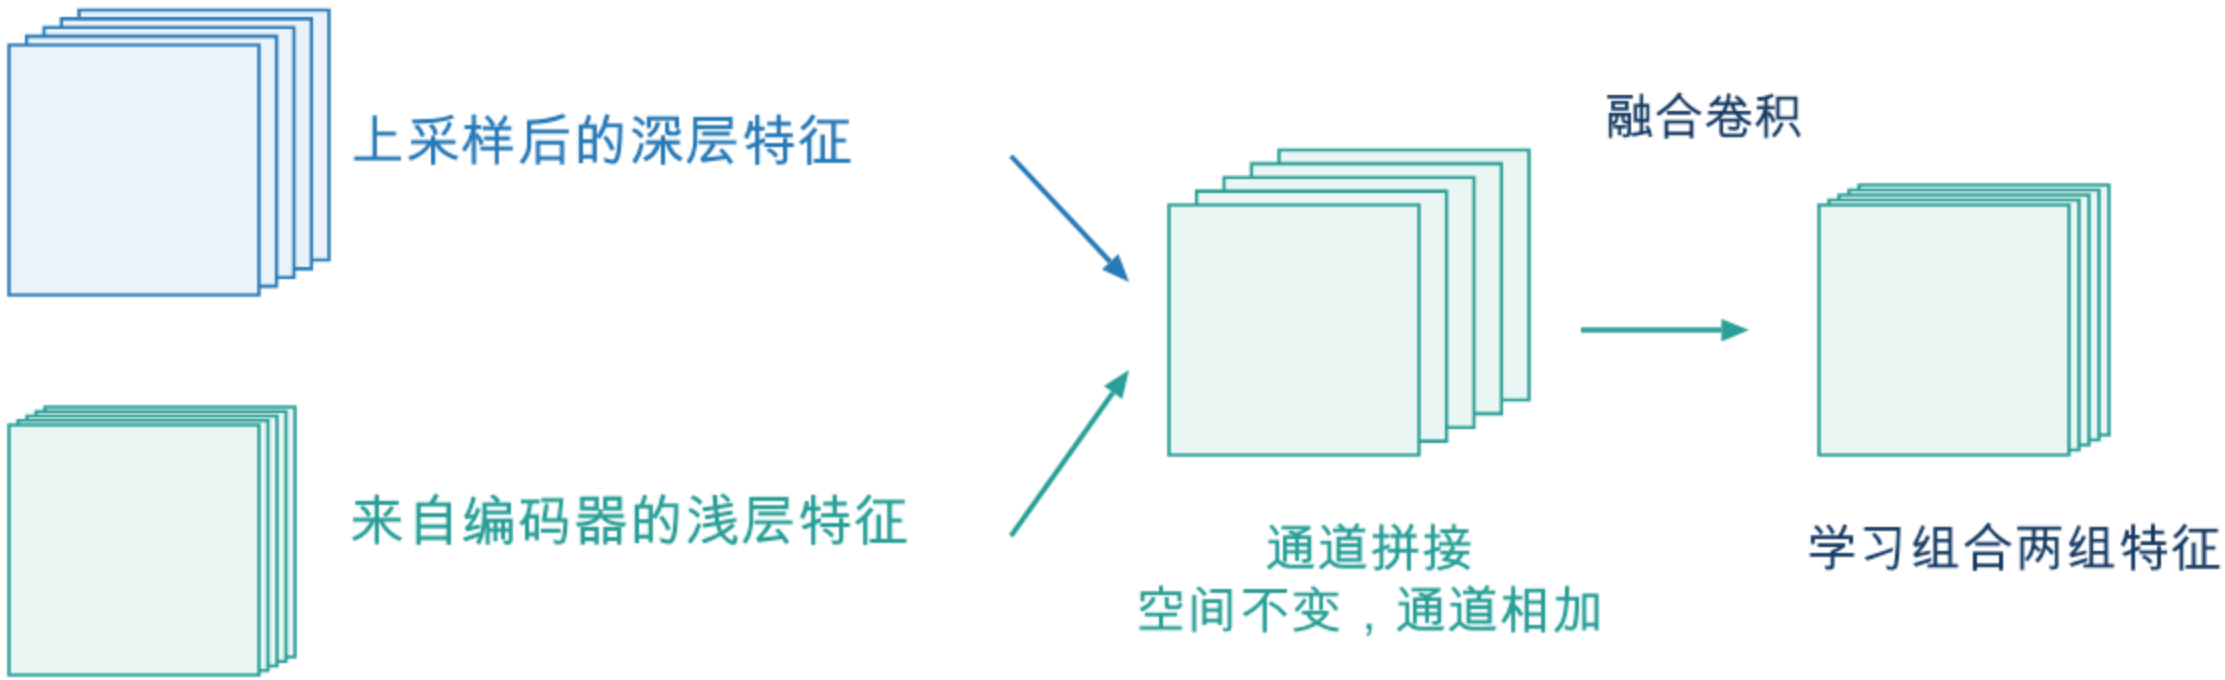
进阶选做：小型 U-Net

跳跃连接把较高分辨率的特征，送到同尺度的解码阶段



跳跃连接：对齐、拼接、融合

先把深层特征上采样，使它与跳跃特征的高、宽一致



示例：64 通道与 32 通道拼接成 96 通道，再由卷积映射到 32 通道。

U-Net 拼接与 ResNet 相加

ResNet（Residual Network，残差网络）

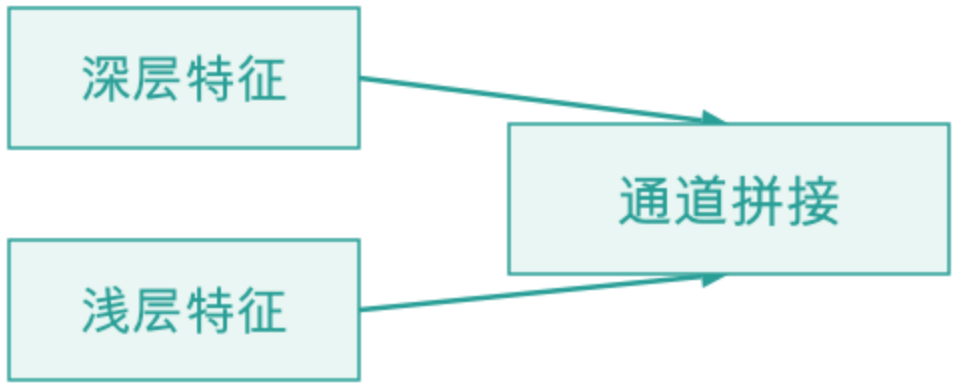
残差相加：学习对输入的修正



$$\mathbf{Y} = F(\mathbf{X}) + \mathbf{X}$$

对应元素相加，形状需匹配
通道数不变，传递恒等路径

U-Net 拼接：融合不同层的特征



高、宽对齐，沿通道保留两组特征
再由卷积学习融合，补充定位细节

BN 与 LN：稳定特征尺度，帮助训练

BN（Batch Normalization）

批量归一化

同一通道，跨样本与空间位置统计

作用：控制特征尺度，改善优化
批量统计的噪声可能带来正则化效果

注意：小批量统计可能不稳定
训练、评估使用统计量的方式不同

LN（Layer Normalization）

层归一化

同一样本，在指定特征维度统计

作用：稳定每个样本的特征尺度
不依赖同批次的其他样本

注意：先明确归一化哪些维度
不能把 LN 当成 BN 的直接替换

归一化后仍有可学习的缩放与平移；是否提升泛化，要用验证集对照。

学生需要补全的代码

文件	学生完成	检查命令
operator_exercises.py	卷积、激活、池化	python checks.py operators
student_encoder.py	三阶段编码器 及一个改进版本	python checks.py encoder python checks.py basic python checks.py improved

已提供：数据处理、基础解码器、训练循环、损失与评估。

进阶选做：自行实现小型 U-Net，不提供代码骨架。

先核对尺寸与梯度更新，再提交107平台训练任务。

在107平台训练与评估

进入 code/，先提交 smoke 短任务，再提交正式训练

```
bash scripts/submit.sh smoke
bash scripts/submit.sh basic
bash scripts/submit.sh improved
```

在验证集上选定模型后，使用对应权重提交最终测试。

```
bash scripts/submit.sh evaluate
```

环境与数据路径、LAB05_CHECKPOINT 的设置见讲义。

至少完成一组受控对比

实验	变化	保持一致
基础模型	三阶段编码器	划分、分辨率、训练预算
改进模型	例如只加入 BN	同一解码器与评估口径
进阶 U-Net	加入跳跃连接与融合	相同数据与训练设置

报告记录

验证 IoU、损失曲线、参数量与训练耗时。
至少分析 3 个相对成功案例和 3 个失败案例。

评分与提交内容

评分项	分值
基础运算与尺寸解释	20
编码器实现与连接	30
平台训练与复现	20
对比与错误分析	20
最终分割效果	10

效果分（10 分）
测试集平均前景 IoU 乘以 10

进阶最多加 20 分
总分封顶 100 分

连接与维度 8 · 有效对照 8
与残差思想的理论比较 4

提交代码、报告、最佳权重
训练记录、代码快照
测试指标与107平台日志

完整数据集、环境与缓存不打包。

开始实验前的四个检查问题

01 卷积怎样改变通道数？池化会改变通道数吗？

02 上采样回到原图大小，是否意味着细节全部恢复？

03 64 通道与 32 通道拼接后，融合卷积接收多少通道？

04 为什么分割效果主要看前景 IoU，而不是像素准确率？

参考资料与图片来源

课程理论	邱锡鹏《神经网络与深度学习》第5章 实验05讲义与配套 PyTorch 代码
宠物照片与标注	Parkhi 等，Oxford-IIIT Pet / Cats and Dogs (2012) robots.ox.ac.uk/~vgg/data/pets/
网络结构	Ronneberger 等，U-Net (2015)，原论文 Figure 1 He 等，Deep Residual Learning (2015)
接口说明	PyTorch：Conv2d、BatchNorm2d、LayerNorm 图片出处与课堂提问见各页讲者备注

基础实现有局限，任务本身有提升空间

同一测试集：3,669 张图片；按每张图片的前景指标取平均

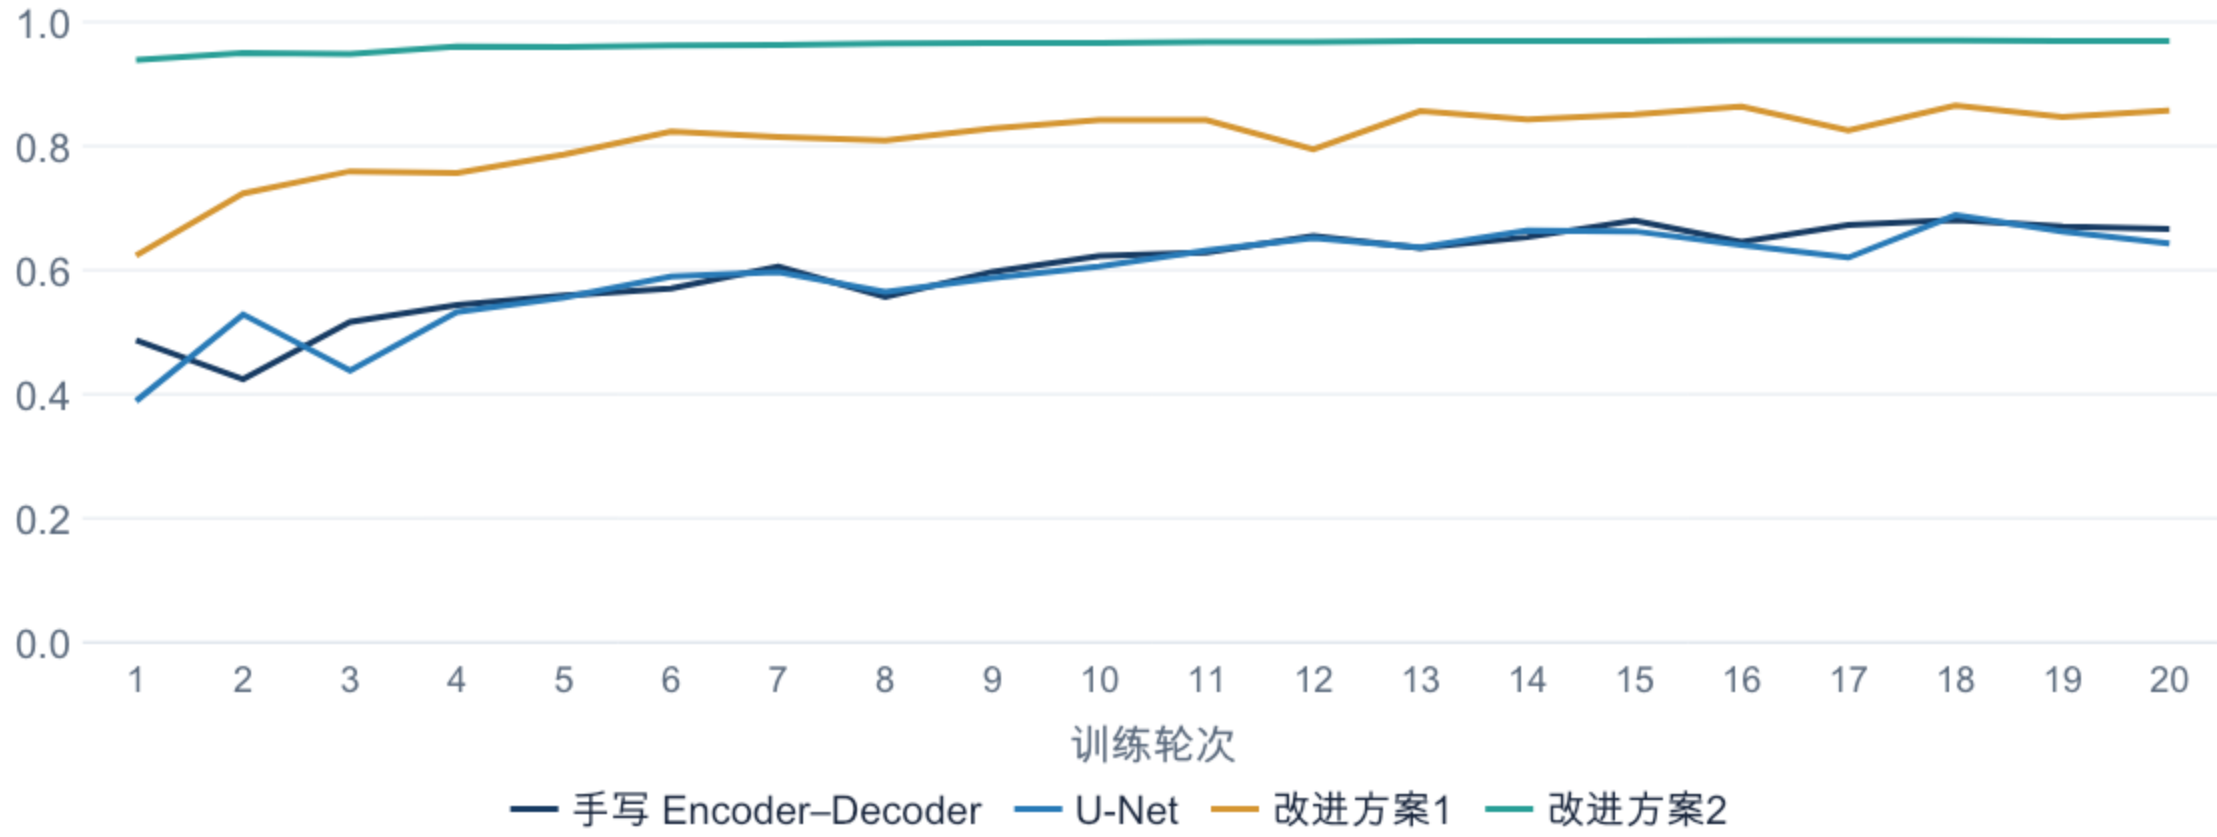
实验	测试 IoU ↑	测试 Dice ↑
手写 Encoder–Decoder	0.702	0.806
U-Net	0.707	0.811
改进方案1	0.867	0.917
改进方案2	0.969	0.981

从约 0.70 到约 0.97：分割质量还有很大提升空间

统一 128 × 128 评估网格，阈值 0.5，忽略不确定边界；训练配置不同。

训练曲线：观察分割效果如何变化

每轮训练结束后，在同一验证集上计算前景 IoU（越高越好）

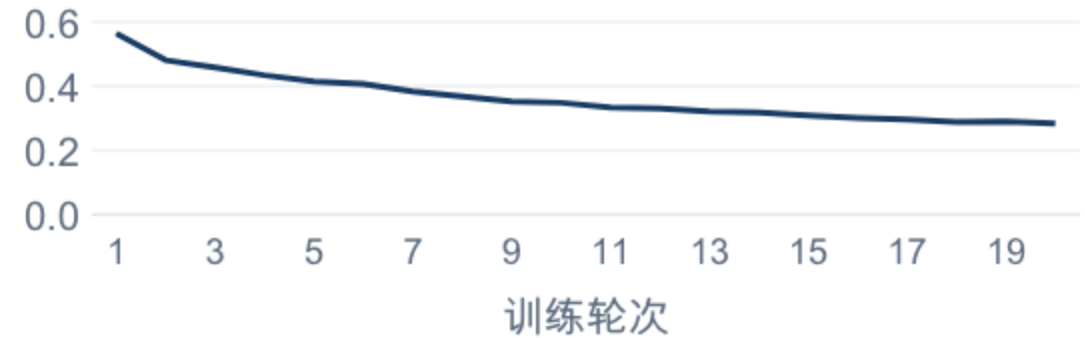


曲线保留真实波动；最终模型由验证集选择，再做一次完整测试。

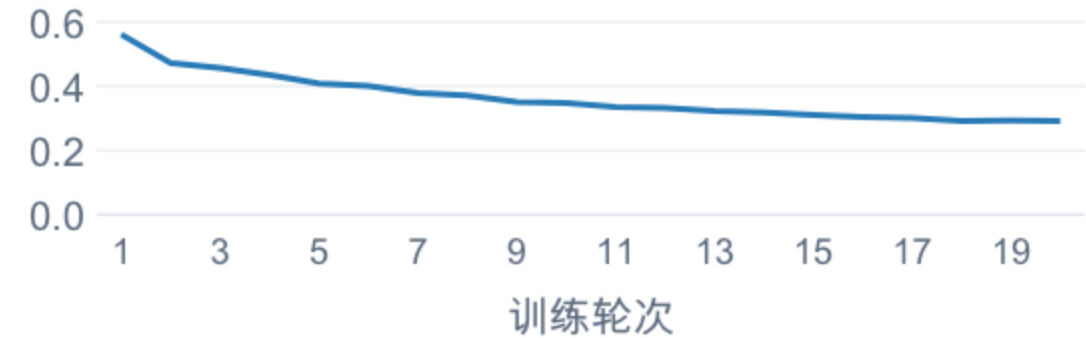
训练损失下降，并不等于分割已经足够好

同时看训练损失、验证指标和预测图片，才能判断模型学到了什么

手写 Encoder–Decoder



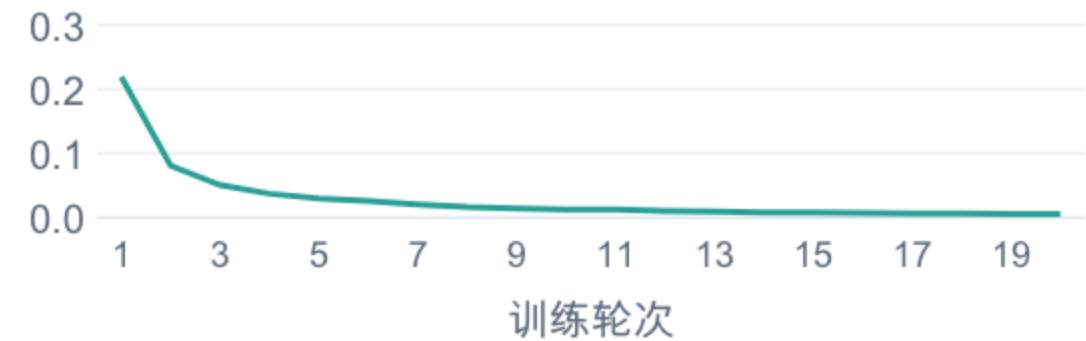
U-Net



改进方案1



改进方案2



各子图纵轴独立；损失定义可能不同，数值不作横向排名。

同一张图片，分割结果可以差多少（1/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

输入图片	真实掩码	手写 Encoder–Decoder	U-Net	改进方案1	改进方案2
					
Birman_5		IoU 0.638	IoU 0.696	IoU 0.564	IoU 0.969
					
Maine_Coon_69		IoU 0.242	IoU 0.444	IoU 0.344	IoU 0.995

白：宠物；黑：背景；灰：标注中的忽略区域。

同一张图片，分割结果可以差多少（2/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

输入图片	真实掩码	手写 Encoder–Decoder	U-Net	改进方案1	改进方案2
					
Siamese_47		IoU 0.882	IoU 0.846	IoU 0.787	IoU 0.872
					
scottish_terrier_99		IoU 0.518	IoU 0.627	IoU 0.466	IoU 0.992

白：宠物；黑：背景；灰：标注中的忽略区域。

同一张图片，分割结果可以差多少（3/3）

此前固定抽取的 6 张测试图片，按原顺序全部展示

输入图片	真实掩码	手写 Encoder–Decoder	U-Net	改进方案1	改进方案2
					
boxer_27		IoU 0.957	IoU 0.906	IoU 0.820	IoU 1.000
					
great_pyrenees_22		IoU 0.834	IoU 0.862	IoU 0.994	IoU 0.998

白：宠物；黑：背景；灰：标注中的忽略区域。

手写网络是起点，分割质量可以继续提高

0.70 → 0.97

同一测试集上的平均前景 IoU

先完成：把原理变成能训练、能评估的网络

再探索：让每一次修改，都有曲线与预测结果作证

基础模型的效果有限，不意味着这个任务只能做到这样。

在本实验评价口径下，可以做得很好；高平均分也仍有失败样例。